Intro



© 2023 *Olivier Claerbout*

Lesmateriaal

- Via GitHub account:
  git clone https://github.com/oclaerbout/syntra_data_scientist.git
- © 2023 Olivier Claerbout

  Dit materiaal mag niet worden gekopieerd, verspreid, gepubliceerd of anderszins gereproduceerd zonder uitdrukkelijke schriftelijke toestemming van de auteur. Dit geldt eveneens voor de Jupyter Notebooks!

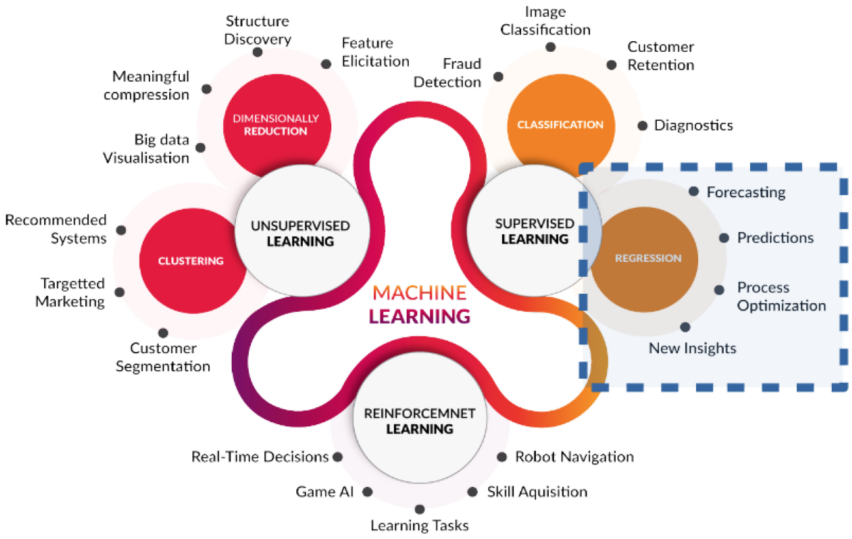
© 2023 *Olivier Claerbout*

Regressie
Enkelvoudige lineaire regressie



© 2023 *Olivier Claerbout*

Lineaire regressie



© 2023 *Olivier Claerbout*

Lineaire regressie

Aanpak:

- Theorie
- Eenvoudige implementatie met Python
- Lineaire regressie met Scikit-learn: ML library
- Polynomiale regressie
- Regularisatie

© 2023 *Olivier Claerbout*

Lineaire regressie

Theorie

- Kansmodellen en bivariate gegevens
- Berekening van samenhang tussen bivariate gegevens
- Lineaire relaties
- Kleinste Kwadraten Methode (Ordinary Least Squares / Least Mean Squares)
- Kostenfuncties
- Gradient descent
- Vectorisatie

© 2023 *Olivier Claerbout*

Bivariate gegevens

Bivariate gegevens zijn gegevens die bestaan uit 2 variabelen:

- Gewicht v/e auto en zijn remafstand
- Snelheid waarmee je rijdt & het verbruik
- Buitentemperatuur & verbruik airco / warmtepomp
- ...

De onafhankelijke variabele is de variabele die men gebruikt om de voorspelling op te baseren. Deze komt op de x as. De afhankelijk variabele is de variabele die men voorspelt. Deze komt op de y as.

© 2023 *Olivier Claerbout*

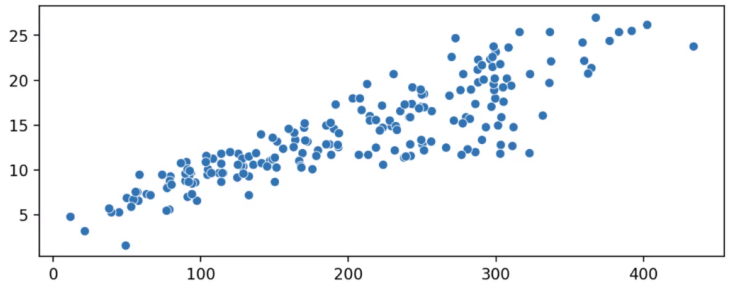
Bivariate gegevens

Beschrijven van de relatie tussen kwantitatieve variabelen

- **Puntenwolk**
- Covariantie
- Correlatiecoëfficiënt

© 2023 *Olivier Claerbout*

Bivariate gegevens



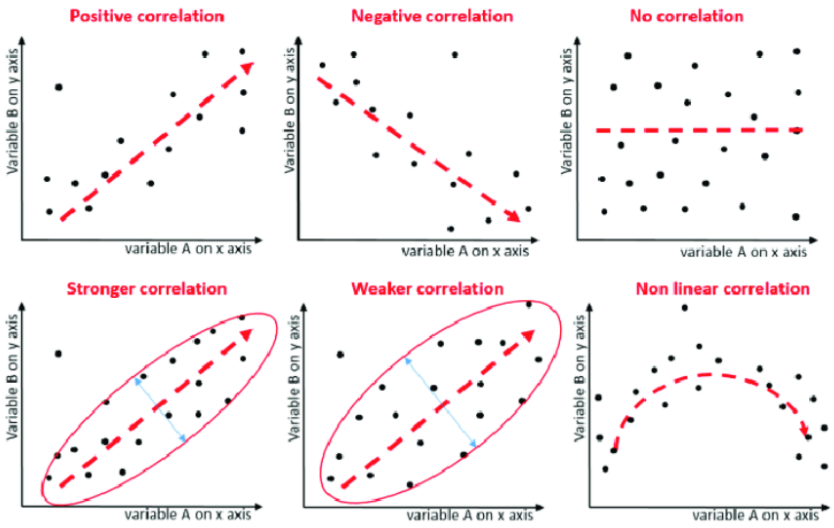
Voorstelling bivariate gegevens

© 2023 *Olivier Claerbout*

Bivariate gegevens

Voorstelling van de lineaire samenhang van bivariate gegevens:

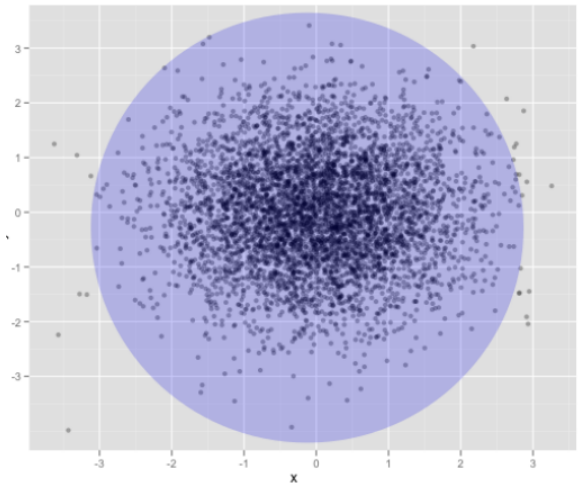
- Richting (+ of -)
- Sterkte



© 2023 *Olivier Claerbout*

Bivariate gegevens

Voorstelling van de lineaire samenhang van bivariate gegevens



© 2023 *Olivier Claerbout*

Lineaire regressie

Beschrijven van de relatie tussen kwantitatieve variabelen

- Puntenwolk
- **Covariantie**
- Correlatiecoëfficiënt

© 2023 *Olivier Claerbout*

Covariantie

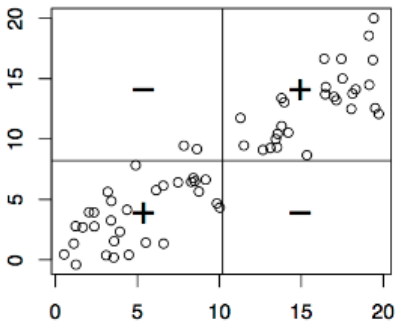
- De covariantie Sxy drukt een maat uit voor de (lineaire) samenhang tussen twee variabelen.
- De covariantie meet hoe de verandering van de ene veriabele de verandering van de andere variabele beïnvloedt.
- De covariantie Cov (x, y) = S xy tussen twee stochastische variabelen x en y wordt gegeven door:

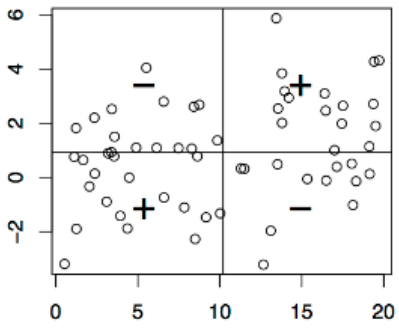
$$Cov(x,y) = \frac{\sum_{i=1}^{N}(x_i - \mu_x)(y_i - \mu_y)}{N} \qquad \text{Populatie covariantie}$$

$$Cov(x,y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n-1} \qquad \text{Steekproef covariantie}$$

© 2023 *Olivier Claerbout*

Covariantie - intuïtief





$$Cov(x,y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

© 2023 *Olivier Claerbout*

Lineaire regressie

Beschrijven van de relatie tussen kwantitatieve variabelen

- Puntenwolk
- Covariantie
- **Correlatiecoëfficiënt**

© 2023 *Olivier Claerbout*

Correlatie(coëfficiënt)

- De covariantie is afhankelijk van de ***schaal van de variabelen***
- Dat betekent dat de waarde moeilijk te interpreteren is zonder context.
- Een hoge covariantie betekent niet per se een sterk verband,
- omdat de schaal de grootte van de covariantie beïnvloedt.
- Daarom wordt vaak de correlatiecoëfficiënt gebruikt

© 2023 *Olivier Claerbout*

Correlatie(coëfficiënt)

De correlatiecoëfficiënt is gelijk aan de genormaliseerde covariantie en heeft een Waarde tussen -1,0 en +1,0

$$r_{xy} = \frac{cov(x,y)}{\sqrt{s_x^2 s_y^2}} = \frac{cov(x,y)}{s_x s_y} = \frac{s_{xy}}{s_x s_y}$$

Kruisproductensom SS_{xy}

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{n\, s_x s_y}$$

© 2023 *Olivier Claerbout*

Correlatie(coëfficiënt)

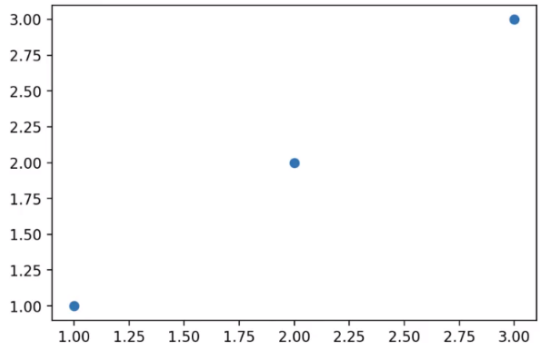
Eigenschappen van de correlatiecoëfficiënt:

- $r_{xy} > 0 \Rightarrow$ positieve lineaire samenhang.
- $r_{xy} < 0 \Rightarrow$ negatieve lineaire samenhang.
- $r_{xy} = +1 \Rightarrow$ perfect positieve lineaire samenhang.
- $r_{xy} = -1 \Rightarrow$ perfect negatieve lineaire samenhang.
- $r_{xy} = 0 \Rightarrow$ ontbreken van lineaire samenhang.

© 2023 *Olivier Claerbout*

Lineaire relaties

Eenvoudigste lineaire relatie?



y = [1, 2, 3]

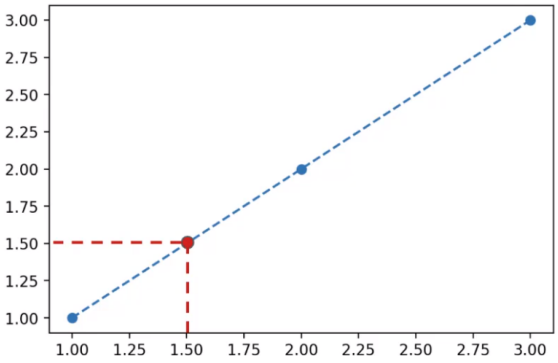
x = [1, 2, 3]

y = x

© 2023 *Olivier Claerbout*

Lineaire relaties

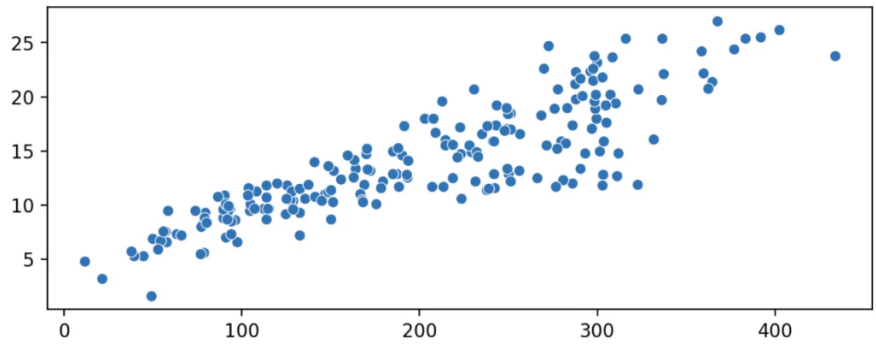
Eenvoudigste lineaire relatie?



© 2023 *Olivier Claerbout*

Lineaire relaties

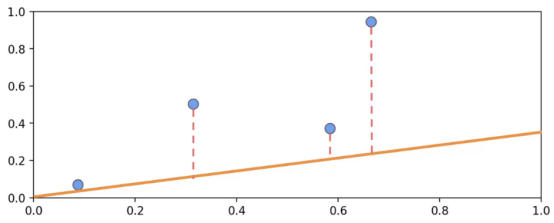
Wat met echte data?

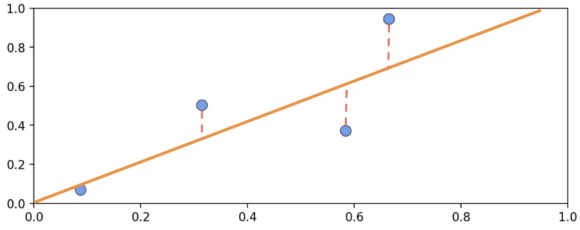


© 2023 *Olivier Claerbout*

Lineaire relaties

Beste fit bepalen



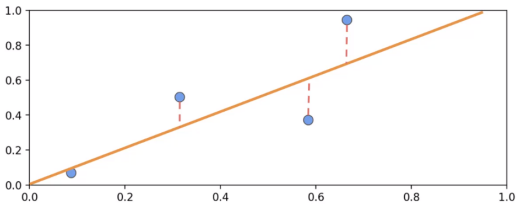


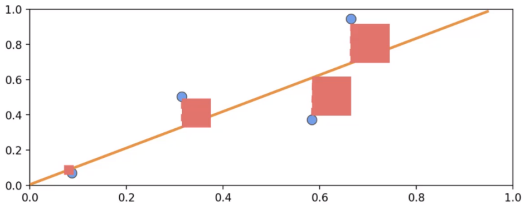
Residuals kunnen zowel positief als negatief zijn!

© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

*We willen de som v/d **kwadraten** van de verschillen tussen de waargenomen afhankelijke variabele (de waarden van de variabele die we observeren) in de gegeven dataset en de waarden die voorspeld worden door de lineaire functie minimaliseren.*





© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Op zoek naar het verband tussen de variabelen

Het verband (model of hypothese) $h_\theta(x)$ is van de vorm:

$$h_\theta(x) = \theta_0 + \theta_1 x$$

- Bepalen van de optimale waarden voor θ_0 en θ_1.
  - θ_0 = snijpunt met de y-as.
  - θ_1 = helling van de rechte.
- De parameters θ_i = **weights**.
- Het zoeken van het model / hypothese = **training / learning**.

© 2023 *Olivier Claerbout*

Lineaire regressie

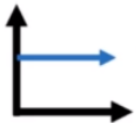
$h_\theta(x) = \theta_0 + \theta_1 x$



$0 < \theta_1$



$0 > \theta_1$



$0 = \theta_1$

© 2023 Olivier Claerbout

Enkelvoudige lineaire regressie

De lijn van de kleinste kwadraten is de lijn $h_\theta(x) = \theta_0 + \theta_1 x$ die voldoet aan de volgende twee voorwaarden:

1. De som van alle errors is gelijk aan 0 ⇒ De gemiddelde fout = 0
2. De som van de gekwadrateerde fouten (Sum of Squared errors SSE) is minimaal.

Bepalen van θ_0 en θ_1: $\hat{\theta}_1 = \frac{SS_{xy}}{SS_{xx}}$

$\hat{\theta}_0 = \bar{y} - \hat{\theta}_0 \bar{x}$

© 2023 Olivier Claerbout

Enkelvoudige lineaire regressie

Praktisch voorbeeld

We hebben een aantal datapunten en we willen θ_0 en θ_1 *bepalen.*

Gemiddelde:

$$\bar{x}=2{,}5$$
$$\bar{y}=3{,}5$$

x	y
1	3
2	4
3	2
4	5

$$\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})$$

SS_{xy}:

Voor punt 1: (1−2.5)(3−3.5)=−1.5×−0.5 = 0.75
Voor punt 2: (2−2.5)(4−3.5)=−0.5×0.5 = −0.25
Voor punt 3: (3−2.5)(2−3.5)=0.5×−1.5 = −0.75
Voor punt 4: (4−2.5)(5−3.5)=1.5×1.5 = 2.25
SOM = 0.75−0.25−0.75+2.25 = 2

SS_{xx}:

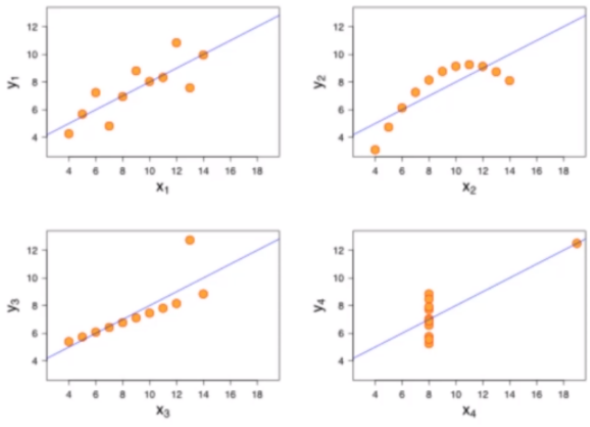
Voor punt 1: (1-2,5)² = 2,25
Voor punt 2: (2 – 2,5)² = 0,25
Voor punt 3: (3 – 2,5)² = 0,25
Voor punt 4: (4 - 2,5)² = 2,25
SOM = 5

Helling θ_1 = 2 / 5 = 0,4 & intercept θ_0= 3,5 – 0,4 * 2,5 = 2,54 dus $\hat{y}=0.4\,x+2{,}54$

© 2023 Olivier Claerbout

Enkelvoudige lineaire regressie

Beperkingen van Lineaire Regressie: Anscombe’s Quartet...



© 2023 Olivier Claerbout

Wat met meerdere features?

Lineaire relaties $h_\theta(x) = \theta_0 + \theta_1 x$

Kleinste kwadraten methode voor lineaire regressie met één feature – niet toepasbaar bij meerdere features!

Hoe meerdere features voorstellen?

© 2023 *Olivier Claerbout*

LR met meerdere features

	leeftijd	gewicht	bloeddruk
0	52	78	132
1	59	83	143
2	67	88	153
3	73	96	162
4	64	89	154
5	74	100	168
6	54	85	137
7	61	85	149
8	65	94	159
9	46	76	128
10	72	98	166

features: leeftijd en gewicht.
target: bloeddruk.
trainingset met 11 training examples.

© 2023 *Olivier Claerbout*

Lineaire regressie

$\hat{y} = \theta_0 x_0 + \ldots + \theta_n x_n$ → $\hat{y} = \sum_{i=0}^{n} \theta_i x_i$

→ bepalen van de beste waarden voor de θ_i*'s?*
→ *we bepaalden eerder dat een best passende rechte het kwadraat van de afwijkingen minimaliseert*
→ *hoe bepalen we eigenlijk de* **verliesfunctie** (cost function)?

© 2023 *Olivier Claerbout*

Lineaire regressie

De error voor een rij j is: $y^j - \hat{y}^j$

We minimaliseren de kwadratische fout: $(y^j - \hat{y}^j)^2$

Het gemiddelde van de som van de kwadraten van de fouten voor m rijen is dan: $\frac{1}{m}\sum_{j=1}^{m}(y^j - \hat{y}^j)^2$

Dit is een berekening voor de gemiddelde gekwadrateerde fout van de voorspellingen.

De verliesfunctie (ook wel cost function) meet hoe goed of slecht een bepaald model de gegevens beschrijft. De meest gebruikte verliesfunctie in lineaire regressie is de Mean Squared Error (MSE)

© 2023 *Olivier Claerbout*

Gradient descent

Onze doelen:

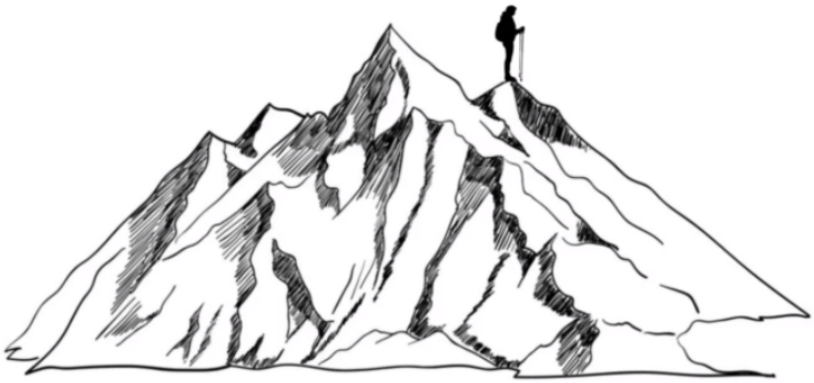
- *Een set θ coëfficiënten vinden die de error minimaliseert (de verlies- of kostfunctie)*
- *Rekenkracht van de computer gebruiken ipv een manuele oplossing van de afgeleide*

→ *we kijken hoe dit gevisualiseerd kan worden voor één enkele θ*

© 2023 *Olivier Claerbout*

Gradient descent

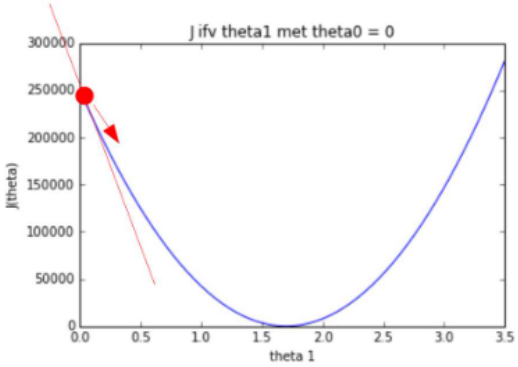
Analogie:



© 2023 *Olivier Claerbout*

Gradient descent

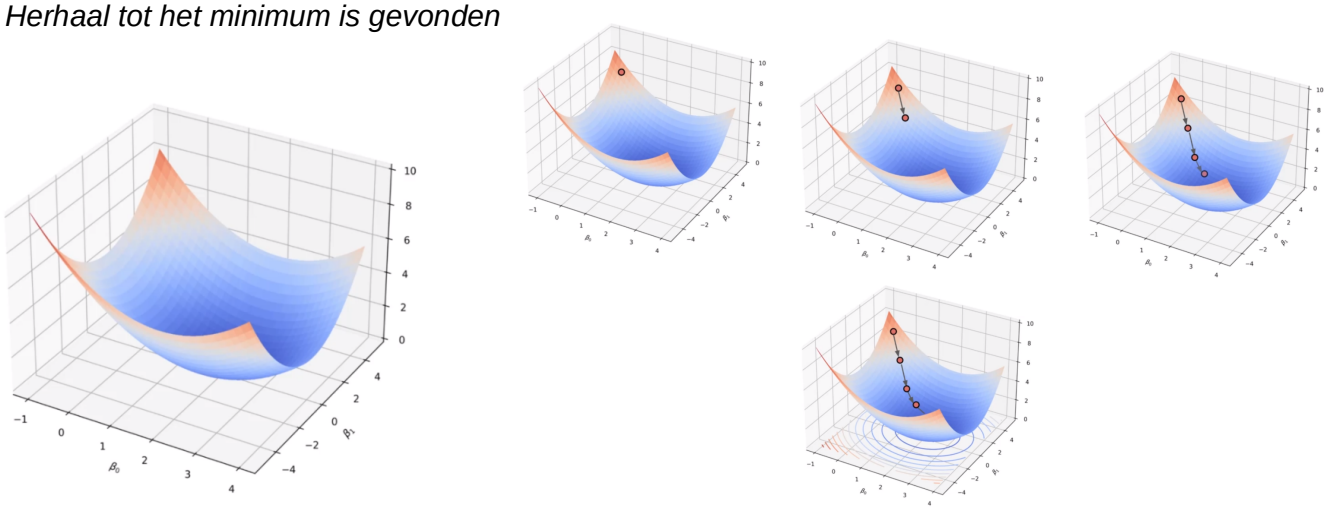
Bereken de gradient op een bepaald punt (1 feature: afgeleide)
Zet een stap proportioneel met de negatieve gradiënt
Herhaal tot het minimum is gevonden



© 2023 *Olivier Claerbout*

Gradient descent

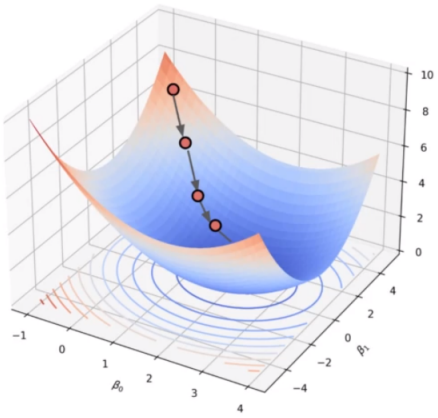
Bereken de gradient op een bepaald punt (2 features: gradient descent)
Zet een stap proportioneel met de negatieve gradiënt
Herhaal tot het minimum is gevonden

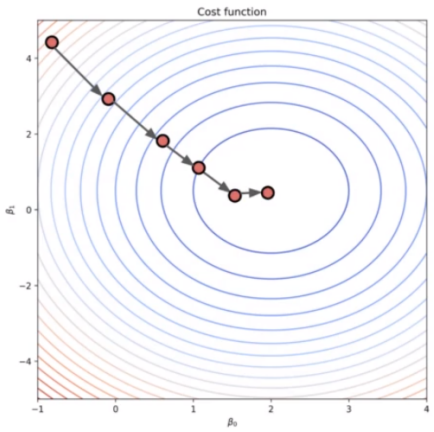


© 2023 *Olivier Claerbout*

Gradient descent

Bereken de gradient op een bepaald punt (2 features: gradient descent)
Zet een stap proportioneel met de negatieve gradiënt
Herhaal tot het minimum is gevonden





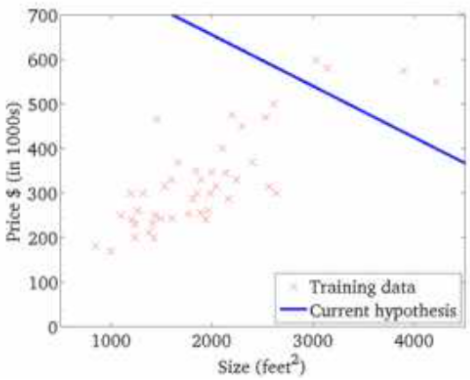
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

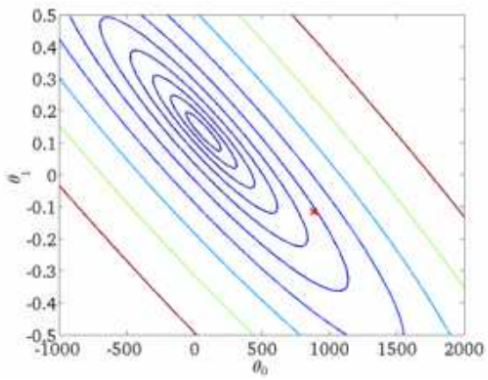
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



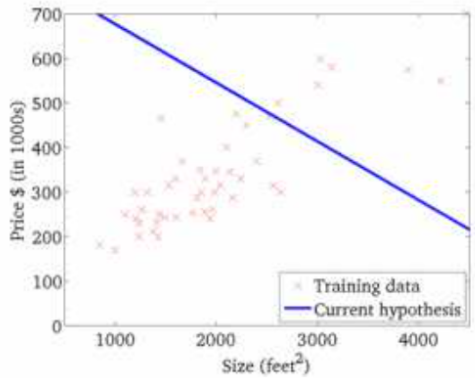
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

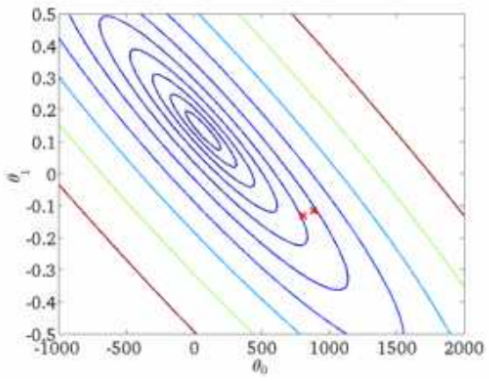
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



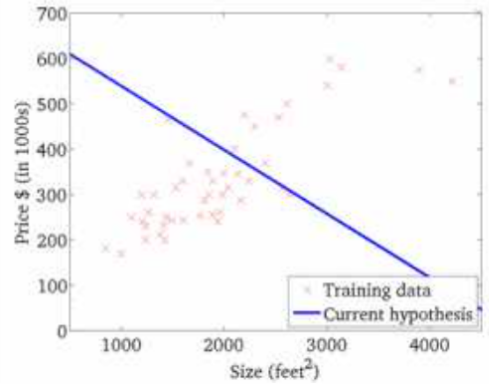
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

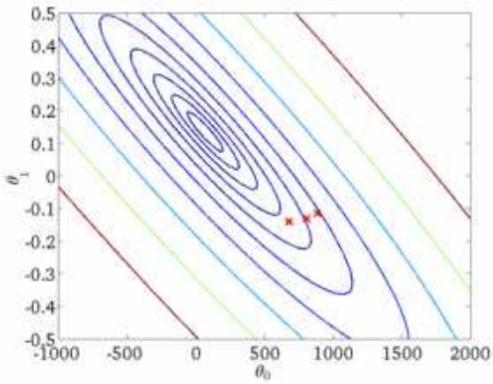
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



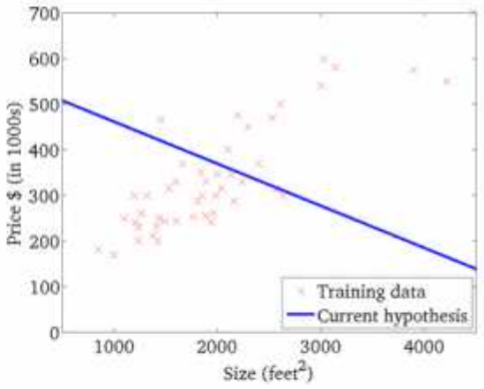
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

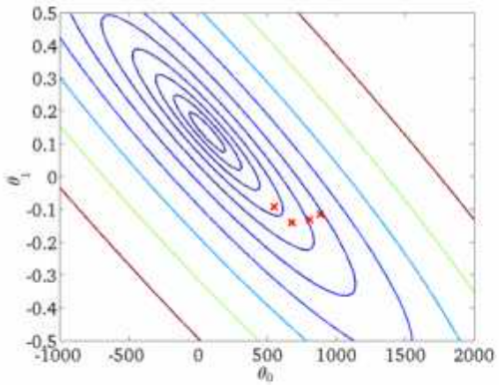
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



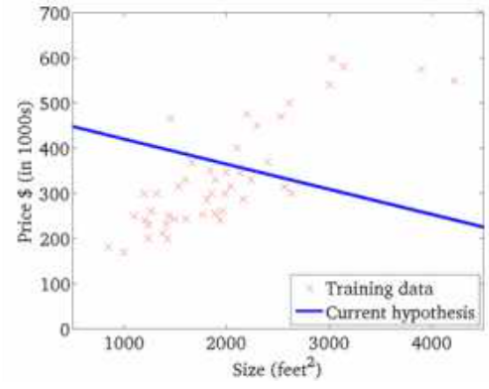
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

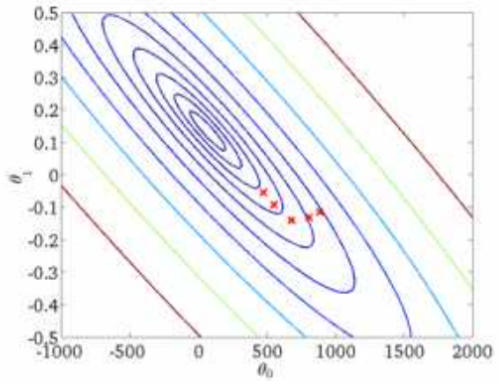
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



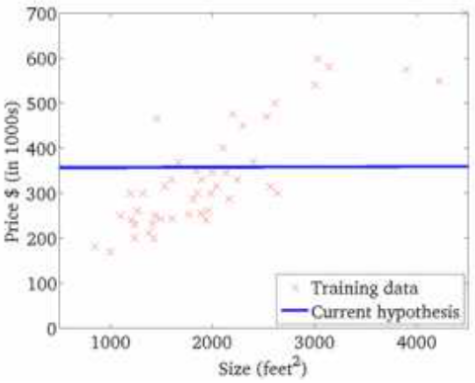
Maak werk van je toekomst
© 2023 *Olivier Claerbout*
SYNTRA ANTWERPEN & VLAAMS-BRABANT

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

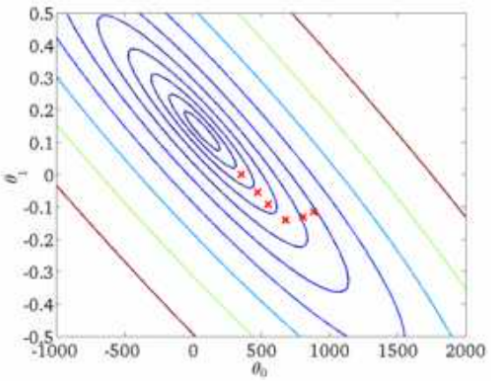
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



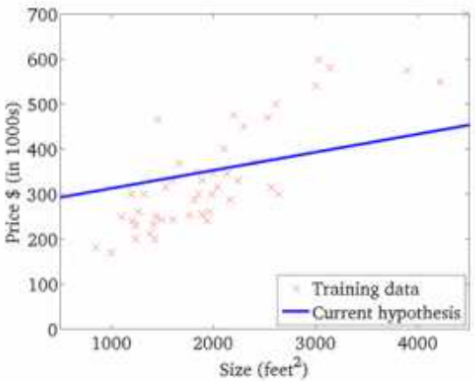
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

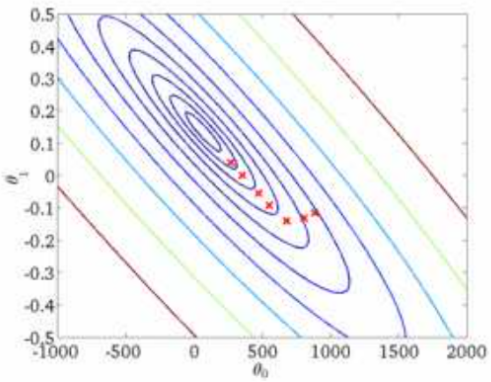
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



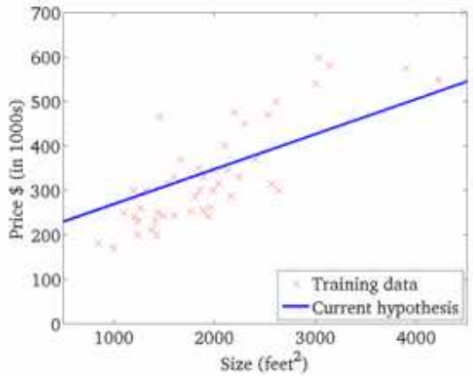
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

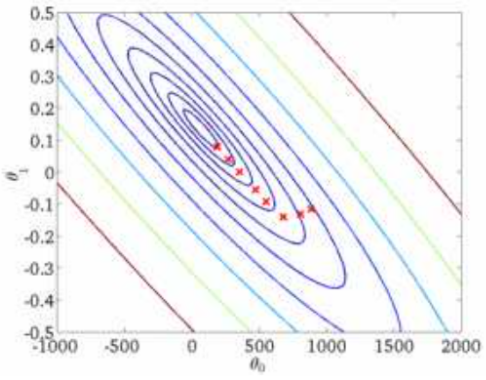
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)



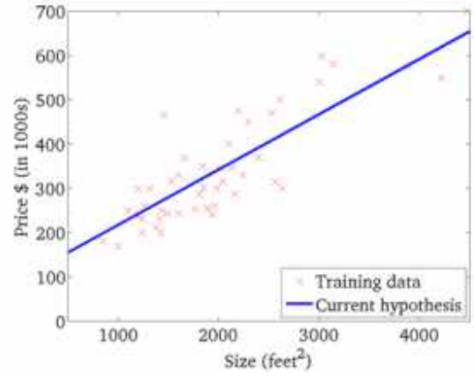
© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

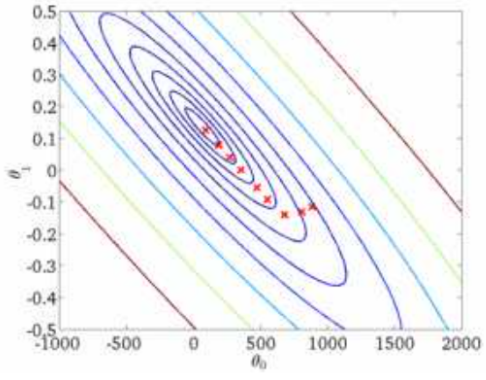
$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)



$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)

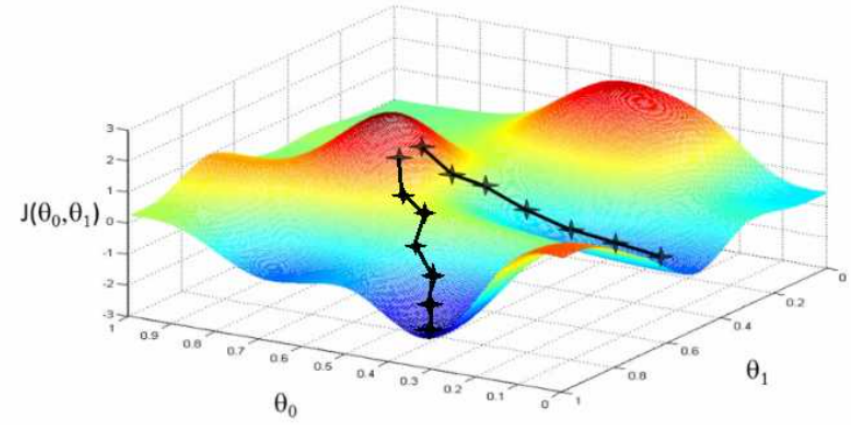


© 2023 *Olivier Claerbout*

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

Lokaal versus globaal optimum

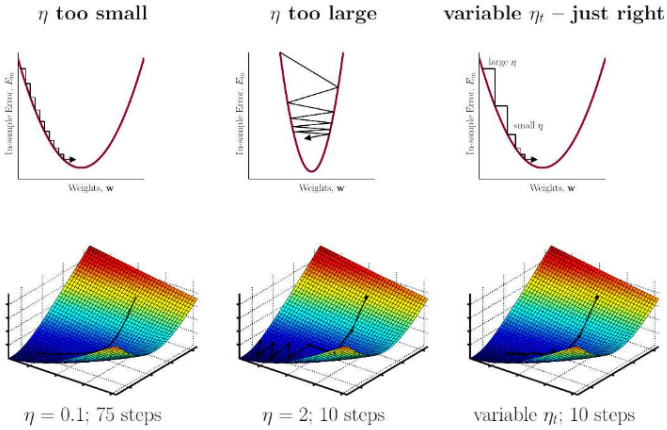


© 2023 Olivier Claerbout

Enkelvoudige lineaire regressie

Gradient Descent (GDS)

Invloed van de learning rate



© 2023 Olivier Claerbout

Samenvatting

Je wil de beste coëfficïenten voor het regressiemodel bepalen $\hat{y} = \theta_0 x_0 + \ldots + \theta_n x_n$

Dit doe je door de coëfficiënten te zoeken die een kostfunctie minimaliseren

Deze kostfunctie is meestal het gemiddelde van de kwadratische verschillen tussen de voorspelde en werkelijke waarden van y, ook bekend als de Mean Squared Error (MSE)

Het zoeken van de coëfficiënten gebeurt door eerst willekeurige θ's te gebruiken en vervolgens de kostfunctie te berekenen. Je gebruikt dan de partiële afgeleiden van deze kostfunctie om te bepalen in welke richting elke θ moet worden aangepast om de kostfunctie te minimaliseren

Je herhaalt deze stappen totdat je een minimum van de kostfunctie vindt

Je doet dit alles bij de gekende datapunten (waarden voor x en y). Je bent dus aan het "spelen" met de coëfficiënten θ om het model zo goed mogelijk te laten passen bij deze gekende punten

Dit alles kan door de PC worden uitgevoerd!

© 2023 *Olivier Claerbout*

Scikit-Learn

Scikit-Learn *is de populairste ML library voor Python:*

- *Een library die veel ML algoritmes bevat*
- *Maakt gebruik van een "estimator-api" framework. Dit betekent dat de manier waarop algoritmes worden geïmporteerd, gefit, en gebruikt, uniform is over de algoritmes heen.*

© 2023 *Olivier Claerbout*

Scikit-Learn

Het voordeel is dat gebruikers eenvoudig verschillende algoritmes kunnen testen

Het nadeel is dat gebruikers eenvoudig bijna elk algoritme kunnen toepassen en zelfs goede resultaten krijgen, zonder te weten waarom.

© 2023 *Olivier Claerbout*

Scikit-Learn

*Scikit-Learn bevat ook veel handige tools, zoals **train test split**, cross validation tools, … daardoor is Scikit-Learn bijna een one-stop-shop voor veel ML noden*

*De Scikit-Learn focus ligt op het **toepassen** van modellen en performance metrics – vooral op ongeziene data. Dit is pragmatischer dan de academische approach die eerder het model en zijn parameters beschrijft. Degenen die echt diep in de parameters willen duiken, kunnen statsmodels gebruiken.*

© 2023 *Olivier Claerbout*

Scikit-Learn

Train test split:

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(poly_features, y, test_size=0.3, random_state=101)
```

Algemene manier van werken voor supervised learning met Scikit-learn:

```
from sklearn.model_family import ModelAlgo
mymodel = ModelAlgo(param1, param2)
mymodel.fit(X_train, y_train)
predictions = mymodel.predict(X_test)

from sklearn.metrics import error_metric
performance = error_metric(y_test, predictions)
```

vb

```
from sklearn.linear_model import LinearRegression
model = LinearRegression()
model.fit(X_train,y_train)
test_predictions = model.predict(X_test)

from sklearn.metrics import mean_absolute_error,mean_squared_error
MAE = mean_absolute_error(y_test,test_predictions)
```


© 2023 *Olivier Claerbout*

Scikit-Learn

Demo: bepalen van de bloeddruk op basis van gewicht en leeftijd

Daarna: oefening "LR_sklearn_oefening_1.ipynb" ***tot deel evaluatie!***

© 2023 *Olivier Claerbout*

Scikit-Learn

We hebben nu een fitted model dat voorspellingen kan doen gebaseerd op features.

Hoe goed zijn deze? Hier komen de test labels in beeld want deze worden gebruikt als referentie.

© 2023 *Olivier Claerbout*

Evaluatie van regressiemodellen

Evaluatie van regressiemodellen in het algemeen – niet voor classificatiemodellen

Metrics zoals accuracy & recall werken voor classificatie, niet voor regressie – we hebben metrics nodig voor continue variabelen zoals:

- **Mean Absolute Error**
- **Mean Squared Error**
- **Root Mean Square Error**

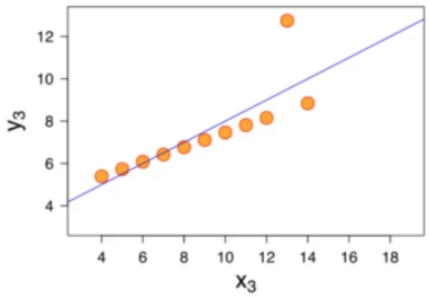
© 2023 *Olivier Claerbout*

Evaluatie van regressiemodellen

Mean Absolute Error:

Het gemiddelde van de absolute waarden van de errors.

$$\frac{1}{n}\sum_{i}^{n}|y_i - \hat{y}_i|$$



© 2023 *Olivier Claerbout*

Evaluatie van regressiemodellen

Mean Squared Error:

Gemiddelde van de gekwadrateerde fouten. Grotere fouten worden sterker "afgestraft" dan bij MAE, waardoor MSE populairder is.

$$\frac{1}{n}\sum_{i}^{n}(y_i - \hat{y}_i)^2$$

© 2023 *Olivier Claerbout*

Evaluatie van regressiemodellen

Root Mean Squared Error:

Wortel van het gemiddelde van de gekwadrateerde fouten.. Hier is de eenheid van de fout terug gelijk aan deze van y. Grotere fouten worden sterker “afgestraft” dan bij MAE. RMSE is één van de meest populaire evaluatiemethodes.

$$\sqrt{\frac{1}{n}\sum_{i}^{n}(y_i - \hat{y}_i)^2}$$

© 2023 *Olivier Claerbout*

Evaluatie van regressiemodellen

Wat is een goede waarde voor RMSE?

Context!

10€ is fantastisch wanneer je de prijs van een huis bepaalt, maar voor een reep snoep is dit rampzalig…

Vergelijk je error eens met het gemiddelde van het label in je dataset om een idee te krijgen van de performantie

Domeinkennis!

© 2023 *Olivier Claerbout*

Evaluatie van regressiemodellen

Bedenk: deze functies zijn allemaal “loss functions”: we willen deze minimaliseren!

Evalueer nu het eerder gebouwde model:

oefening “LR_sklearn_oefening_1.ipynb” ***vanaf deel evaluatie!***

© 2023 *Olivier Claerbout*