Regressie
Polynomiale regressie



© 2023 *Olivier Claerbout*

Lesmateriaal

- Via GitHub account:
  git clone https://github.com/oclaerbout/syntra_data_scientist.git
- © 2023 Olivier Claerbout

  Dit materiaal mag niet worden gekopieerd, verspreid, gepubliceerd of anderszins gereproduceerd zonder uitdrukkelijke schriftelijke toestemming van de auteur. Dit geldt eveneens voor de Jupyter Notebooks!

© 2023 *Olivier Claerbout*

Lineaire regressie

Aanpak:

- Theorie
- Eenvoudige implementatie met Python
- Lineaire regressie met Scikit-learn: ML library
- **Polynomiale regressie**
- Regularisatie

© 2023 *Olivier Claerbout*

Polynomiale regressie

Hoe kunnen we het voorgaande LR model verbeteren?

Bedenken van nieuwe features

Voorbeelden:

- Uit de lengte en breedte van een huis de oppervlakte halen als nieuwe feature.
- Uit een start en eindpunt de afstand halen als nieuwe feature.
- Uit een datum afleiden welke dag van de week het is.
- Veranderingen in de features.
- Nieuwe opgemeten parameters.
- ***Hogere orde relaties van bestaande features***

Feature expansion

© 2023 *Olivier Claerbout*

Polynomiale regressie

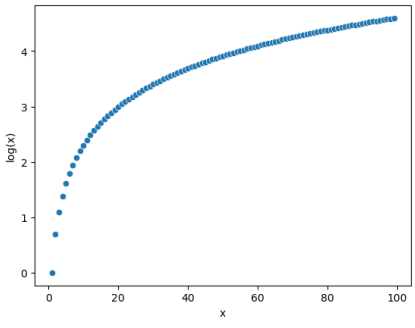
Polynomiale regressie helpt ons bij:

- Niet-lineaire relatie tussen feature en label
- Interactie tussen de features

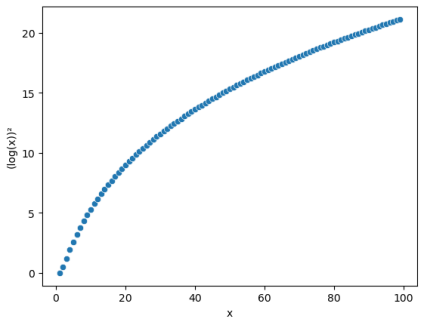
© 2023 *Olivier Claerbout*

Hogere orde relaties

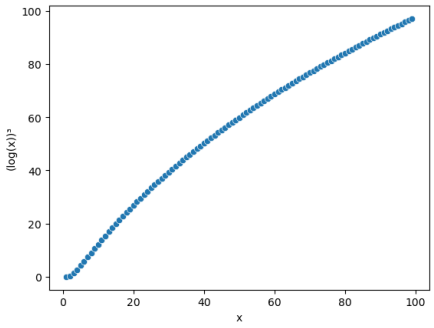
Wat als we een niet-lineaire feature hebben die zich gedraagt als log(x)?



x



x^2



x^3

© 2023 *Olivier Claerbout*

Interactie tussen features

Wat als we een feature hebben die beïnvloed wordt door een andere?

Voorbeeld:

- Krantenadvertenties op zich blijken niet efficiënt, maar versterken het effect van een TV campagne
- Hoe kunnen we dit controleren?

© 2023 *Olivier Claerbout*

Interactie tussen features

- De eenvoudigste manier is om bestaande features te vermenigvuldigen om de interactieterm te maken
- De originele features worden behouden

Scikit-Learn doet dit voor ons via preprocessing

© 2023 *Olivier Claerbout*

Interactie tussen features

- Scikit-Learn's preprocessing library bevat veel tools om op de dataset te gebruiken **voor** het model wordt getraind
- Eén tool is PolynomialFeatures. Deze maakt automatisch hogere orde features en interactietermen tussen alle feature combinaties

© 2023 *Olivier Claerbout*

Interactie tussen features

- PolynomialFeatures maakt volgende termen:
  - Een bias (waarde = 1,0)
  - De waarden tot een macht (vb x, x^2, x^3, …) tot de gekozen exponent
  - Interacties tussen alle feature paren (x1 * x2, x1 * x3,…)
  - Voorbeeld voor 2 features A en B, met gekozen orde 2:
    - 1, A, B, A^2, AB, B^2
  - Algemeen voor feature termen x_1 en x_2:
    - 1, x_1, x_2, x_1^2, x_1x_2, x_2^2
  - Stel voor een rij met waarden $x_1 = 2$ en $x_2 = 3$:
    - 1, 2, 3, 4, 6, 9 → je hebt veel meer features uit je originele dataset: van 2 naar 6.

© 2023 *Olivier Claerbout*

Interactie tussen features

- Polynomiale regressie met Scikit-Learn
- Zie notebook polynomial regression.ipynb

© 2023 *Olivier Claerbout*

Underfitting en overfitting

© 2023 *Olivier Claerbout*

Bias-Variance Trade Off

- Polynomial model presteert beter dan standaard linear regression model
- Hoe bepalen we de optimale graad van de polynoom?
- Waarmee moeten we rekening houden als we de complexiteit van het model verhogen?

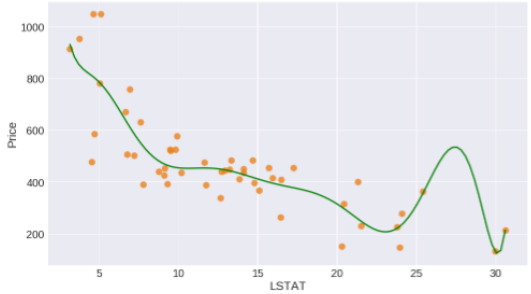
© 2023 *Olivier Claerbout*

Underfitting en overfitting

Overfitting

Overfitting treedt op wanneer een model de training data te goed modelleert en niet kan generaliseren op nieuwe data.

- Het model is te ‘complex’.
- De ruis van willekeurige fluctuaties in de data wordt opgepikt.
- Model met een hoge variantie.



© 2023 *Olivier Claerbout*

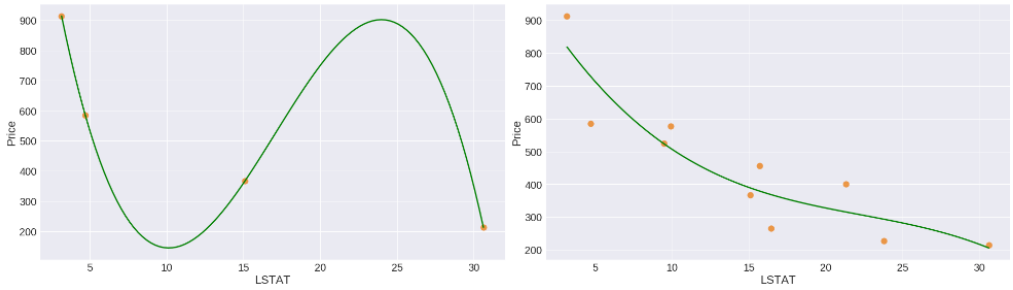
Underfitting en overfitting

Overfitting

Afhankelijk van grootte van de trainingset (aantal observaties m).

- Bij weinig observaties: snel overfitting bij complexer model.
- Bij veel observaties: minder snel overfitting bij complexer model.

Voorbeeld: Derde orde polynoom

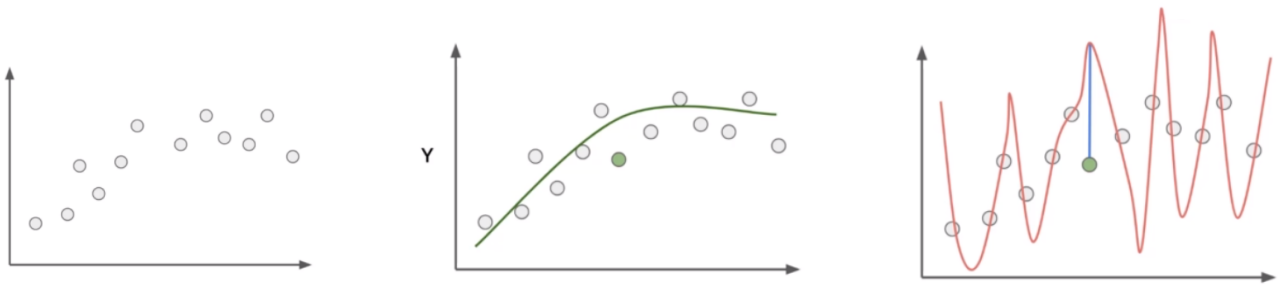


© 2023 *Olivier Claerbout*

Underfitting en overfitting

Overfitting

RMSE op test data??



Dataset

Goed model

Overfitting

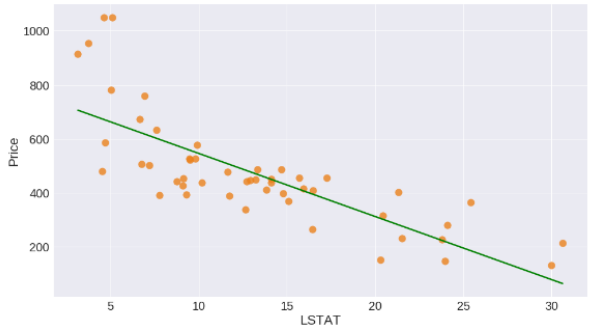
© 2023 *Olivier Claerbout*

Underfitting en overfitting

Underfitting

Underfitting treedt op wanneer een model de training data niet kan modelleren en ook niet kan generaliseren op nieuwe data.

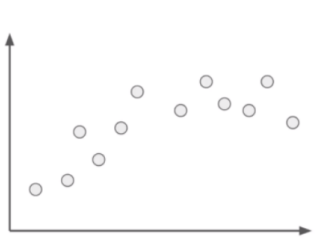
- Het model is te ‘simpel’.
- Model met hoge bias en lage variantie.



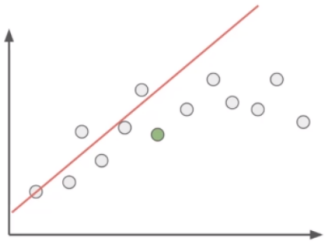
© 2023 *Olivier Claerbout*

Underfitting en overfitting

Overfitting



Dataset

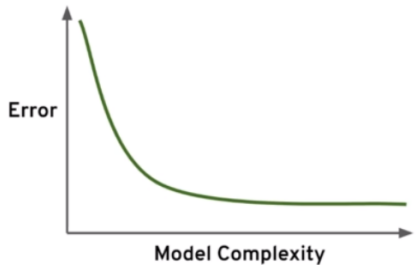


Underfitting

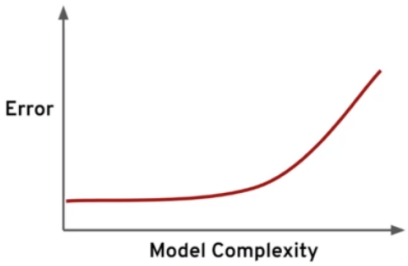
© 2023 *Olivier Claerbout*

Underfitting en overfitting

- Hoe opmerken bij multidimensionale datasets?
  - Error vs complexiteit plotten (vb voor hogere orde polynoom)



Goed model

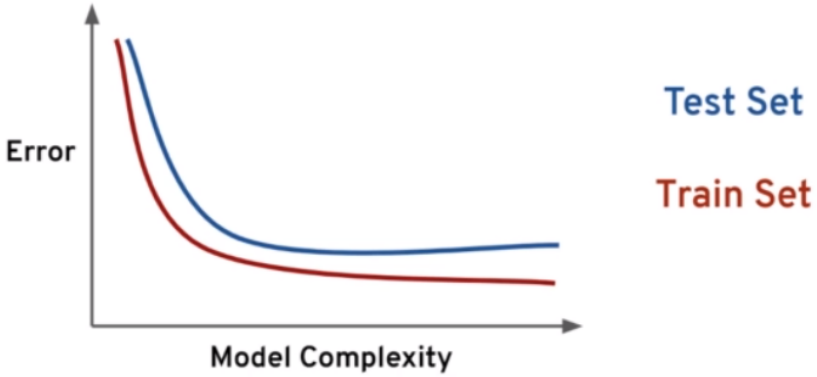


Slecht model

© 2023 *Olivier Claerbout*

Underfitting en overfitting

- Performantie:



© 2023 *Olivier Claerbout*

Underfitting en overfitting

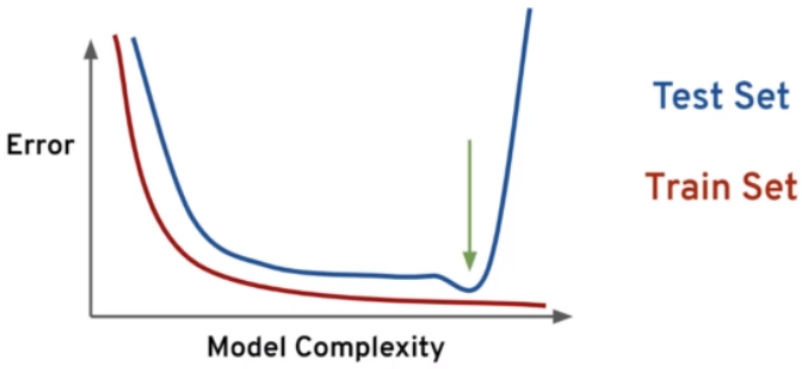
- Keuze van de optimale complexiteit van het model (=graad van de polynoom)
- Error op training en test data cruciaal om overfitting te voorkomen

Zie notebook!

© 2023 *Olivier Claerbout*

Underfitting en overfitting

- Overfitting:



© 2023 *Olivier Claerbout*

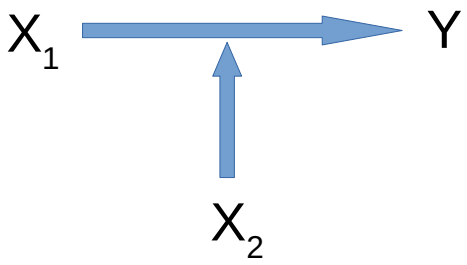
EXTRA:

Interpretatie van hogere orde- en interactiecoëfficiënten

© 2023 *Olivier Claerbout*

Interactie als statistisch concept

- Interactie: voor situaties waarbij de impact van een onafhankelijke variabele op een afhankelijke variabele beïnvloed wordt door een derde variabele.
- Formeel: het effect van X_1 op Y varieert naargelang de waarden van X_2



X_1: onafhankelijke focusvariabele
X_2: moderatorvariabele
Y: afhankelijke variabele

© 2023 *Olivier Claerbout*

Interactie-effecten: wanneer nuttig?

- Een model zonder interactie-effecten maakt impliciet de veronderstelling dat het effect van de onafhankelijke focusvariabele op de afhankelijke variabele constant is. Vaak is die veronderstelling niet realistisch!
- Als er redenen zijn om aan te nemen dat de aard van een effect samenhangt met een derde variabele, is een model met interactie-effecten aangewezen.

© 2023 *Olivier Claerbout*

Interactie-effecten: voorbeeld

- **Het eerste voorbeeld kijkt naar het aantal uren dat de respondenten vrij hebben op een dag in de week- of een werkdag. De vraag die in een survey gesteld werd aan 18- tot 85-jarige respondenten, luidde:**
- Wanneer u de voorbije maand bekijkt, hoeveel uren had u dan gewoonlijk vrij tijdens een weekdag of een werkdag? Tijd die gebruikt wordt voor betaald werk, verzorging van de kinderen of andere huisgenoten, het vervullen van taken waartoe men zich verplicht voelt en essentiële behoeften zoals eten, persoonlijke verzorging en slapen, tellen niet mee als vrije tijd.

© 2023 *Olivier Claerbout*

Interactie-effecten: voorbeeld

- Uit tabel 1 blijkt dat het gemiddelde aantal gerapporteerde uren vrije tijd iets meer dan 3,7 bedraagt (bijna 3 uur en drie kwartier). Maar er zijn natuurlijk grote verschillen. Sommige respondenten zeggen helemaal geen vrije tijd te hebben op een weekdag terwijl andere respondenten zeggen over maar liefst 16 vrije uren te beschikken .

Tabel 1 Aantal uren vrije tijd op een dag in de week

	N	Minimum	Maximum	Gemiddelde	Standaard-afwijking
vrij_weekdag	1460	0	16	3,71	2,82

© 2023 *Olivier Claerbout*

Interactie-effecten: voorbeeld

- De hoeveelheid vrije tijd verschilt volgens onder andere:
  - Geslacht
  - Betaald werk

	Gemiddelde	Standaardafwijking	N
Geslacht			
vrouw	3,36	2,60	751
man	4,08	3,00	709
Betaald werk			
nee	5,08	3,24	652
ja	2,60	1,79	808

© 2023 *Olivier Claerbout*

Interactie-effecten: voorbeeld

- Meer in detail:

Aantal uren vrije tijd op een dag in de week volgens de gecombineerde verdeling van geslacht en het al dan niet hebben van betaald werk

Geslacht	Betaald werk	Gemiddelde	Standaard-afwijking	N
vrouw	nee	4,32	2,88	396
	ja	2,28	1,68	355
man	nee	6,25	3,42	256
	ja	2,85	1,82	453

© 2023 *Olivier Claerbout*

Theoretische Interpretatie van een interactieterm

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2$$

θ_1 en θ_2 worden de hoofdeffecten genoemd en θ_3 het interactie-effect. Opgepast: de benaming hoofdeffect is enigszins misleidend omdat het over een conditioneel of specifiek effect gaat!

Interpretatie:

$\boldsymbol{\theta_0}$ is het intercept met ongewijzigde interpretatie: de voorspelde waarde voor de afhankelijke variabele als alle onafhankelijke variabelen gelijk zijn aan 0.

Voorspelde wijziging van y bij één eenheid wijziging in x_1: $\theta_1 + \theta_3 x_2$

Voorspelde wijziging van y bij één eenheid wijziging in x_2: $\theta_2 + \theta_3 x_1$

© 2023 *Olivier Claerbout*

Theoretische Interpretatie van een interactieterm

$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2$

Voorspelde wijziging van y bij één eenheid wijziging in x_1: $\theta_1 + \theta_3 x_2$
Voorspelde wijziging van y bij één eenheid wijziging in x_2: $\theta_2 + \theta_3 x_1$

Hieruit blijkt:
θ_1 is nog altijd het effect is van x_1 op y, maar enkel indien x_2 gelijk is aan 0!
Het is dus een **conditioneel effect** geworden.
Het effect van x_1 op y bij andere waarden van x_2 kan worden berekend met de vergelijking.

θ_2 is het effect van x_2 op y als x_1 gelijk is aan 0.

Het effect van x_1 op y is afhankelijk van x_2 en omgekeerd, in overeenstemming met de definitie van een interactie-effect!

© 2023 Olivier Claerbout

Theoretische Interpretatie van een interactieterm

$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2$

Wat met θ_3 ?

θ_3 vertelt ons hoeveel het effect van x_1 op y verandert wanneer x_2 met één eenheid toeneemt (ook geldig voor x_2)

Eenvoudig uitgedrukt: *θ_3 geeft ons inzicht in het effect van het gecombineerde effect van x_1 en x_2 op y*

© 2023 Olivier Claerbout

Interpretatie: voorbeeld

$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2$

Stel bij vorig voorbeeld, na regressie zonder interacties:

$\hat{y}$ = *1,36 + 0,06 leeftijd – 0,59 aantal kinderen ten laste*

→ *vrije tijd op een weekdag voor nuljarigen zonder kinderen = 1,36.*

Krijgt iemand die 10 jaar ouder wordt 0,6u meer vrije tijd?

© 2023 Olivier Claerbout

Interpretatie: voorbeeld

$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2$

Stel bij vorig voorbeeld, na regressie zonder interacties:

$\hat{y}$ = *1,36 + 0,06 leeftijd – 0,59 aantal kinderen ten laste*

→ *vrije tijd op een weekdag voor* ***nuljarigen zonder kinderen*** *= 1,36.*

	N	Minimum	Maximum	Gemiddelde	Standaard-afwijking
leeftijd	1460	18	85	47,84	17,47
dev_leeftijd	1460	-30	37	-0,16	17,47

$\hat{y}$ = *4,09 + 0,06 dev_leeftijd – 0,59 aantal kinderen ten laste*

© 2023 Olivier Claerbout

Interpretatie: voorbeeld

Toevoegen categorische onafhankelijke variabelen

$\hat{y}$ = 5,048 + 0,04 dev_leeftijd – 0,38 aantal kinderen ten laste – 1,03 vrouw – 1,79 betaald werk

© 2023 Olivier Claerbout

Interpretatie: voorbeeld

Toevoegen categorische onafhankelijke variabelen

$\hat{y}$ = 5,048 + 0,04 dev_leeftijd – 0,38 aantal kinderen ten laste – 1,03 vrouw – 1,79 betaald werk

Regressiecoëfficiënt vrouw = -1,03 → *wat betekent dit?*

Voor wie geldt nu de intercept?

© 2023 Olivier Claerbout

Interpretatie: voorbeeld

Meervoudige regressie met interactie-effecten: ***vrouw * betaald werk***

$\hat{y}$ = *5,91 + 0,04 dev_leeftijd – 0,37 aantal kinderen ten laste – 1,74 vrouw – 2,48 betaald werk + 1,26 vrouw * betaald werk*

Intercept: nog steeds # uren vrij voor 48-jarige mannen zonder betaald werk & kinderen

Effecten leeftijd en kinderen ten laste: zelfde interpretatie als voorheen

Wat met ***geslacht*** *en* ***betaald werk****?*

© 2023 *Olivier Claerbout*

Interpretatie: voorbeeld

Meervoudige regressie met interactie-effecten: ***vrouw * betaald werk***

$\hat{y}$ = *5,91 + 0,04 dev_leeftijd – 0,37 aantal kinderen ten laste – 1,74 vrouw – 2,48 betaald werk + 1,26 vrouw * betaald werk*

Intercept: nog steeds # uren vrij voor 48-jarige mannen zonder betaald werk & kinderen

Effecten leeftijd en kinderen ten laste: zelfde interpretatie als voorheen

Wat met ***geslacht*** *en* ***betaald werk****?*

© 2023 *Olivier Claerbout*

Interpretatie: voorbeeld

*ŷ = 5,91 + 0,04 dev_leeftijd – 0,37 aantal kinderen ten laste – 1,74 vrouw – 2,48 betaald werk + 1,26 vrouw * betaald werk*

*Wat met **geslacht** en **betaald werk**?*

Effect vrouw is veel groter geworden. Zie eerder: hoofdeffect is een conditioneel effect geworden (andere dummy in het interactie-effect op nul) en dus slechts voor één groep geldig: mensen zonder betaald werk.

Hoofdeffect geslacht → betaald werk op nul.

Hoofdeffect geslacht: bij de mensen zonder betaald werk voorspellen we 1u en 45min minder vrije tijd voor vrouwen dan voor mannen (onder controle van de effecten van leeftijd en kinderen ten laste).

Voor wie geldt het hoofdeffect van betaald werk? Wat is het effect?

© 2023 Olivier Claerbout

Interpretatie: voorbeeld

*ŷ = 5,91 + 0,04 dev_leeftijd – 0,37 aantal kinderen ten laste – 1,74 vrouw – 2,48 betaald werk + 1,26 vrouw * betaald werk*

Voor wie geldt het hoofdeffect van betaald werk? Wat is het effect?

Wat is het effect van geslacht bij mensen met betaald werk?

Wat is het effect van betaald werk bij vrouwen?

© 2023 Olivier Claerbout

EXTRA:

Significantie van coëfficiënten

© 2023 *Olivier Claerbout*

Significantietesten

Niet ingebouwd in Sklearn → statsmodels gebruiken

```
import statsmodels.api as sm
```

```
X_poly_sm = sm.add_constant(X_converted) # Voeg constante (intercept) toe want in sklearn gebeurt dit automatisch!
                                         # ook via include_bias=True bij aanmaak polyfeatures mogelijk...
model_statsmodels = sm.OLS(y, X_poly_sm).fit()
```

```
print(model_statsmodels.summary())
```


© 2023 *Olivier Claerbout*

Significantietesten

In de praktijk: deel de coëfficiënt door zijn geschatte standaardfout.

Als het bekomen resultaat groter is dan 2 of kleiner dan -2, is het besluit dat het effect significant is.

Alternatief: kijk naar de bijhorende p-value. Als de p-waarde kleiner is dan je significantieniveau (bijv. 0.05), dan is de coëfficiënt significant.

OLS Regression Results

Dep. Variable:	sales	R-squared:	0.992
Model:	OLS	Adj. R-squared:	0.991
Method:	Least Squares	F-statistic:	1186.
Date:	Mon, 25 Sep 2023	Prob (F-statistic):	4.00e-178
Time:	13:22:52	Log-Likelihood:	-129.91
No. Observations:	200	AIC:	299.8
Df Residuals:	180	BIC:	365.8
Df Model:	19		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	3.9436	0.341	11.577	0.000	3.271	4.616
x1	0.0897	0.005	17.774	0.000	0.080	0.100
x2	0.0387	0.028	1.373	0.171	-0.017	0.094
x3	0.0140	0.016	0.880	0.380	-0.017	0.045
x4	-0.0004	3.35e-05	-13.134	0.000	-0.001	-0.000
x5	0.0014	0.000	8.515	0.000	0.001	0.002
x6	-0.0002	0.000	-2.070	0.040	-0.000	-9.9e-06
x7	-0.0006	0.001	-0.514	0.608	-0.003	0.002
x8	-0.0003	0.001	-0.447	0.655	-0.002	0.001
x9	0.0002	0.000	0.654	0.514	-0.000	0.001
x10	7.628e-07	7.31e-08	10.437	0.000	6.19e-07	9.07e-07
x11	-1.216e-06	4.36e-07	-2.790	0.006	-2.08e-06	-3.56e-07
x12	7.245e-07	2.89e-07	2.511	0.013	1.55e-07	1.29e-06
x13	1.799e-06	2.45e-06	0.734	0.464	-3.04e-06	6.63e-06
x14	-1.51e-06	1.93e-06	-0.781	0.436	-5.33e-06	2.31e-06
x15	-1.148e-07	7.3e-07	-0.157	0.875	-1.56e-06	1.33e-06
x16	3.327e-06	1.62e-05	0.206	0.837	-2.86e-05	3.52e-05
x17	4.939e-06	1.08e-05	0.458	0.648	-1.63e-05	2.62e-05
x18	2.673e-06	5.7e-06	0.469	0.639	-8.57e-06	1.39e-05
x19	-2.305e-06	1.97e-06	-1.168	0.245	-6.2e-06	1.59e-06

Omnibus:	116.550	Durbin-Watson:	2.108
Prob(Omnibus):	0.000	Jarque-Bera (JB):	1660.512
Skew:	-1.860	Prob(JB):	0.00
Kurtosis:	16.617	Cond. No.	9.54e+07

© 2023

Lineaire Regressie

ENKELE TIPS

© 2023 *Olivier Claerbout*

Categorische variabelen

Ook categorische variabelen kunnen worden gebruikt voor regressie.

Vb voor geslacht:

Man: 0 of 1
Vrouw: 0 of 1

Bij meer dan 2 levels: meerdere dummy variabelen.

Vb RGB kleuren:

Rood:	1 0 0
Groen:	0 1 0
Blauw:	0 0 1

© 2023 *Olivier Claerbout*

Dummy Variable Trap

Opgepast: correlatie tussen dummy variabelen!

Behouden van alle ‘n’ dummy variabelen leidt tot multicollineariteit
We hebben een feature ‘op overschot’ die geen extra informatie brengt

Hoe detecteren?

- Variance Inflation Factor (VIF)
- Correlatiematrix

Hoe vermijden?

- Laat een dummy variabele vallen: “n1 encoding”
- Gebruik regularisatie (zie verder)

© 2023 *Olivier Claerbout*

VIF

Variance Inflation Factor (VIF):

Een maatstaf voor de hoeveelheid collineariteit in regressie analyse.

$$VIF_i = \frac{1}{1 - R_i^2}$$

Met $R_i^2 =$ de determinatiecoëccifiënt bij regressie voor de i^{de} onafhankelijke variabele uit de overgebleven onafhankelijke variabelen

VIF = 1: variabelen zijn niet gecorreleerd
1 < VIF < 5: zekere correlatie aanwezig (tot 3: min of meer ok)
VIF > 5: hoge mate van correlatie: minder betrouwbaar model!

© 2023 *Olivier Claerbout*

Residual plots

Residuals (delta tussen echte labels en voorspellingen) mogen geen patroon vertonen maar moeten random en niet gecorreleerd zijn.

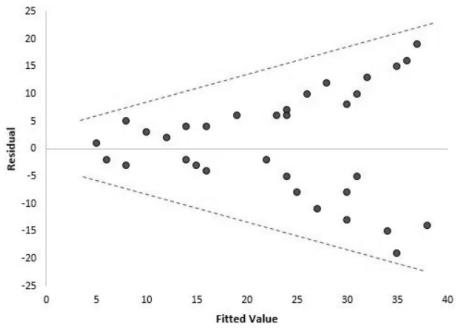
<u>Indien wel aanwezig:</u>

- Toevoegen ontbrekende features (vb weekdag)
- Gebruik specifiek model zoals time-series

<u>Niet constante variantie van residuals:</u>

Te herkennen aan trechtervorm in residual plot

Probeer y te transformeren: $\log(y)$ of $\sqrt{y}$



© 2023 *Olivier Claerbout*

Uitschieters

Deze kunnen problemen veroorzaken zoals een hoge RSE (residual standard error) en lagere R^2

Gebruik residual plots kunnen worden gebruikt om uitschieters te identificeren

© 2023 *Olivier Claerbout*