Regressie
Resampling, Regularisatie & Model Selection



© 2023 Olivier Claerbout

Lesmateriaal

- Via GitHub account:
  git clone https://github.com/oclaerbout/syntra_data_scientist.git

© 2023 Olivier Claerbout

Regularisatie - intro

© 2023 Olivier Claerbout

Regularisatie

- Om volgende issues op te lossen:
  - Reduceren complexiteit van het model (zoeken “optimale complexiteit”)
  - Penalisatie van de verliesfunctie middels een extra kostenterm
  - Reduceren overfitting van het model (meer bias, minder variance)
    - Zoektocht naar optimale “penalty hyperparameter”

Methode om de mate van bias van een te regelen en een goed evenwicht te vinden tussen underfitting en overfitting.

© 2023 Olivier Claerbout

Underfitting en overfitting

Regularisatie (regularization)

De tuningparameter λ regelt de complexiteit

- Kleine waarde voor λ: lage bias, hoge variantie (overfitting).
- Grote waarde voor λ: hoge bias, lage variantie (underfitting).

Afhankelijk van hoe de kostenterm gedefiniëerd wordt is er andere benaming voor de regularisatie:

- Ridge regression (L2 regularisatie)
- Lasso regression (L1 regularisatie)
- Elastic Net: combinatie van L1 en L2 regularisatie

© 2023 Olivier Claerbout

Regularisatie

- L1 regularisatie voegt een kostenterm toe evenredig met de absolute waarde van de magnitude van de coëfficiënten
  - Dit limiteert de grootte van de coëfficiënten
  - Kan een “sparse model” voortbrengen met *coëfficiënten gelijk aan nul*

© 2023 Olivier Claerbout

Regularisatie

- L1 regularisatie voegt een kostenterm toe evenredig met de absolute waarde van de magnitude van de coëfficiënten

$$\sum_{i=1}^{n}\left(y_i-\theta_0-\sum_{j=1}^{p}\theta_j x_{ij}\right)^2+\lambda\sum_{j=1}^{p}|\theta_j|=RSS+\lambda\sum_{j=1}^{p}|\theta_j|$$

De regularisatie-term is een extra kostenterm die het gebruik van hogere orde features afstraft tenzij ze de globale kostenfunctie doen dalen.

© 2023 Olivier Claerbout

Regularisatie

- L2 regularisatie voegt een kostenterm toe evenredig met het kwadraat van de magnitude van de coëfficiënten
  - Alle coëfficiënten worden met dezelfde factor verkleind
  - Coëfficiënten worden niet noodzakelijk geëlimineerd

$$\sum_{i=1}^{n}\left(y_i-\theta_0-\sum_{j=1}^{p}\theta_j x_{ij}\right)^2+\lambda\sum_{j=1}^{p}\theta_j^2=RSS+\lambda\sum_{j=1}^{p}\theta_j^2$$

© 2023 Olivier Claerbout

Regularisatie

- Elastic net combineert L1 en L2 met de toevoeging van een alpha parameter die de ratio tussen beide regelt:

$$\frac{\sum_{i=1}^{n}(y_i - x_i^J \hat{\theta})^2}{2n} + \lambda\left(\frac{1-\alpha}{2}\sum_{j=1}^{m}\hat{\theta}_j^2 + \alpha\sum_{j=1}^{m}|\hat{\theta}_j|\right)$$

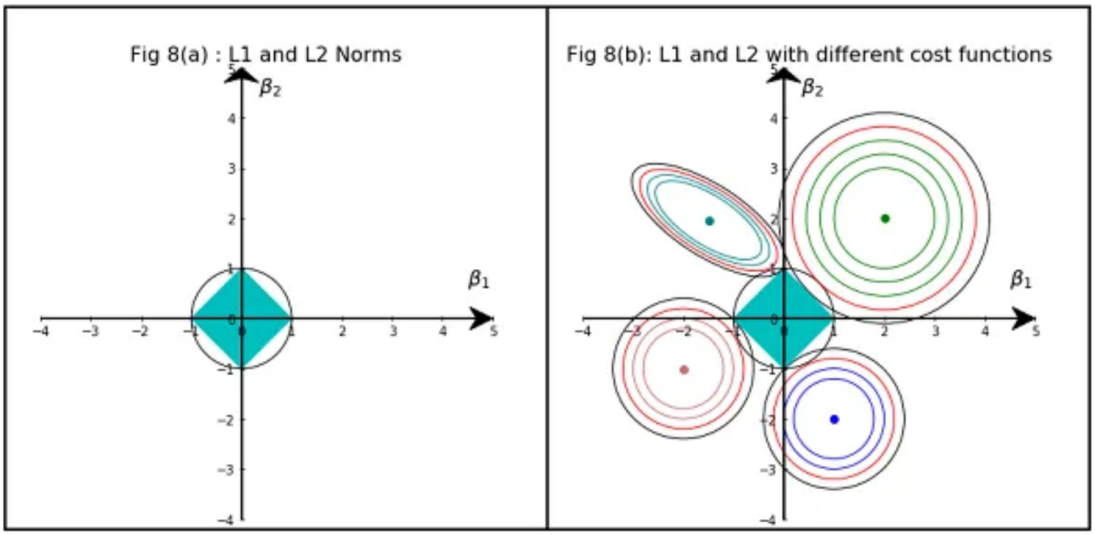
© 2023 Olivier Claerbout

Regularisatie

- Kost van regularisatie:
  - Extra hyperparameter die moet getuned worden, ahw een term waarmee de penalty wordt vermenigvuldigd om de sterkte van de penalty te bepalen.

© 2023 Olivier Claerbout

Regularisatie



© 2023 Olivier Claerbout

Feature scaling

© 2023 Olivier Claerbout

Feature Scaling

Doel van feature scaling

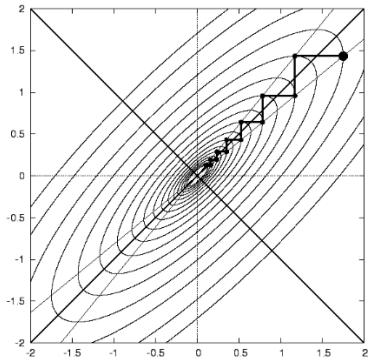
- Biedt veel voordelen voor het ML proces!
- Sommige ML modellen vereisen geschaalde features om goed te werken

zorgt ervoor dat de features op **dezelfde schaalverdeling** staan.

© 2023 Olivier Claerbout

Feature Scaling

- Verbetert de convergentie van gradient descent algoritmes
- Als de features op verschillende schalen zijn, zullen sommige weights sneller updaten dan andere aangezien de x_j feature waarden een rol spelen in de weight updates



© 2023 Olivier Claerbout

Feature Scaling

- Vermijdt Dominantie van Features
- Verbeterde Prestaties van Algoritmen
- Evenwichtige regularisatie
- Vereenvoudigt Visualisatie

© 2023 Olivier Claerbout

Feature Scaling

OPPASSEN:

- Nieuwe, ongeziene data ook schalen
- Beïnvloedt interpreteerbaarheid van coëfficiënten:
  - Eenvoudiger om coëfficiënten met elkaar te vergelijken, maar moeilijker om terug te koppelen naar originele, ongeschaalde features!

© 2023 Olivier Claerbout

Feature Scaling

Belangrijkste manieren

- Standaardisatie
  - Herschaalt data om een gemiddelde (μ) van 0 en een standaardafwijking (σ) van 1
- Normalisatie
  - Herschaalt alle waarden tussen 0 en 1

Opgepast; standaardisatie wordt ook wel Z-score normalisatie genoemd...

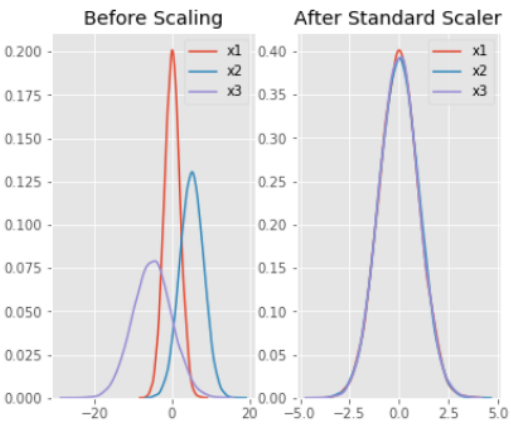
© 2023 Olivier Claerbout

Standaardisatie

Standard scaling

$$x_{s_i} = \frac{x_i - mean(x)}{stdev(x)}$$

- Geschaalde features: gemiddelde = 0 en standaardafwijking = 1.
- Geschaalde features schommelen rond 0 (soms nodig bij deep learning).
- Vervormt geen relatieve afstanden tussen de feature waarden.
- Kan beter overweg met uitschieters.
- Garandeert geen genormaliseerde data op exact dezelfde schaal.



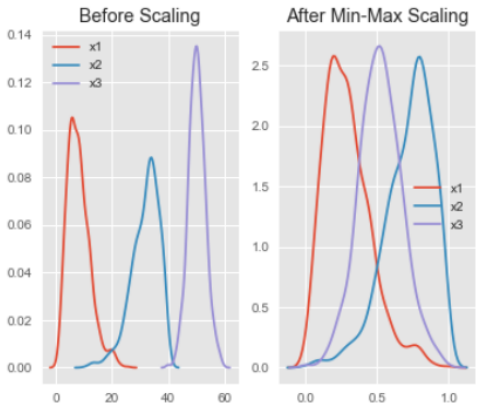
© 2023 Olivier Claerbout

Normalisatie

MIN – MAX scaling

$$x_{s_i} = \frac{x_i - Min(x)}{Max(x) - Min(x)}$$

- Schaalt alle features tussen 0 en 1.
- Werkt goed bij niet Gaussiaanse distributies en bij kleine variantie.
- De scheefheid (skew) blijft bewaard.
- Gevoelig voor uitschieters.



© 2023 Olivier Claerbout

Feature Scaling

Andere manieren...

- Er zijn nog verschillende methodes om features te scalen
- Scikit-Learn biedt hiertoe classes met “fit” en “transform”, eenvoudig te gebruiken op feature data
- Wat doen **fit** & **transform** hier?

© 2023 Olivier Claerbout

Feature Scaling

Andere manieren...

- Er zijn nog verschillende methodes om features te scalen
- Scikit-Learn biedt hiertoe classes met “fit” en “transform”, eenvoudig te gebruiken op feature data
- Wat doen **fit** & **transform** hier?

© 2023 Olivier Claerbout

Feature Scaling

.fit() & .transform()

- .fit() berekent de noodzakelijke statistieken (X_{min}, X_{max}, gem, std dev)
- .transform() schaalt de data en retourneert een geschaalde versie van de data
- Zie bij polynomial features!

© 2023 Olivier Claerbout

Feature Scaling

Werkwijze

- Doe een train test split
- Fit op de training feature data
- Transform op training feature data
- Transform op test feature data

© 2023 Olivier Claerbout

Resampling - Cross Validation

© 2023 Olivier Claerbout

Resampling

Wat?

- Een manier om een bestaande dataset opnieuw te ordenen

Waarom?

- De robuustheid van een model evalueren
- Overfitting voorkomen

© 2023 Olivier Claerbout

Resampling

Voorbeelden?

- K-fold Cross-Validation
- Leave-One-Out Cross-Validation (LOOCV)
- *Bootstrapping **
- *Leave-p-out Cross-Validation **
- *Random Permutation **

** zien we hier niet*

© 2023 Olivier Claerbout

Cross Validation

Wat?

- Een geavanceerde manier om data in een training en test set op te splitsen
- Zie sectie 5.1 van ISLP

© 2023 Olivier Claerbout

Cross Validation

Wat?

- Train Test Split: eerlijk evalueren van de performantie van het model op ongeziene data
- Hierdoor kunnen we de hyperparameters niet op de volledige dataset tunen!

© 2023 Olivier Claerbout

Cross Validation

Kunnen we:

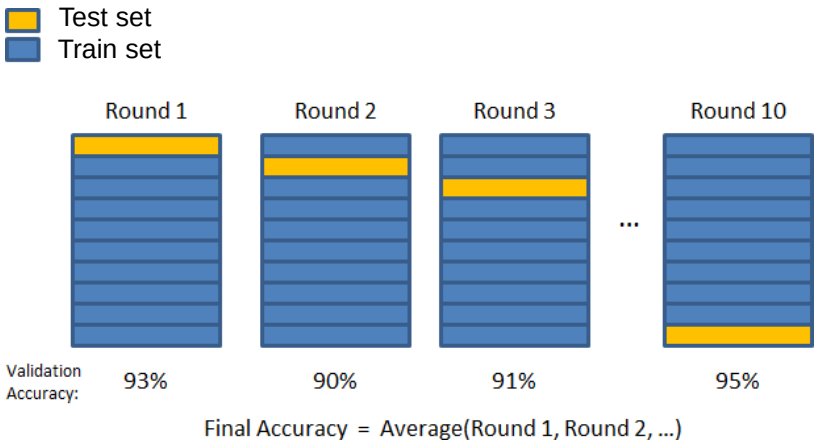
- Trainen op ALLE data
- Evalueren op ALLE data
  → Cross Validation!

© 2023 Olivier Claerbout

Cross Validation

K-fold cross-validation

- Zoeken naar optimale hyperparameters
- Voorbeeld: 10-fold cross-validation



© 2023 Olivier Claerbout

Cross Validation

- We hebben getraind op ALLE data
- We hebben geëvalueerd op ALLE data
- We hebben een beter idee van de echte performantie over de verschillende splits heen

Tegen welke kost?
We moeten alles K keer opnieuw berekenen!

© 2023 Olivier Claerbout

Cross Validation

- K-fold cross-validation
- K is vaak 10 dus elke test set is 10% van de data
- Grootste K is aantal rijen
  - Gekend als leave one out cross validation
  - Zeer veel rekenkracht nodig!

© 2023 Olivier Claerbout

Cross Validation

Te overwegen:

- Ga uit van een standaard train test split en K-fold cross validation
- Als we hyperparameters tunen op basis van de performantie op test data, krijgen we dan eerlijke performance metrics?
- Zijn onze hyperparameters op een faire wijze getuned?
- Krijgen we eerlijke prestatiestatistieken op basis van gegevens die nog nooit zijn gezien en op basis waarvan nooit werd bijgestuurd?

© 2023 Olivier Claerbout

Cross Validation

- Hoe komen we te weten hoe het model zich gedraagt voor data die het nooit heeft gezien, en waardoor het nooit werd beïnvloed tijdens hyperparameter tuning?
- **Hold out test set!**

Train Validation Test split!

© 2023 Olivier Claerbout

Cross Validation

- Verschillende werkwijzen zijn ok
- Houd rekening met:
  - Voorgaand werk om mee te vergelijken
  - Vereisten inzake rapportering
  - Faire evaluatie

© 2023 Olivier Claerbout

Cross Validation

- Veel regularisatietechnieken hebben parameters die getuned kunnen worden mbv cross-validatie

© 2023 Olivier Claerbout

Cross Validation vs train-test split

- Beide technieken dienen om de performantie van het model te evalueren
- Wat is bijvoorbeeld het verschil bij 80/20 train test split of Cross Validation met 20% holdout set?

© 2023 Olivier Claerbout

Cross Validation vs train-test split

- Train test split met 20% test set
  - Train op 80%, evalueer op 20%
  - Voordelen:
    - Snel en eenvoudig
    - Goed voor grote datasets waar CV teveel rekenkracht zou vragen
  - Nadelen:
    - In functie van de uitgevoerde split kan de evaluatie hoge variantie hebben

© 2023 Olivier Claerbout

Cross Validation vs train-test split

- CV met 20% holdout set
  - K-fold cross validation op 80%, evalueer op 20%
  - Voordelen:
    - Meer robuuste schatting van de performantie op ongeziene data omdat het model is geëvalueerd op meerdere subsets tijdens CV
  - Nadelen:
    - Meer rekenkracht nodig
    - Traint ook maar op 80% van de data

© 2023 Olivier Claerbout

Cross Validation vs train-test split

- Het is niet per definitie zo dat CV een betere performantie geeft, maar CV geeft meestal een meer consistente en betrouwbare schatting van de performantie
- De holdout set bij CV levert (net als bij train test split) een onafhankelijke meting van de finale performantie op ongeziene data.
- CV kan tijdens het trainen hyperparameter tuning doen
- Bij sommige datasets met een smalle of afwijkende distributie kan een eenvoudige train test split hoge variantie vertonen. CV zal betrouwbaarder zijn.

© 2023 Olivier Claerbout

Cross Validation vs train-test split

- De keuze tussen CV en train test split hangt af van de grootte van de dataset, de beschikbare resources voor training, en de specifieke doelen van de evaluatie.

© 2023 Olivier Claerbout

Bias-Variance trade-off for k-fold Cross-Validation

© 2023 Olivier Claerbout

Bias-variance trade-off for k-fold CV

- In de context van model evaluation refereert bias naar de **systematische error** die wordt geïntroduceerd **in de schatting van de testfout door de evaluatie procedure** (k-fold CV in dit geval), niet over de bias van het model zelf!
- We hebben het dus over de afwijking tussen de via CV geschatte testfout en de werkelijke testfout
- **De testfout is hier de Cross-Validation Testfout (of Validatiefout)**
- Deze fout is het verschil tussen de voorspelde waarden van het model en de werkelijke waarden (testset) **voor een bepaalde fold**
- Het gemiddelde van al deze fouten is een voorspelling voor de algemene fout

© 2023 *Olivier Claerbout*

Bias-variance trade-off for k-fold CV

- K-fold CV met k = 2 zal de dataset in 2 splitsen, en 2 keer een fout berekenen. Het gemiddelde van deze fouten vormt de schatting van de testfout.
- Aangezien hier een groot deel van de data wordt weggelaten bij het trainen, is het goed mogelijk dat sommige patronen of trends in de data per ongeluk vaker worden weggelaten uit de trainingset, wat leidt tot een hogere fout op de test set in de folds. De systematische error (bias) in de schatting van de testfout is dus hoger.
- Naarmate het aantal folds hoger wordt, zal steeds een kleinere portie van de data worden weggelaten bij het trainen. Er zullen steeds minder patronen of trends in de data ontbreken in de train set, waardoor de bias lager wordt.
- Bij leave-one-out CV is dit effect maximaal: de gemiddelde geschatte testfout zal normaal het dichtst bij de ware testfout liggen dan bij k-fold CV, wat maakt dat de bias hier het laagst is.

© 2023 *Olivier Claerbout*

Bias-variance trade-off for k-fold CV

- Bij LOOCV hebben we evenwel n keer nagenoeg een identieke dataset om op te trainen. Dit betekent dat de modellen zeer gelijkaardig – nagenoeg identiek zijn.
- De fout die wordt gemaakt in elke fold is dus nagenoeg volledig afhankelijk van die specifieke weggelaten observatie, en niet van de algemene samenstelling van de dataset.
- Als gevolg hiervan zullen eventuele “ruis” of “onregelmatigheden” in individuele datapunten een grotere invloed hebben op de testfout in LOOCV dan in k-fold CV.
- Het gevolg is dat hoewel de gemiddelde testfout over alle folds in LOOCV een lage bias kan hebben (omdat het gebaseerd is op bijna de hele dataset), de variantie van deze schatting kan toenemen omdat het sterk wordt beïnvloed door individuele datapunten.
- In k-fold CV, waar de grootte van elke testset groter is, worden de effecten van individuele datapunten enigszins "gemiddeld" over meerdere observaties in elke testset, wat de variantie kan verminderen.
- Wanneer k tussen 5 en 10 ligt, zijn de schattingen van de test error niet onderhevig aan hoge bias of variance.

© 2023 *Olivier Claerbout*

Ridge Regression

© 2023 *Olivier Claerbout*

Ridge Regression

- Ridge Regression is een regularisatietechniek die overfigging op de training data tegengaat
- Het doet dit door een strafterm gebaseerd op de gekwadrateerde waarden van de coëfficiënten bij de error te voegen

© 2023 Olivier Claerbout

Ridge Regression

- Ridge Regression is een regularisatietechniek voor Lineaire Regressie
- Relevant deel in ISLP: 6.2.1

© 2023 Olivier Claerbout

Ridge Regression

$$\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 x_1 + \hat{\theta}_2 x_2 + ... + \hat{\theta}_p x_p$$

- Deze θ – coëfficiënten zijn gevonden door de Residual Sum of Squares (RSS) te minimaliseren

$$RSS = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

$$RSS = \sum_{i=1}^{n} (y_i - \hat{\theta}_0 - \hat{\theta}_1 x_{i1} - \hat{\theta}_2 x_{i2} - ... - \hat{\theta}_p x_{ip})^2$$

$$RSS = \sum_{i=1}^{n} (y_i - \hat{\theta}_0 - \sum_{j=1}^{p} \theta_j x_{ij})^2$$

© 2023 Olivier Claerbout

Ridge Regression

- Het doel van Ridge Regression is om overfitting te voorkomen door een bijkomende strafterm toe te voegen

$$ERR = RSS = \sum_{i=1}^{n} (y_i - \hat{\theta}_0 - \sum_{j=1}^{p} \theta_j x_{ij})^2 \quad + \lambda \sum_{j=1}^{p} \theta_j{}^2$$

"schrinkage penalty"

Ridge Regression minimaliseert de volledige error term: RSS + strafterm

© 2023 Olivier Claerbout

Ridge Regression

- De schrinkage penalty is gebaseerd op de *gekwadrateerde* coëfficiënt:

$$ERROR = \sum_{i=1}^{n} \left(y_i - \hat{\theta}_0 - \sum_{j=1}^{p} \theta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} \theta_j^2$$

Er is ook een te tunen lambda parameter, die bepaalt hoe sterk de “straf” is

© 2023 Olivier Claerbout

Ridge Regression in Python

- Sklearn gebruikt α in plaats van λ om de te tunen hyperparameter over veel modellen heen altijd dezelfde naam te laten hebben: α
- Voor cross validation prestatiestatistieken gebruikt sklearn een “scorer object”. Alle scorer objects volgen de conventie dat hogere waarden beter zijn dan lagere waarden.

© 2023 Olivier Claerbout

Ridge Regression in Python

Notebook: Regularization-Ridge-Lasso-ElasticNet.ipynb

© 2023 *Olivier Claerbout*

Lasso Regression

© 2023 *Olivier Claerbout*

Lasso Regression (L1)

- L1 regularisatie voegt een strafterm toe evenredig met de absolute waarde van de magnitude van de coëfficiënten

$$\sum_{i=1}^{n}\left(y_i-\theta_0-\sum_{j=1}^{p}\theta_j x_{ij}\right)^2+\lambda\sum_{j=1}^{p}|\theta_j|=RSS+\lambda\sum_{j=1}^{p}|\theta_j|$$

© 2023 Olivier Claerbout

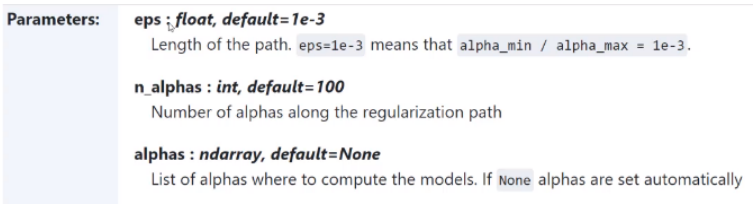
Lasso Regression (L1)

- L1 regularisatie voegt een strafterm toe evenredig met de absolute waarde van de magnitude van de coëfficiënten
  - Beperkt de grootte van de coëfficiënten
  - Kan coëfficiënten op nul zetten als λ voldoende groot is
  - Net als subset selection selecteert LASSO features
  - LASSO modellen zijn doorgaans eenvoudiger te interpreteren

© 2023 Olivier Claerbout

Lasso Regression (L1)

- LassoCV met sklearn checkt een aantal alphas in een range, in plaats van de alphas direct te verstrekken aan het model



Parameters:

eps : *float, default=1e-3*
Length of the path. `eps=1e-3` means that `alpha_min / alpha_max = 1e-3`.

n_alphas : *int, default=100*
Number of alphas along the regularization path

alphas : *ndarray, default=None*
List of alphas where to compute the models. If `None` alphas are set automatically

- Bekijk even de resultaten van LASSO in Python en Scikit-Learn

© 2023 Olivier Claerbout

Lasso Regression in Python

Notebook: Regularization-Ridge-Lasso-ElasticNet.ipynb

© 2023 Olivier Claerbout

Elastic Net

© 2023 Olivier Claerbout

Elastic Net

- We hebben al Ridge en Lasso Regressie gedaan
- Lasso Regressie kan coëfficiënten naar nul laten ‘krimpen’, maar we hebben nog niet gezien hoe of waarom
- Dit wordt duidelijker met Elastic Net, een combinatie van Lasso en Ridge
- Bekijk even de resultaten van LASSO in Python en Scikit-Learn

© 2023 Olivier Claerbout

Elastic Net

- We kunnen Lasso en Ridge herschrijven als:
  - minimaliseer de residual sum of squares onder een bepaalde voorwaarde (de penalty term)

$$\underset{\theta}{\text{minimaliseer}} \left\{ \sum_{i=1}^{n} \left(y_i - \theta_0 - \sum_{j=1}^{p} \theta_j x_{ij} \right)^2 \right\} \quad \text{met voorwaarde} \quad \sum_{j=1}^{p} |\theta_j| \leq s$$

en

$$\underset{\theta}{\text{minimaliseer}} \left\{ \sum_{i=1}^{n} \left(y_i - \theta_0 - \sum_{j=1}^{p} \theta_j x_{ij} \right)^2 \right\} \quad \text{met voorwaarde} \quad \sum_{j=1}^{p} \theta_j^2 \leq s$$

© 2023 Olivier Claerbout

Elastic Net

- Voor de eenvoud:
  - We vertrekken van de vergelijking $\hat{y} = \theta_1 x_1 + \theta_2 x_2$
  - We weten dat regularisatie kan worden uitgedrukt als een bijkomende voorwaarde waar RSS aan onderhevig is
    - L1 beperkt de som van de absolute waarden van de coëfficiënten
    - L2 beperkt de som van de kwadraten van de coëfficiënten
    - Er is een som s waarbij de penalty lager is dan...

© 2023 Olivier Claerbout

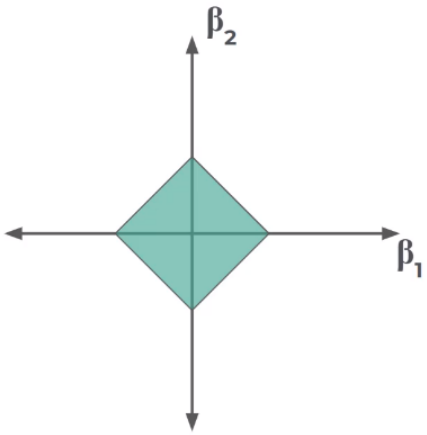
Elastic Net

- Voor de eenvoud:
  - We vertrekken van de vergelijking $\hat{y} = \theta_1 x_1 + \theta_2 x_2$
  - Er is een som s waarbij de penalty lager is dan…
    - Voor Lasso Regression: $|\theta_1| + |\theta_2| \leq s$
    - Voor Ridge Regression: $\theta_1^2 + \theta_2^2 \leq s$

© 2023 Olivier Claerbout

Elastic Net

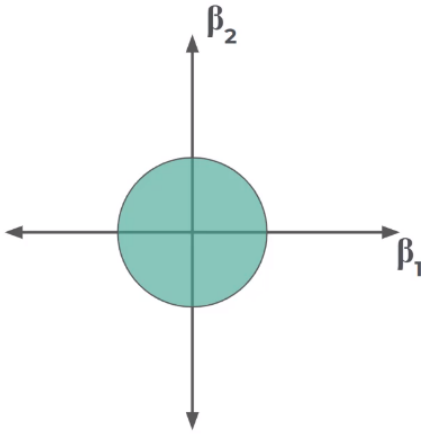
- Plot van Lasso: $|\theta_1| + |\theta_2| \leq s$



© 2023 Olivier Claerbout

Elastic Net

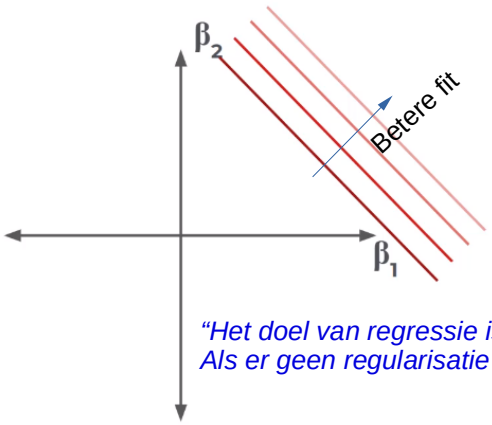
- Plot van Ridge: $\theta_1^2 + \theta_2^2 \leq s$



© 2023 Olivier Claerbout

Elastic Net

- Hoe ziet RSS eruit?



De rode contourlijnen in de afbeelding zijn isolijnen van de kwadratensom van de residuen (RSS).

Dit betekent dat elk punt op een contourlijn een gelijke waarde van de RSS heeft.

Hoe dichter de lijnen bij het centrum liggen, hoe lager de RSS, wat betekent dat het model daar een betere fit heeft (het centrum is de OLS-oplossing – de gewichten zonder regularisatie).

De RSS is een kwadratische functie van de coëfficiënten en heeft een ellipsvormige structuur in de parameter-ruimte.

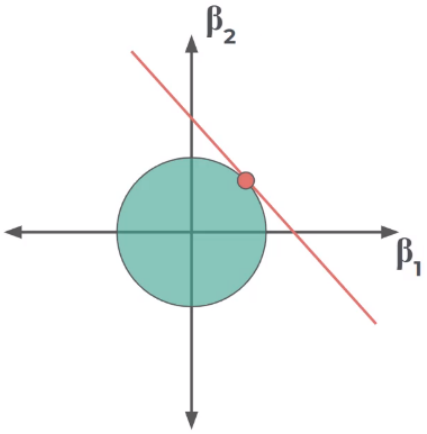
"Het doel van regressie is om een punt (β_1, β_2) te vinden dat deze contourlijnen minimaliseert. Als er geen regularisatie zou zijn, dan zouden we simpelweg het punt nemen waar RSS het laagst is.

© 2023 Olivier Claerbout

Elastic Net

Maar met regularisatie moeten we ons houden aan een extra beperking: de strafterm (L1 of L2) mag niet groter zijn dan een bepaalde waarde s.

voor Ridge Regressie:
een cirkelvormige beperking



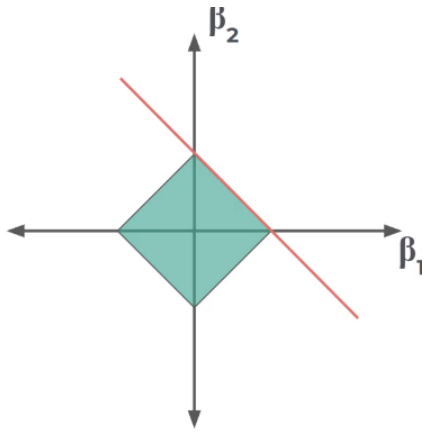
- Dit betekent dat de gewichten niet te groot mogen zijn en binnen deze cirkel moeten blijven.
- Het optimale punt wordt bepaald door het eerste contactpunt tussen de RSS-contourlijnen en de cirkel.
- Dit zorgt ervoor dat Ridge Regression kleinere coëfficiënten afdwingt, maar geen coëfficiënten volledig op nul zet.
- Effect: Alle features blijven bijdragen, maar met kleinere gewichten.
- De grens is een cirkel, dus het minimalisatiepad raakt meestal niet precies de assen, waardoor Ridge geen feature selectie uitvoert.

© 2023 Olivier Claerbout

Elastic Net

Maar met regularisatie moeten we ons houden aan een extra beperking: de strafterm (L1 of L2) mag niet groter zijn dan een bepaalde waarde s.

voor Lasso Regressie:
een ruitvormige beperking



- Hier mogen de gewichten ook niet te groot worden, maar de grens is een diamantvorm in plaats van een cirkel.
- Het optimale punt wordt bepaald door het eerste contactpunt tussen de RSS-contourlijnen en de ruit.
- Effect: De hoeken van de ruit bevinden zich precies op de assen, waardoor het minimalisatiepad vaak coëfficiënten op nul dwingt. Dit betekent dat Lasso feature selectie uitvoert.
- Omdat de ruithoeken op de assen liggen, is het waarschijnlijk dat het optimalisatieproces ervoor zorgt dat sommige coëfficiënten volledig verdwijnen (nul worden).

© 2023 Olivier Claerbout

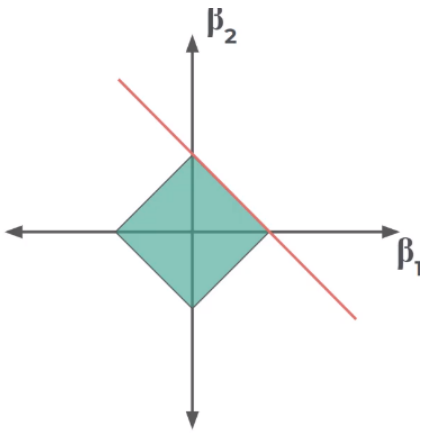
Waarom zet L1 coëfficiënten op 0?

- Geometrisch gezien vormt de L1 regularisatie een ruimtelijke beperking waarin de gewichten zich kunnen bewegen.
- In 2D (zoals in de afbeelding) is deze beperking een ruit, in hogere dimensies (> 2) vormt het een hyperkubus.
- De RSS is een kwadratische functie van de coëfficiënten en heeft een ellipsvormige structuur in de parameter-ruimte.
- Het optimale punt wordt bepaald door de kleinste RSS-contour die nog binnen de L1-beperking valt.
- Omdat de RSS-contouren ellipsvormig zijn, zal de eerste plaats waar een contour de L1-begrenzing raakt, waarschijnlijk een hoek zijn.
- Een hoek betekent dat een of meerdere coëfficiënten exact nul zijn.
- Daarnaast is er nog het Sparsity-inducerend effect: in hoge dimensies (p > 2) heeft de hyperkubus veel meer hoeken dan randen of zijvlakken. De kans dat de optimalisatieoplossing precies op een hoek uitkomt is daarom veel groter dan dat deze op een vlak ligt.

© 2023 Olivier Claerbout

Elastic Net

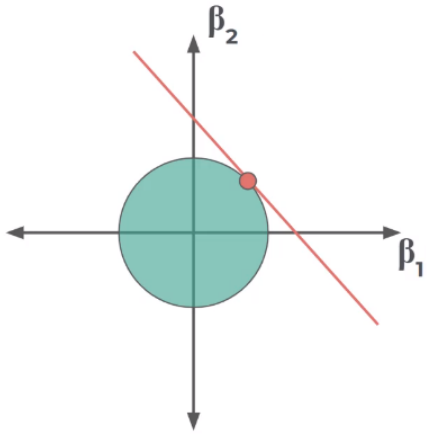
→ Voor Lasso: omdat je de kwadratensom (RSS) minimaliseert en je aan de voorwaarde van de Lasso strafterm die de vorm van een kubus of hyperkubus heeft bent onderworpen, zal je zeer waarschijnlijk een hoek van de hyperkubus tegenkomen, waarvoor sommige componenten van beta nul zijn.



© 2023 Olivier Claerbout

Elastic Net

Voor Ridge: in het geval van een n-sfeer, zijn de punten op de grens voor dewelke sommige θ's nul zijn niet te onderscheiden van de andere, en het is niet waarschijnlijker dat het convexe object een punt raakt waar sommige componenten van θ nul zijn dan voor punten waar geen enkele θ nul is.

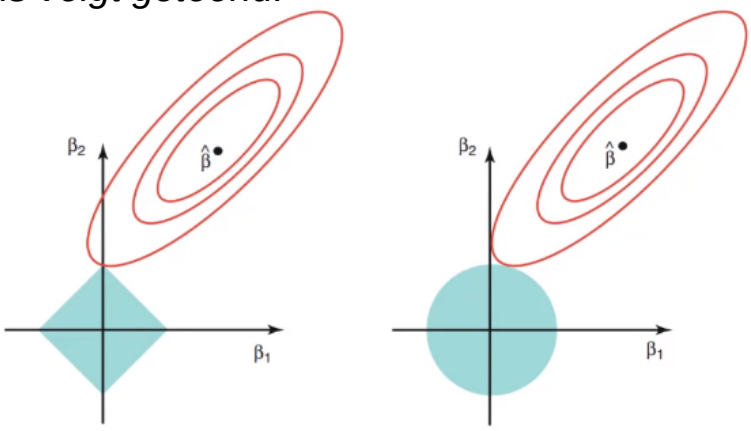


© 2023 Olivier Claerbout

Elastic Net

Daarom leidt Lasso vaker tot nulcoëfficiënten dan Ridge

Het voorgaande wordt ook vaak als volgt getoond:



© 2023 Olivier Claerbout

Elastic Net

Elastic Net wil dus de regularisatie van L1 en L2 verbeteren door ze te combineren.

$$\text{Error} = \sum_{i=1}^{n}\left(y_i-\theta_0-\sum_{j=1}^{p}\theta_j x_{ij}\right)^2+\lambda_1\sum_{j=1}^{p}\theta_1{}^2+\lambda_2\sum_{j=1}^{p}|\theta_j|$$

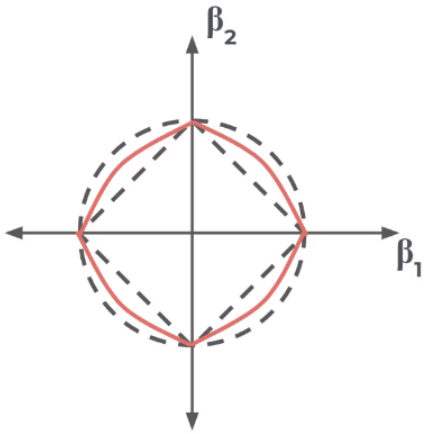
Merk op: er zijn 2 afzonderlijke λ termen! Je kan dit voorstellen als een λ aan de buitenzijde, en een alfa aan de binnenzijde:

$$\frac{\sum_{i=1}^{n}\left(y_i-x_i{}^J\hat{\theta}\right)^2}{2n}+\lambda\left(\frac{1-\alpha}{2}\sum_{j=1}^{m}\hat{\theta}_j{}^2+\alpha\sum_{j=1}^{m}|\hat{\theta}_j|\right)$$

© 2023 Olivier Claerbout

Elastic Net

Hoe ziet dit eruit in het "strafgebied": een soort "gebogen kubus"...



© 2023 Olivier Claerbout

Elastic Net met Python & Scikit-learn!

Notebook: Regularization-Ridge-Lasso-ElasticNet.ipynb

© 2023 *Olivier Claerbout*

Subset selection & Stepwise selection

© 2023 *Olivier Claerbout*

Subset selection

- Probeert alle mogelijke combinaties van features en kiest de beste subset
- Computationeel duur bij veel features (2^p combinaties!)
- Dit is in tegenstelling tot Regularisatie (Ridge, Lasso, Elastic Net), waar we het model trainen op alle features, en vervolgens sommige features laten krimpen of nul worden.

© 2023 Olivier Claerbout

Best Subset selection

- Bij best subset selection wordt een afzonderlijke fit gedaan voor elke mogelijke combinatie van p features. Vervolgens wordt het beste model geselecteerd. Dit gebeurt als volgt:
  - Laat M_0 het nulmodel zijn, zonder features. Dit model voorspelt simpelweg het gemiddelde voor elke observatie.
  - Vervolgens testen we alle mogelijke feature combinaties. Er zijn $\binom{p}{k}$ mogelijke modellen (de binomiaalcoëfficiënt; het aantal manieren om k features te kiezen uit p)
  - Voor elk model bereken je de RSS
  - Kies het model met de laagste RSS voor elke k en noem het M_k.
  - Hierna is het probleem gereduceerd van 2^p mogelijke modellen tot p + 1 mogelijke modellen.

Best Subset Selection is een grondige maar dure methode om het beste regressiemodel te vinden!

© 2023 Olivier Claerbout

Stepwise selection

- Stepwise Selection is een snellere manier om een subset van de beste features te kiezen voor een regressiemodel, zonder alle mogelijke combinaties te testen zoals bij Best Subset Selection.
- Het doel is om een klein maar krachtig model te vinden door stapsgewijs features toe te voegen of te verwijderen op basis van hun statistische significantie.
- Forward stepwise selection werkt als volgt:
  - Start met het nulmodel (geen features, alleen het gemiddelde)
  - Test elke feature afzonderlijk en voeg de feature toe die de grootste verbetering geeft (vb laagste resulterende RSS, beste R^2,...)
  - Herhaal dit proces tot geen enkele feature meer een significante verbetering geeft
  - Het eindmodel bevat alleen de beste features!

Dit werkt goed in de praktijk, maar garandeert niet dat het beste model wordt geselecteerd uit de 2^p mogelijke modellen aangezien deze niet allemaal worden geanalyseerd.

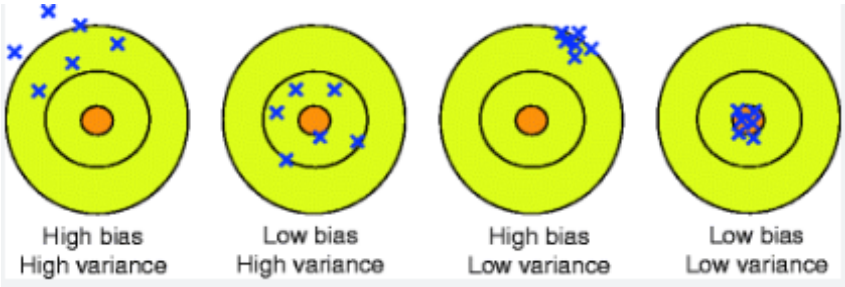
© 2023 Olivier Claerbout

Subset selection & Stepwise selection met Python & Scikit-learn!

Notebook: subset_stepwise_selection.ipynb

© 2023 Olivier Claerbout

Bias vs variance



- Bias: systematische error in de voorspellingen van het model. Model is te eenvoudig en niet in staat om de juiste patronen te capteren. Slechte resultaten op train en test.
- Variance: de gevoeligheid van een model tov veranderingen in de training data. Een model met hoge variance is te complex en heeft teveel de ruis in de dataset gemodelleerd ipv de echte patronen. Goede resultaten op train, slechte op test...

© 2023 Olivier Claerbout

Bias: praktijkvoorbeeld

- Het COMPAS (Correctional Offender Management Profiling for Alternative Sanctions) algoritme, dat wordt gebruikt in de Amerikaanse rechtssystemen om de waarschijnlijkheid te schatten dat een verdachte opnieuw een misdrijf zal plegen, is het meest prominente voorbeeld van AI-bias (vooringenomenheid) en de negatieve gevolgen voor de samenleving.
- Het algoritme voorspelt twee keer zoveel valse positieven voor recidive bij zwarte overtreders (45%) dan bij blanke overtreders (23%), en is 77% meer geneigd om zwarte overtreders als hoog risico te bestempelen om in de toekomst gewelddadige misdrijven te plegen, terwijl het blanke overtreders onterecht als laag risico bestempelt.

© 2023 Olivier Claerbout