Cross validation & Grid Search



© 2023 Olivier Claerbout

Lesmateriaal

- Via GitHub account:
  git clone https://github.com/oclaerbout/syntra_data_scientist.git

© 2023 Olivier Claerbout

Cross Validation

© 2023 Olivier Claerbout

Cross Validation

- We gebruikten reeds ingebouwde cross validation (vb bij RidgeCV)
- We gaan nu zien hoe we cross validation zelf kunnen toepassen bij andere modellen
- Hierdoor kunnen we dan grid searches doen om optimale hyperparameters te vinden

© 2023 Olivier Claerbout

Cross Validation

- We starten van het eenvoudigste cross validation proces wat we nu kennen (Train | Test split), en bouwen op tot volledige k-fold cv
- We starten met het herhalen van wat we hierover al gezien hebben…

© 2023 Olivier Claerbout

Train Test split

- Train | Test split
- Begin met volledige dataset
- Kies een deel om te trainen, een deel om te testen
- Train het model
- Evalueer de error op de test set
- We doen aanpassingen op basis van de fout op de test set

Laat ons dit even reviewen in notebook 00-Cross-Validation.ipynb

© 2023 Olivier Claerbout

Demo: train | test split

© 2023 Olivier Claerbout

Train Validation Test split

- We zagen net dat de Train | Test split methode het nadeel heeft dat de performantie niet op ‘echt ongeziene’ data gebeurt.
- Alhoewel het bijsturen van hyperparameters op test data niet echt wordt aanzien als een ‘data lek’, is het toch een potentieel issue vanuit het standpunt van rapportering

© 2023 Olivier Claerbout

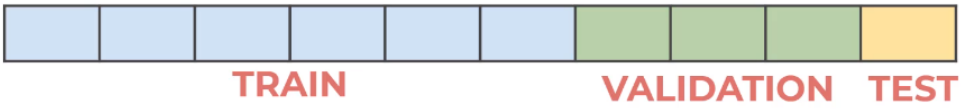
Train Validation Test split

- Als we een echt eerlijke en finale set van performantiestatistieken willen, dan moeten we deze van een finale test set op basis waarvan niet werd bijgestuurd
- Laat ons dit even bekijken in theorie en praktijk!

© 2023 Olivier Claerbout

Train Validation Test split

- We splitsen een dataset in Train, Validatie en Test



- Hoe groot moet de test set zijn? En validatie?

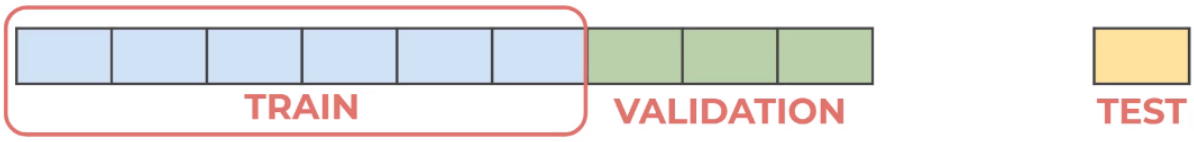
© 2023 Olivier Claerbout

Train Validation Test split

- Houd de test set apart voor finale evaluatie



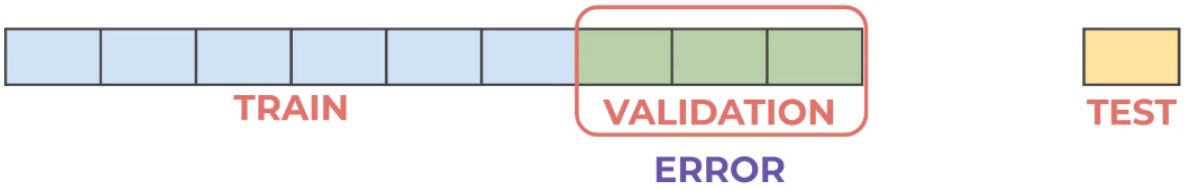
- Fit het model op de train set



© 2023 Olivier Claerbout

Train Validation Test split

- Evalueer de performantie op de validatie set

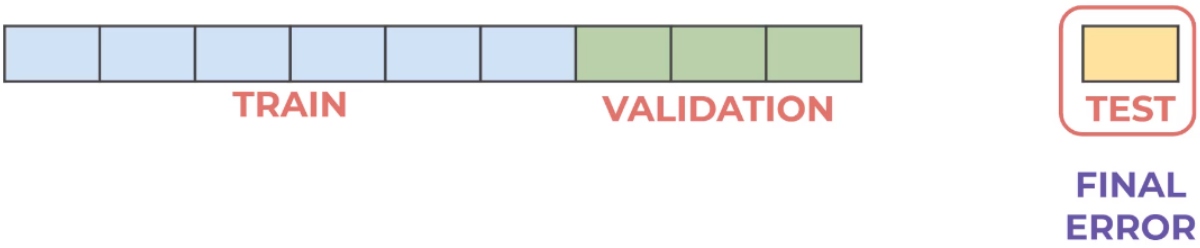


- Pas indien nodig hyperparameters aan en herhaal...

© 2023 Olivier Claerbout

Train Validation Test split

- Bepaal finale performantie op de test



- Pas NIET meer aan!

© 2023 Olivier Claerbout

Train Validation Test split

- De reden om niet meer aan te passen na finale test is om een eerlijke evaluatie van het model te krijgen
- Het model is niet gefit op de finale test data, en de hyperparameters zijn niet bijgestuurd op basis van de finale test data
- De finale test data is dus echt een set nooit geziene data

© 2023 Olivier Claerbout

Train Validation Test split

- In Python met Scikit-Learn doen we dit door de train_test_split() functie twee keer te callen
  - Eén keer om een grotere training set af te splitsen
  - Een tweede keer om de resterende data te splitsen in een validatie en een test set te splitsen

Laat ons dit even reviewen in notebook 00-Cross-Validation.ipynb

© 2023 Olivier Claerbout

Demo: train | validation | test split

© 2023 Olivier Claerbout

Cross Validation - cross_val_score

- Gebruik van de ingebouwde cross_val_score voor elk model
- Model hoeft dan geen CV ingebouwd hebben!

© 2023 Olivier Claerbout

Cross Validation – werkwijze (herhaling)

- Start met de volledige dataset



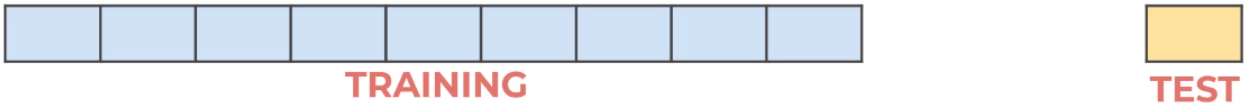
- Splits de dataset in Training en Test data



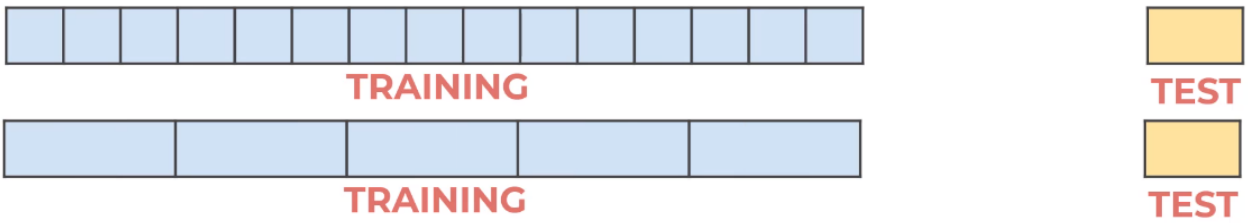
© 2023 Olivier Claerbout

Cross Validation – werkwijze (herhaling)

- Zet de Test data apart voor finale evaluatie



- Kies een K-fold split waarde voor de Training data



© 2023 Olivier Claerbout

Cross Validation – werkwijze (herhaling)

- Train op K-1 folds en Validate op 1 Fold



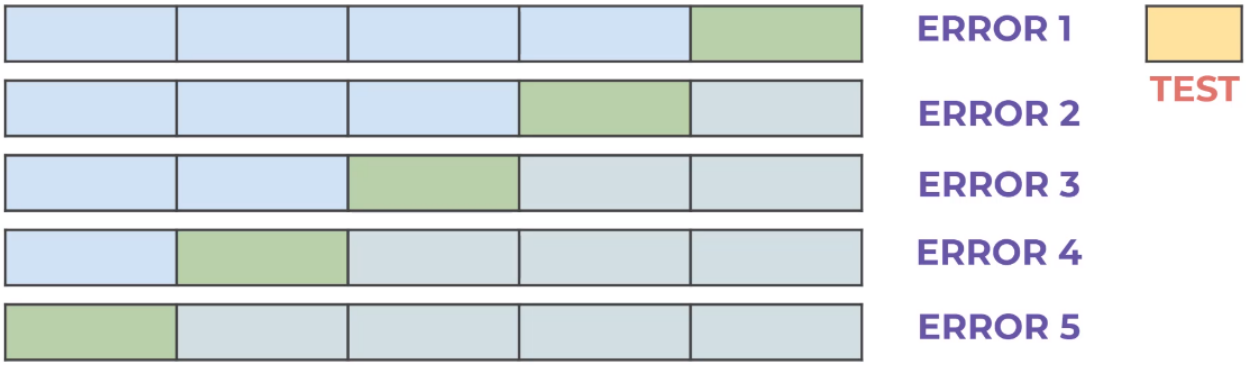
- Bereken een error voor deze fold



© 2023 Olivier Claerbout

Cross Validation – werkwijze (herhaling)

- Herhaal voor de verschillende Fold combinaties



Gemiddelde ERROR berekenen, bijsturen en opnieuw CV! Tevreden? Bereken error op TEST set.

© 2023 Olivier Claerbout

Cross Validation – werkwijze (herhaling)

- De cross_val_score functie gebruikt een model en training set (met een K en gekozen metric) om dit automatisch te doen.
- Hierdoor kan cross validation toegepast worden op elk model

Laat ons dit even reviewen in notebook 00-Cross-Validation.ipynb

© 2023 Olivier Claerbout

Demo: gebruik van cross_val_score

© 2023 Olivier Claerbout

Cross Validation met cross_validate

- De cross_validate functie laat ons toe om meerdere performantiestatistieken van cross validation voor een model te zien, en geeft ook info inzake de tijd die fitten en testen in beslag nam

© 2023 Olivier Claerbout

cross_val_score vs cross_validate

- cross_val_score
  - Geeft scores van de testsplits voor elk van de k "folds" (partities) van kruisvalidatie terug.
  - Voordelen: Eenvoudig en rechttoe rechtaan. Goed voor snelle schattingen van de modelprestaties met een enkele evaluatiemetric.
  - Nadelen: Beperkte functionaliteit in vergelijking met cross_validate. Het biedt niet de flexibiliteit van meerdere scoring metrics of de mogelijkheid om fit- en score-tijden te meten.
  - Toepassingsgebied: Wanneer u snel een idee wilt krijgen van de modelprestaties met een enkele metric, zoals mean squared error.

© 2023 Olivier Claerbout

cross_val_score vs cross_validate

- cross_validate
  - Geeft test scores, fit tijden, en score tijden voor elk van de k "folds" terug. Kan ook training scores en gefitte modellen (estimators) retourneren. Ondersteunt meerdere evaluatiemetrics tegelijk.
  - Voordelen: Biedt uitgebreidere informatie dan cross_val_score. Verschil-lende aspecten van modelprestaties en -gedrag in één keer evalueren.
  - Nadelen: Kan als overkill worden beschouwd als u alleen geïnteresseerd bent in een enkele, eenvoudige prestatie-indicator.
  - Toepassingsgebied: Voor gedetailleerde informatie over modelprestaties, incl. zaken als fit- en score-tijden, of voor meerdere evaluatiemetrics in één keer

© 2023 Olivier Claerbout

cross_val_score vs cross_validate

- Conclusie:
  - De keuze tussen cross_val_score en cross_validate hangt af van de specifieke behoeften van uw project. Als u snel een enkele prestatie-indicator wilt, kan cross_val_score voldoende zijn. Als u echter meer gedetailleerde informatie of meerdere evaluatiemetrics tegelijk wilt, dan is cross_validate de betere keuze.
- Hoe kan deze functie worden gebruikt?

Laat ons dit even reviewen in notebook 00-Cross-Validation.ipynb

© 2023 Olivier Claerbout

Demo: gebruik van cross_validate

© 2023 Olivier Claerbout

Grid Search

- Complexere modellen hebben vaak meerdere aanpasbare hyperparameters
- Grid search is een manier om een model te trainen en valideren op elke mogelijke hyperparameter combinatie

© 2023 Olivier Claerbout

Grid Search

- Scikit-Learn bevat een GridSearchCV klasse die in staat is om een dictionary met meerdere hyperparameter opties te testen via cross validation
- Hierdoor kan zowel cross-validation als grid-search op een worden toegepast op elk model

Laat ons dit even reviewen in notebook 01-Grid-Search.ipynb

© 2023 Olivier Claerbout