Logistische Regressie



© 2025 *Olivier Claerbout*

Overzicht

- Classificatie
- Waarom geen Lineaire Regressie?
- Van Lineaire Regressie naar Logistische Regressie
- Wiskundige benadering
- Eenvoudige implementatie van Logistische Regressie voor een classificatieprobleem
- Interpretatie resultaten
- Prestatiecoëfficiënten (Accuracy, Precision, Recall / ROC curves)
- Multiclass Classificatie
- Project!

© 2025 *Olivier Claerbout*

Logistische Regressie

Classificatie

© 2025 *Olivier Claerbout*

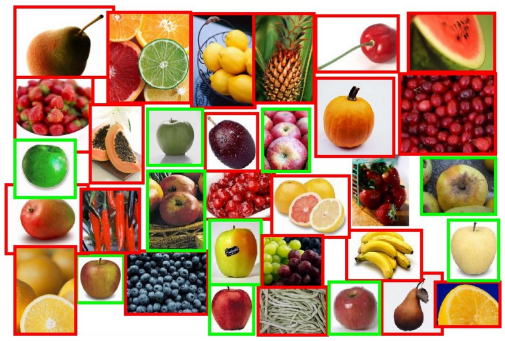
Logistische Regressie

- Lineaire Regressie: voorspellen continu label
- Hoe categorisch label voorspellen?
  - Logistische Regressie
  - Opgepast: Logistische Regressie is een ***Classificatietechniek***

© 2025 *Olivier Claerbout*

Logistische Regressie

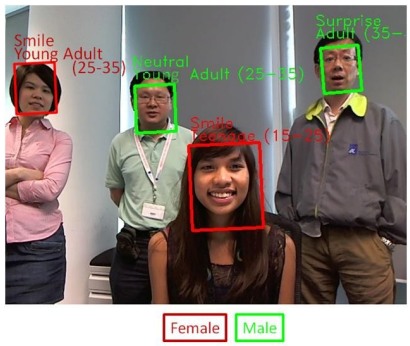
- *Classificatie is een supervised learning techniek waarbij een getraind model niet geziene inputs toewijst aan één of meerdere gelabelde categorieën (classes)*



© 2025 *Olivier Claerbout*

Logistische Regressie

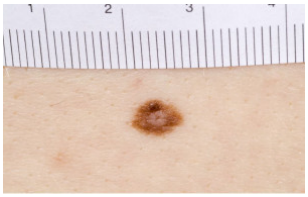
- *Toepassingen van classificatie:*
  - Gezichtsherkenning
  - Nummerplaatherkenning
  - Spam detectie
  - Medische diagnoses
  - Voorspelling of een klant op een ad zal klikken
  - Kwaliteitscontrole
  - …

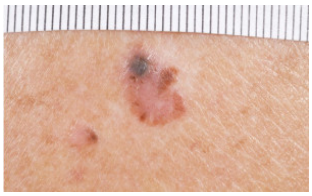


© 2025 *Olivier Claerbout*

Soorten Classifiers

- Binary classifier:
  - Verdeel de samples in 2 verschillende klasses
  - Vb: is een vlek goedaardig of kwaadaardig?

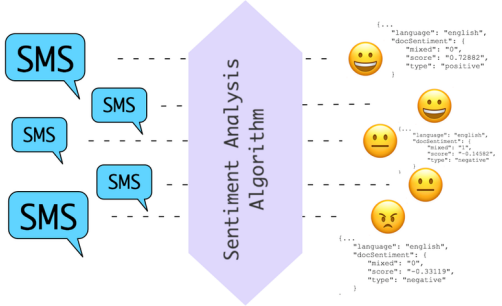




© 2025 *Olivier Claerbout*

Soorten Classifiers

- Multiclass classifier:
  - Verdeel de samples in 3 of meerdere verschillende klasses
  - Vb: gezichtsherkenning, sentiment analyse

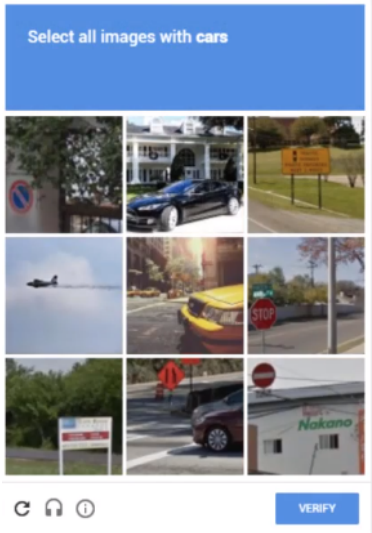


© 2025 *Olivier Claerbout*

Soorten Classifiers

- Multiclass classifier:
  - Klasse 0: Wagen
  - Klasse 1: Straat
  - Klasse 2: Brug





© 2025 Olivier Claerbout

Soorten Classifiers

- Multiclass
- Continue variabele kan worden opgedeeld in categorieën:

  - Klasse 0: woningen < 150k €
  - Klasse 1: woningen 150k € - 200k €
  - Klasse 2: woningen > 200k €

Wij gaan dit niet gebruiken, maar het kan...

© 2025 Olivier Claerbout

Soorten Classifiers

- Multilabel classifier:
  - Er kunnen meerdere labels aan een sample toegewezen worden. Een sample kan tot meerdere klasses behoren
  - Voorbeelden: image content analysis, een film kan tot meerdere genres behoren.



Huis	Boom	Strand	Wolken	Bergen	Dieren
Ja	Ja	Nee	Ja	Nee	Nee

© 2025 Olivier Claerbout

Classifiers

- Classificatie algoritmes geven een **kans** om tot een klasse te behoren

  - Klasse 0: 10%
  - Klasse 1: 85%
  - Klasse 2: 5%

© 2025 Olivier Claerbout

Classifiers

- Aangezien onze voorspelling een categorie is, kunnen we geen verschil berekenen tussen werkelijk en voorspeld
- Volledig nieuwe set performantiestatistieken nodig!

© 2025 *Olivier Claerbout*

Logistische Regressie

Waarom geen lineaire regressie?

© 2025 *Olivier Claerbout*

Waarom geen lineaire regressie

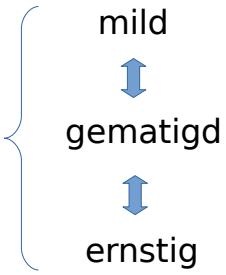
- Indien er meer dan 2 labels zijn, stel medische diagnose:
  - Beroerte
  - Overdosis
  - Epileptische aanval

Y: 3 opties. In functie van de volgorde krijgen we volledig andere lineaire modellen (coëfficiënten) op basis van de input features, met andere voorspellingen op test observaties

© 2025 Olivier Claerbout

Waarom geen lineaire regressie

- Enkel mogelijk bij:
  - *natuurlijke orde* tussen aandoeningen vb mild, gematigd, ernstig waarbij onderlinge *delta's ongeveer gelijk* zijn



Spijtig genoeg is er in het algemeen geen methode om een kwalitatieve variabele met meer dan 2 klassen om te vormen naar een kwantitatieve vorm die klaar is voor lineaire regressie

© 2025 Olivier Claerbout

Waarom geen lineaire regressie

- Voor een classifier met 2 labels (binair) is de situatie beter
  - Vb 0 = beroerte; 1 = overdosis drugs
- We kunnen een lineair regressiemodel fitten:
  - Voorspel overdosis als $0{,}5 < \hat{y}$, anders beroerte

© 2025 *Olivier Claerbout*

Waarom geen lineaire regressie

- Lineaire Regressie is in dit geval acceptabel
  - $X\hat{\theta}$ ~ Pr(overdosis|X)
- Probleem: range van voorspellingen!

© 2025 *Olivier Claerbout*

Waarom geen lineaire regressie

- Samenvattend:
  - Regressie kan niet meer dan 2 kwalitatieve labels aan
  - Zelfs met slechts 2 klassen: geen betekenisvolle voorspellingen

Logistische regressie...

© 2025 *Olivier Claerbout*

Logistische Regressie

Theorie en intuïtie: de logistische functie

© 2025 *Olivier Claerbout*

Sigmoid of logistische functie

- Logistische Regressie werkt via transformatie van een Lineaire Regressie naar een classificatie model door middel van de **logistische functie**:

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

Momenteel bespreken we de logistische functie, niet het logistische regressie model!

© 2025 Olivier Claerbout

Sigmoid of logistische functie

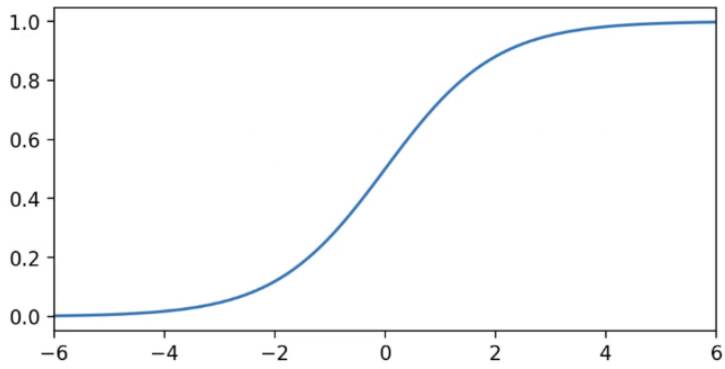
- De logistische functie werd ontwikkeld door Pierre François Verhulst (olv Adolphe Quetelet)
- Verhulst was een Belgisch Wiskundige
- Eerst Brussel, doctoraat in Gent
- Wetten inzake aangroei bevolking
  - Voorheen constante groei
  - Verhulst hield rekening met uitputting van bronnen
  - Tegenwoordig vooral in biologische wetenschappen vb bacteriënpopulaties



© 2025 Olivier Claerbout

Sigmoid of logistische functie

- “Grenzen” bij logistische functie:

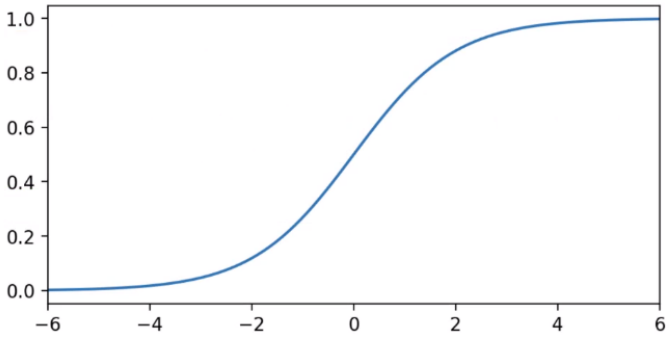


$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

© 2025 Olivier Claerbout

Sigmoid of logistische functie

- In jaren 40 vorige eeuw: Joseph Berkson gebruikt logistische functie voor statistisch modelleren



$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



© 2025 Olivier Claerbout

Lineaire naar Logistische Regressie

- Hoe kunnen we:

  Een **lineair regressie** model, gebruikt voor een regressietaak...

  omvormen...

  tot een **logistisch regressiemodel** voor een classificatietaak?

Beeld je een dataset in met één enkele feature (inkomen vorig jaar) en een enkele te voorspellen waarde (afbetalingen voldaan)

© 2025 Olivier Claerbout

Lineaire naar Logistische Regressie

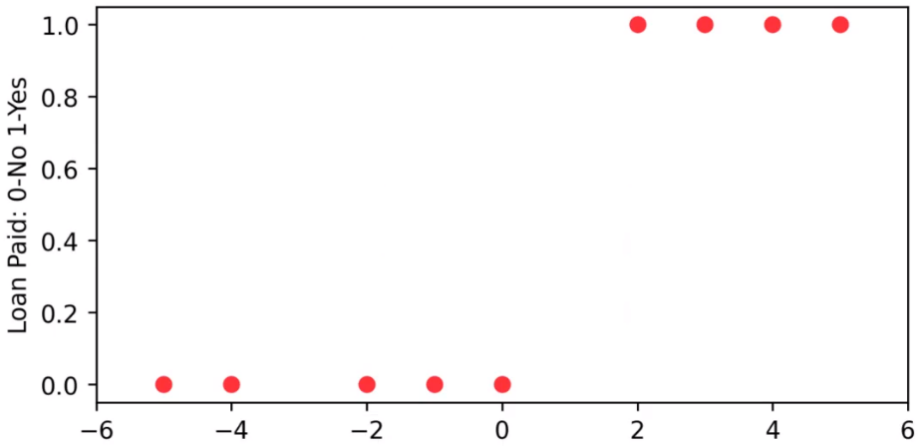
- Dataset:

Inkomen	Lening afbetaald
-5	0
-4	0
-2	0
-1	0
0	0
2	1
3	1
4	1
5	1

© 2025 Olivier Claerbout

Lineaire naar Logistische Regressie

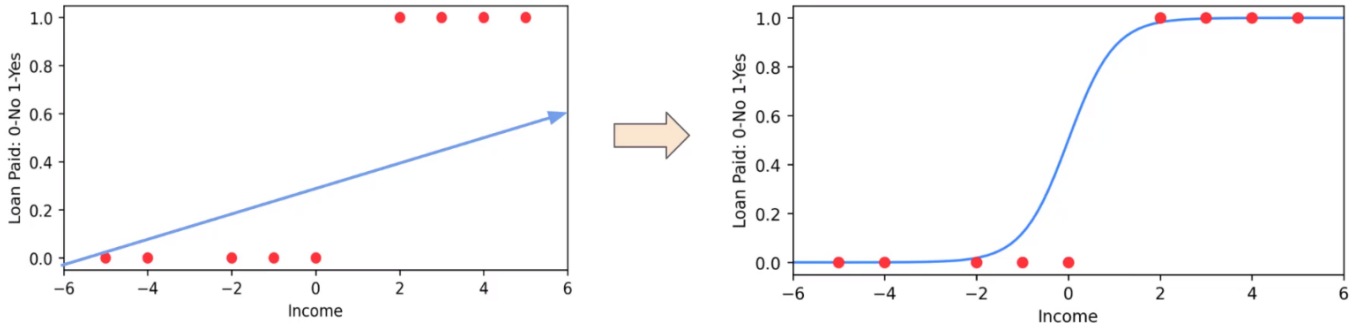
- Inkomen vs betaald:



© 2025 Olivier Claerbout

Lineaire naar Logistische Regressie

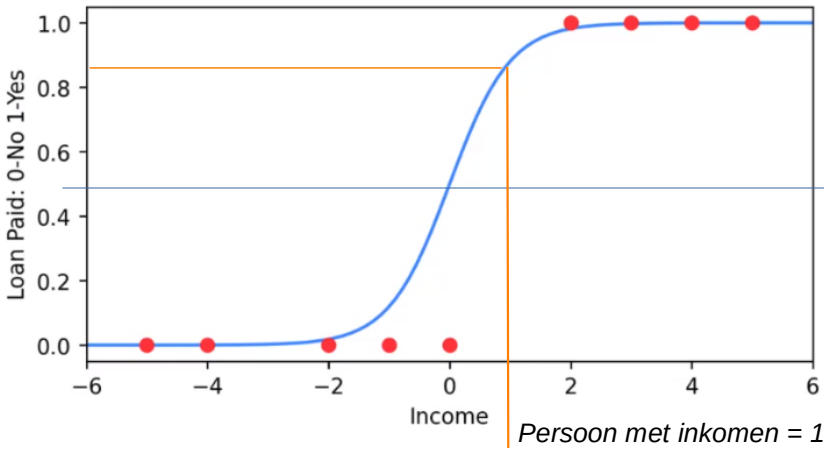
- Inkomen vs betaald:



© 2025 Olivier Claerbout

Lineaire naar Logistische Regressie

- Y-as: kans om tot een klasse te behoren



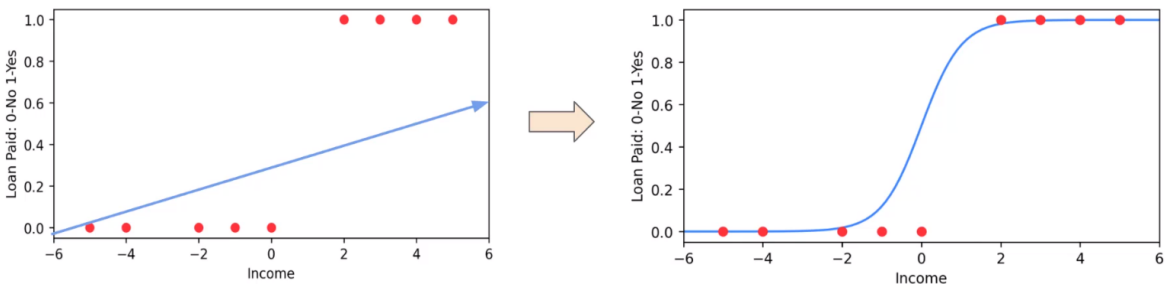
P(y=1) > 0,5
= kantelpunt

Persoon met inkomen = 1: kans op afbetalen = 0,85 => Pred = 1

© 2025 Olivier Claerbout

Lineaire naar Logistische Regressie

- Hoe bekomen we de “S” lijn?
- Conversie van lineaire naar logistische regressie!



© 2025 Olivier Claerbout

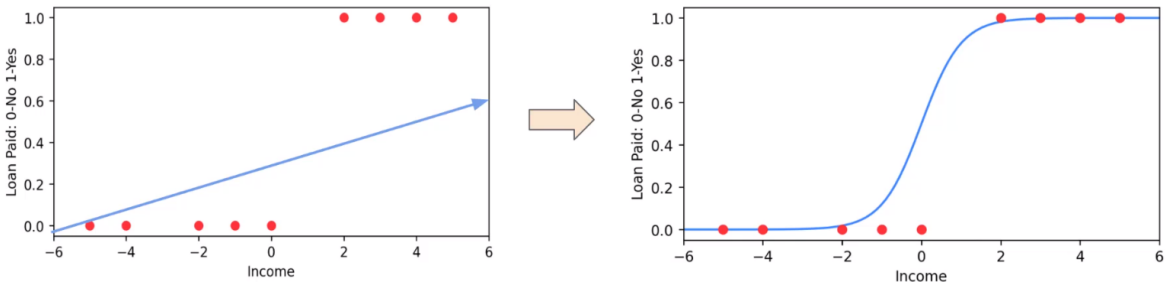
Logistische Regressie

Theorie en intuïtie: wiskundige achtergrond

© 2025 *Olivier Claerbout*

Theorie en intuïtie

- Conversie van lineaire naar logistische regressie:
- Overstap van een model waar we een slechte fit hebben naar een model wat deze fit aankan



© 2025 *Olivier Claerbout*

Theorie en intuïtie

- We kennen de vergelijking van Lineaire Regressie:

$$\hat{y} = \theta_0 x_0 + \ldots + \theta_n x_n \qquad \hat{y} = \sum_{i=0}^{n} \theta_i x_i$$

- We weten dat de logistische functie van elke input een output tussen 0 en 1 geeft

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

© 2025 Olivier Claerbout

Theorie en intuïtie

- Volledig uitgeschreven:

$$\hat{y} = \frac{1}{1+e^{-\sum_{i=0}^{n} \theta_i x_i}}$$

© 2025 Olivier Claerbout

Theorie en intuïtie

- ODDS (Kansverhouding)
- Bekend uit gokken?
  - N to 1 of 2 tegen 3 ...

De kansverhouding van een gebeurtenis met waarschijnlijkheid p wordt gedefinieerd als de kans dat de gebeurtenis doorgaat gedeeld door de kans dat de gebeurtenis niet doorgaat:

$$\frac{p}{1-p}$$

Bij p = 50%: 1 to 1 ODDS

© 2025 Olivier Claerbout

Theorie en intuïtie

- We kunnen de formule van logistische regressie herschikken om aan te tonen dat deze equivalent is aan het modelleren van ln(odds) als een lineaire combinatie van de features

$$\hat{y} = \frac{1}{1 + e^{-\sum_{i=0}^{n} \theta_i x_i}}$$

Log odds als lineaire combinatie van de features!
→ oplossen zodat θx aan één kant staat

© 2025 Olivier Claerbout

Theorie en intuïtie

- We hebben nu een y as in termen van ln(odds)!

$$\ln\left(\frac{\hat{y}}{1-\hat{y}}\right)=\sum_{i=0}^{n}\theta_i x_i$$

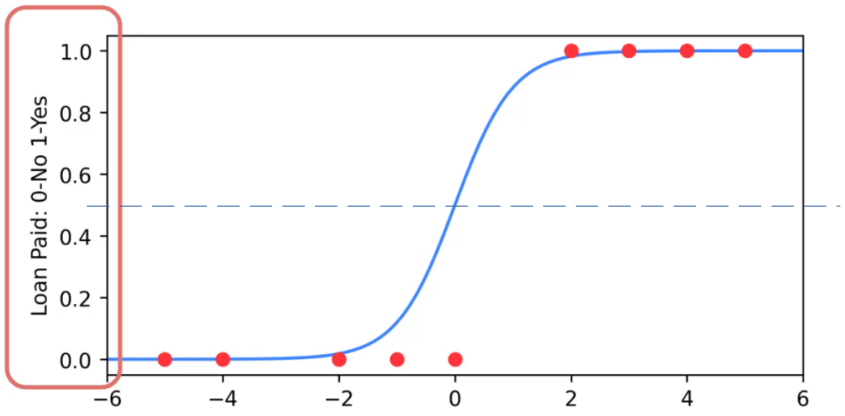
Hoe zou de functiecurve eruit zien ifv log odds?

© 2025 Olivier Claerbout

Theorie en intuïtie

- Bij p = 0,5

$$\ln\left(\frac{0{,}5}{1-0{,}5}\right)=0$$

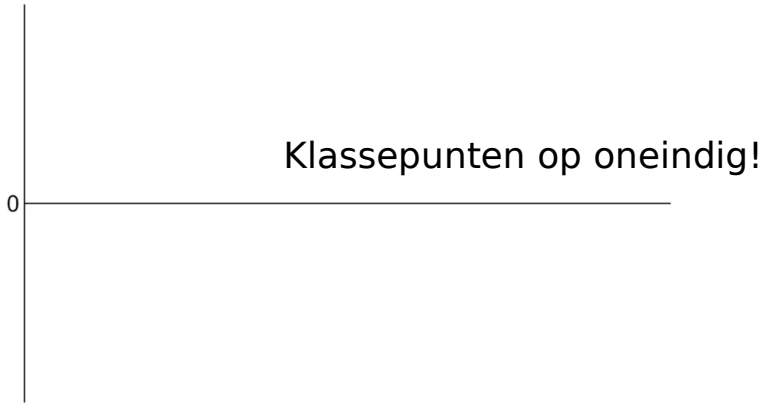


© 2025 Olivier Claerbout

Theorie en intuïtie

- Als p naar 1 gaat: ln(odds) wordt ∞

$$\ln\left(\frac{0{,}5}{1-0{,}5}\right)=0$$



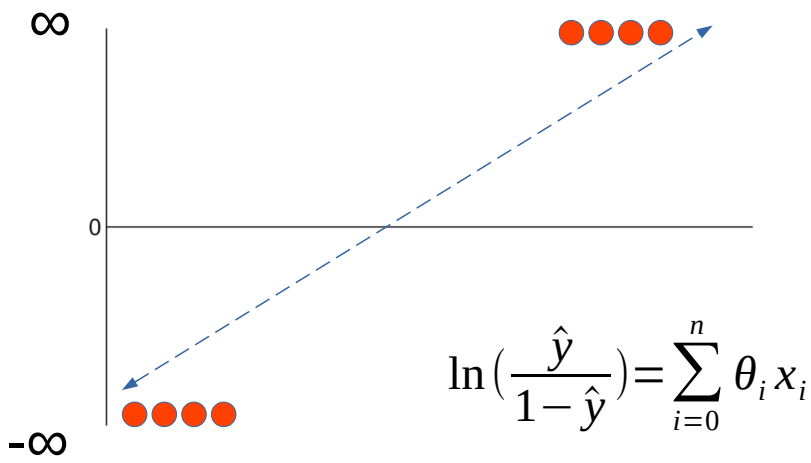
- Als p naar 0 gaat: ln(odds) wordt -∞

© 2025 Olivier Claerbout

Theorie en intuïtie

$$\ln\left(\frac{p}{1-p}\right)=0$$

Onze logistische functie is een lijn indien we als y as de ln(odds) gebruiken



© 2025 Olivier Claerbout

Theorie en intuïtie

- Aangezien de ln(odds) schaal niet lineair is, kunnen we een waarde van θ niet direct linken aan een toe- of afname van een “eenheid” zoals we dit konden in Lineaire Regressie.

$$\ln\left(\frac{\hat{y}}{1-\hat{y}}\right)=\sum_{i=0}^{n}\theta_i x_i$$

© 2025 Olivier Claerbout

Theorie en intuïtie

Teken van de coëfficiënt:

- Positief teken van een θ betekent een toename van de kans dat een observatie behoort tot klasse 1 bij toename van bijhorende feature x
- En omgekeerd...

$$\ln\left(\frac{\hat{y}}{1-\hat{y}}\right)=\sum_{i=0}^{n}\theta_i x_i$$

© 2025 Olivier Claerbout

Theorie en intuïtie

Magnitude van de coëfficiënt:

- De magnitude van een coëfficiënt is moeilijk direct te interpreteren
- We kunnen wel beginnen de odds ratio gebruiken, waarbij we magnitudes tegenover elkaar vergelijken

$$\ln\left(\frac{\hat{y}}{1-\hat{y}}\right)=\sum_{i=0}^{n}\theta_i x_i$$

© 2025 Olivier Claerbout

Theorie en intuïtie

Magnitude van de coëfficiënt:

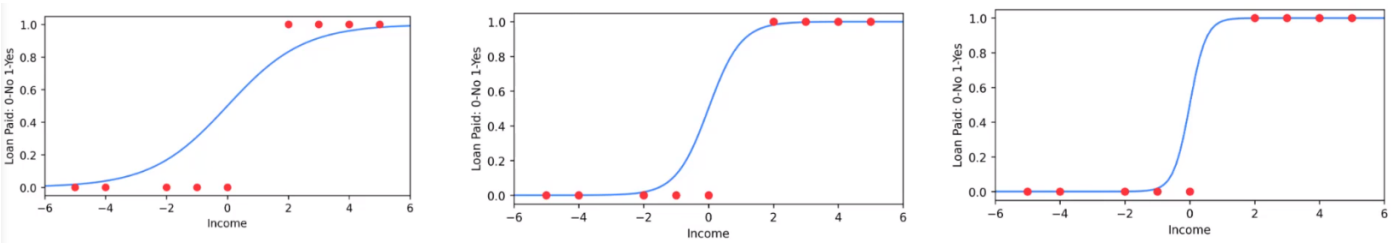
- Het vergelijken van magnitudes van coëfficiënten geeft inzicht in welke features het meest invloed hebben op de voorspelling van de klasse

$$\ln\left(\frac{\hat{y}}{1-\hat{y}}\right)=\sum_{i=0}^{n}\theta_i x_i$$

© 2025 Olivier Claerbout

Theorie en intuïtie

Hoe fitten we de curve?



Maximum likelihood!

© 2025 Olivier Claerbout

Theorie en intuïtie

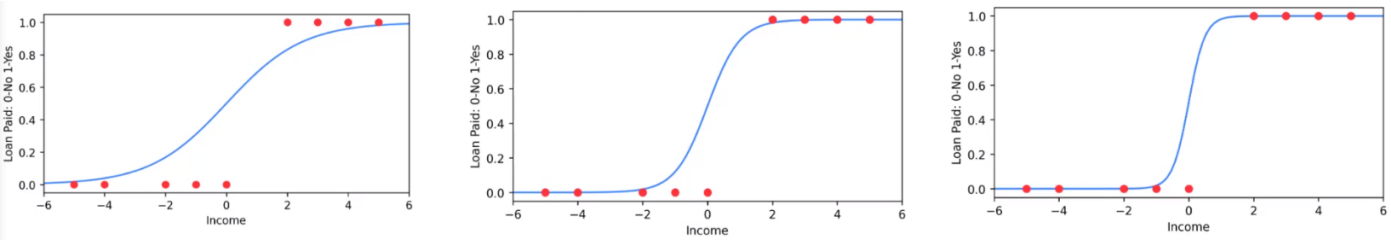
- Logistische regressie gebruikt maximum likelihood om het best passend model te vinden
- We gaan een intuïtieve benadering zien hoe dit werkt
- We zullen de kostfunctie en Gradient Descent ook even bekijken

De wiskunde hiervan is buiten de scope van deze opleiding, zelfs buiten de scope van ISLP… (zie H4.3.2)

© 2025 Olivier Claerbout

Theorie en intuïtie

- Hier zien we 3 verschillende logistische regressie curves met verschillende θ waarden
- Welke is de best passende? Hoe meten we dit?



© 2025 Olivier Claerbout

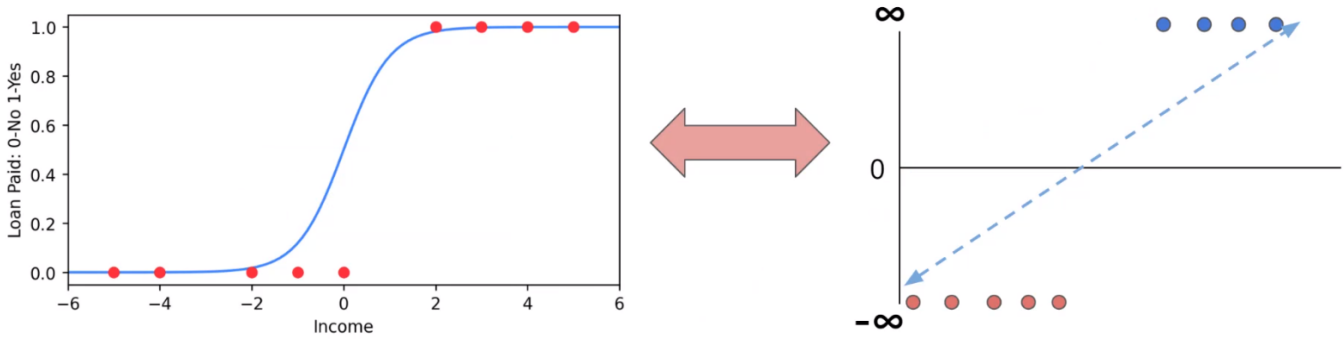
Theorie en intuïtie

- Bij lineaire regressie konden we de kleinste kwadratensom gebruiken om de beste fit te vinden
- In functie van ln(odds) hadden we een lineaire relatie met de θ coëfficiënten en de x features
- Maar: targets bevinden zich op ∞ en -∞
- Kleinste kwadratensom is dus niet mogelijk

© 2025 Olivier Claerbout

Theorie en intuïtie

- Eerste stap voor maximum likelihood is teruggaan van ln(odds) naar kansen



© 2025 Olivier Claerbout

Theorie en intuïtie

- Eerste stap voor maximum likelihood is teruggaan van ln(odds) naar kansen

$$\ln\left(\frac{p}{1-p}\right)=\ln\left(odds\right)$$

$$\frac{p}{1-p}=e^{\ln\left(odds\right)}$$

$$p=\left(1-p\right)e^{\ln\left(odds\right)}$$

© 2025 Olivier Claerbout

Theorie en intuïtie

- Eerste stap voor maximum likelihood is teruggaan van ln(odds) naar kansen

$$p=(1-p)e^{\ln(odds)}$$

$$p=e^{\ln(odds)}-pe^{\ln(odds)}$$

$$p+pe^{\ln(odds)}=e^{\ln(odds)}$$

© 2025 Olivier Claerbout

Theorie en intuïtie

- Eerste stap voor maximum likelihood is teruggaan van ln(odds) naar kansen

$$p+pe^{\ln(odds)}=e^{\ln(odds)}$$

$$p\left(1+e^{\ln(odds)}\right)=e^{\ln(odds)}$$

$$p=\frac{e^{\ln(odds)}}{1+e^{\ln(odds)}}$$

© 2025 Olivier Claerbout

Theorie en intuïtie

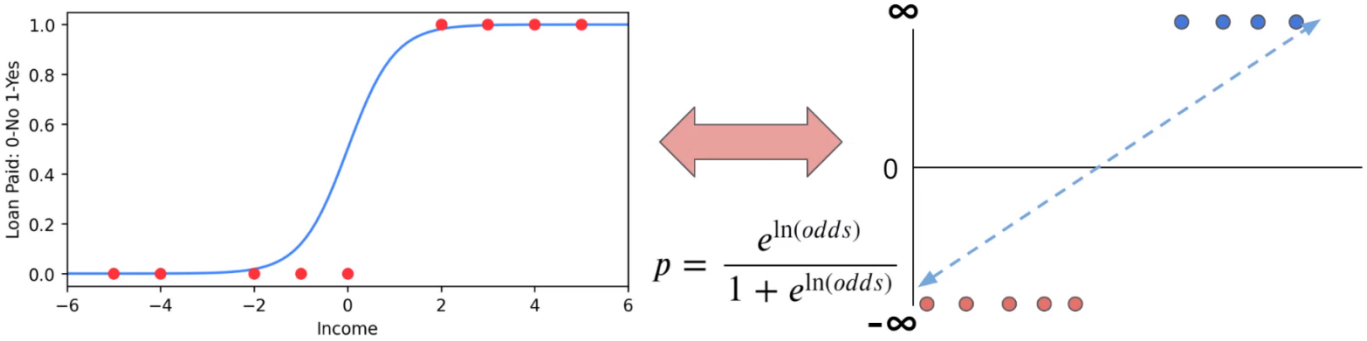
- Eerste stap voor maximum likelihood is teruggaan van ln(odds) naar kansen

$$p = \frac{e^{\ln(odds)}}{1 + e^{\ln(odds)}}$$

© 2025 Olivier Claerbout

Theorie en intuïtie

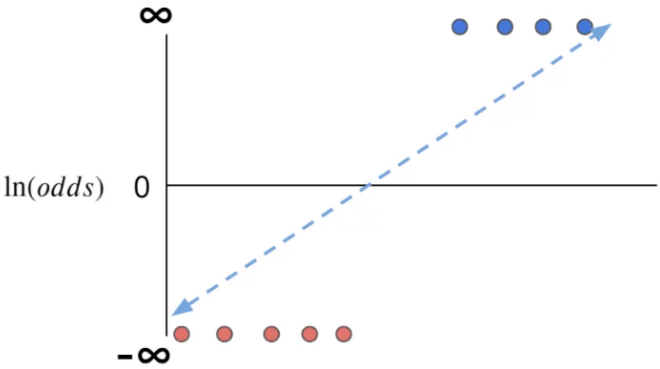
- We kunnen nu ln(odds) omrekenen naar een kans!



© 2025 Olivier Claerbout

Theorie en intuïtie

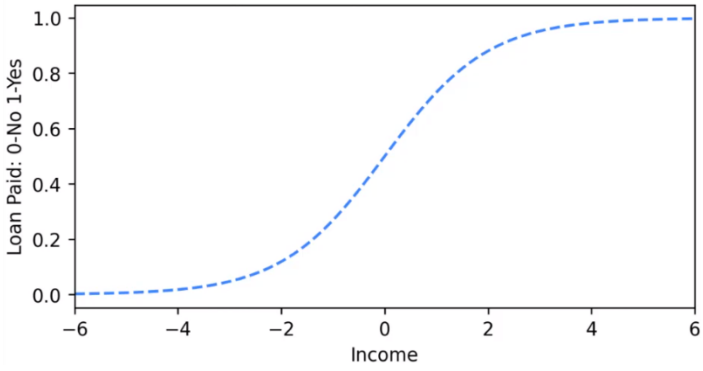
- Max likelihood bepalen:
  - Kies een lijn in de ln(odds) as en projecteer de punten op de lijn

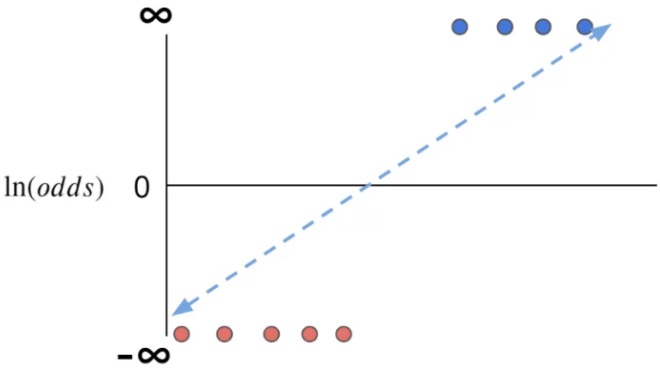


© 2025 Olivier Claerbout

Theorie en intuïtie

- We weten dat deze lijn een bepaalde vorm heeft op de “kansen” y-as:



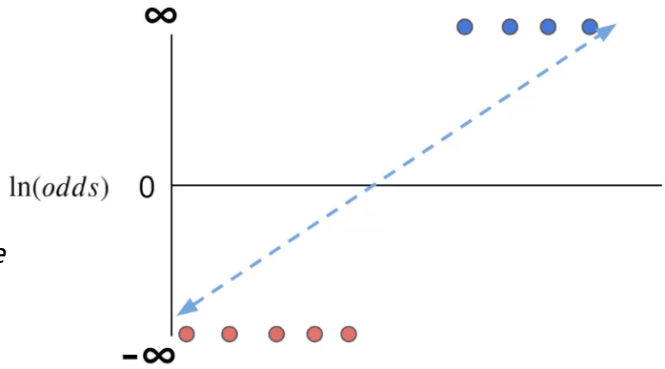


© 2025 Olivier Claerbout

Theorie en intuïtie

- Max likelihood bepalen:
  - Kies een lijn in de ln(odds) as en projecteer de punten op de lijn

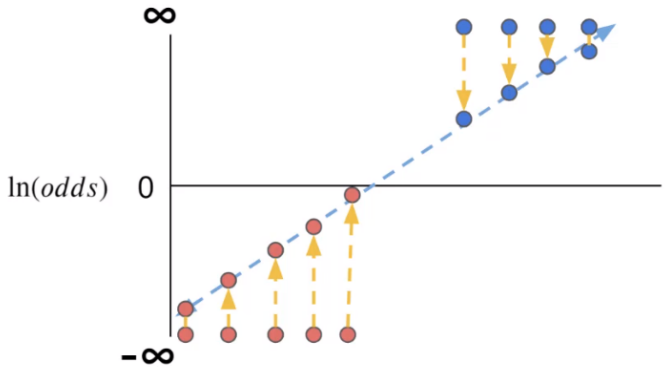
We nemen de bij de datapunten horende x waarde en projecteren die op de lijn



© 2025 Olivier Claerbout

Theorie en intuïtie

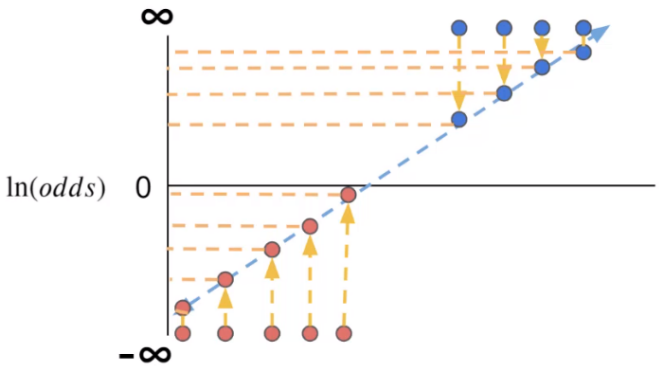
- Max likelihood bepalen:
  - Kies een lijn in de ln(odds) as en projecteer de punten op de lijn



© 2025 Olivier Claerbout

Theorie en intuïtie

- Max likelihood bepalen:
  - Bereken de ln(odds) voor de op de lijn geprojecteerde punten

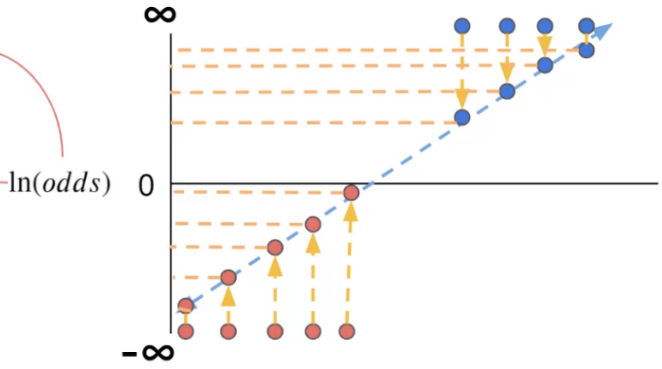


© 2025 Olivier Claerbout

Theorie en intuïtie

- Max likelihood bepalen:
  - Plug deze ln(odds) waarden in de eerder geziene formule om kansen te berekenen

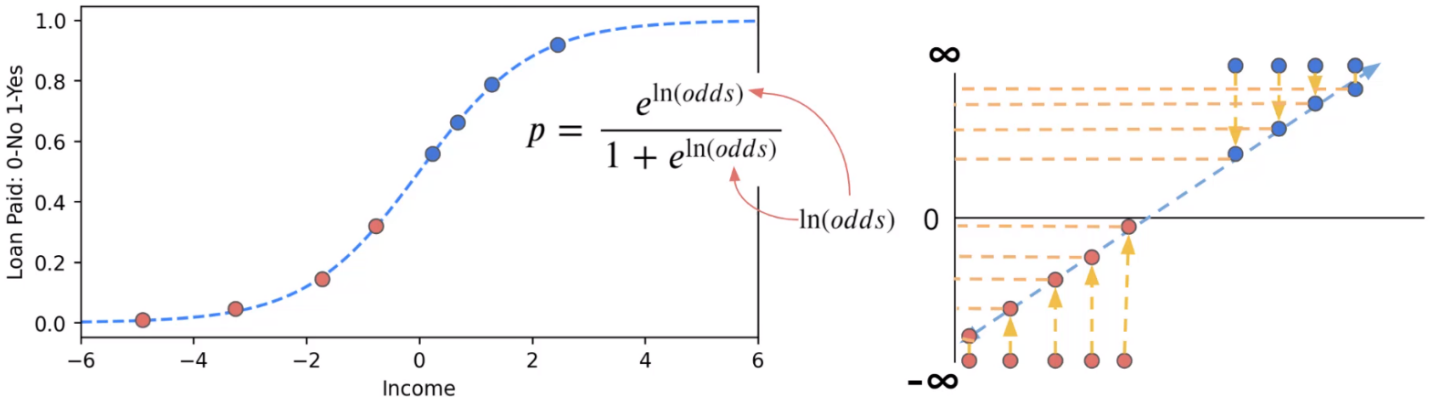
$$p = \frac{e^{\ln(odds)}}{1 + e^{\ln(odds)}}$$



© 2025 Olivier Claerbout

Theorie en intuïtie

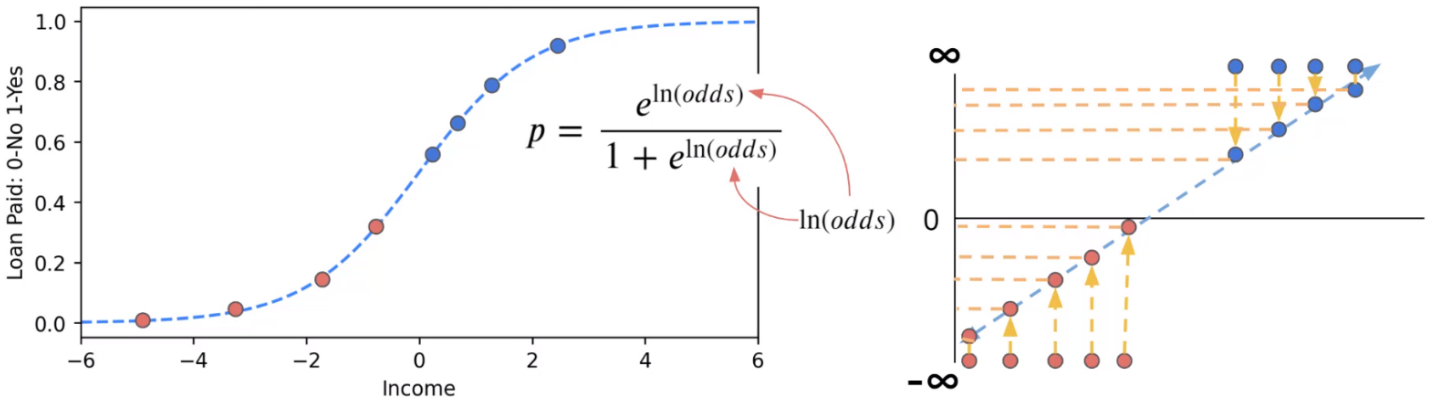
- Neem deze kansen en zet ze uit op het logistisch regressiemodel



© 2025 Olivier Claerbout

Theorie en intuïtie

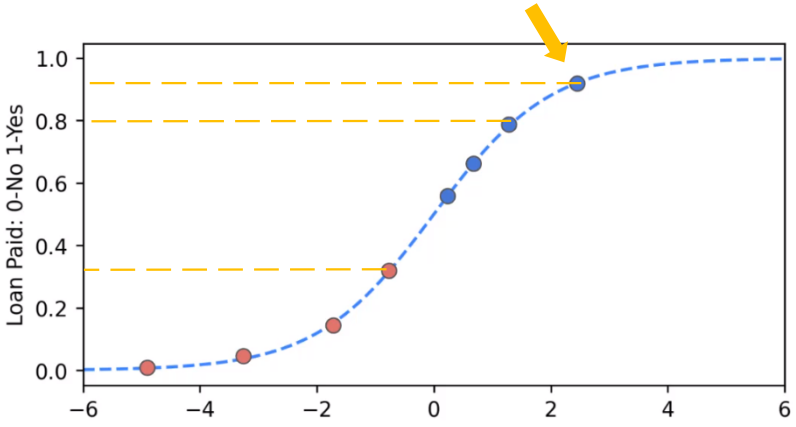
- We meten nu de waarschijnlijkheden voor deze kansen



© 2025 Olivier Claerbout

Theorie en intuïtie

- Waarschijnlijkheid = Product van de kansen om tot klasse 1 te behoren.



Waarschijnlijkheid = 0,9 ...
Waarschijnlijkheid = 0,9 * 0,8

Waarschijnlijkheid = 0,9 * 0,8 * 0,65 * ... *(1-0,35) * ...

*Perfecte fit: 1*1*1*1...*

© 2025 Olivier Claerbout

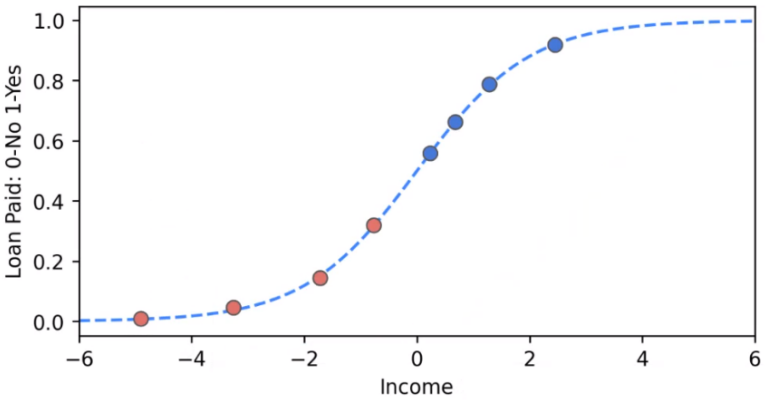
Theorie en intuïtie

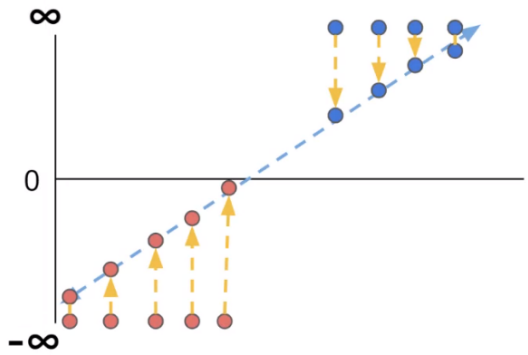
- Er bestaat een set θ coëfficiënten die de waarschijnlijkheden maximaliseert!
- Kies de beste coëfficiënten in ln(odds) termen die de maximum likelihood representeert inzake het voorspellen van de juiste klasse van de datapunten

© 2025 Olivier Claerbout

Theorie en intuïtie

- Er bestaat een set θ coëfficiënten die de waarschijnlijkheden maximaliseert!

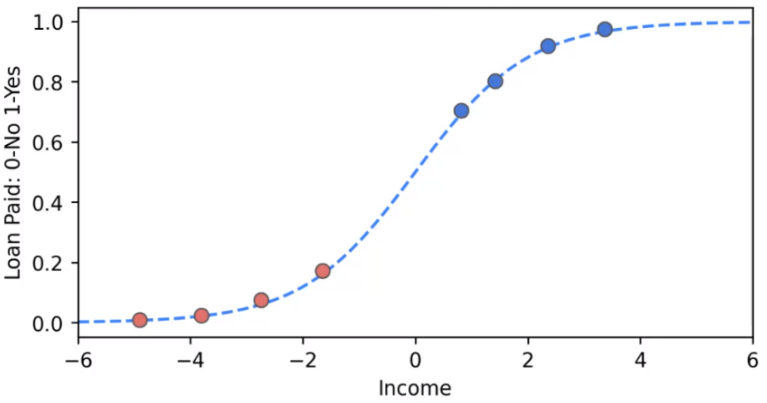


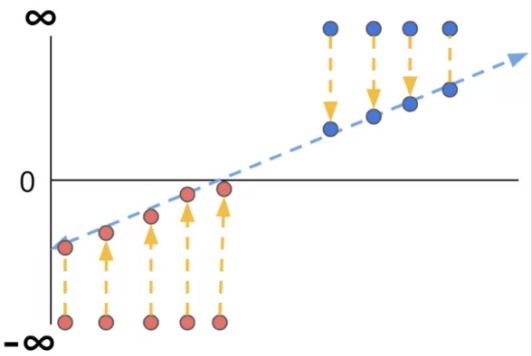


© 2025 Olivier Claerbout

Theorie en intuïtie

- Er bestaat een set θ coëfficiënten die de waarschijnlijkheden maximaliseert!





Maak werk van je toekomst
© 2025 Olivier Claerbout
SYNTRA ANTWERPEN & VLAAMS-BRABANT

Theorie en intuïtie

- Concept is zelfde als bij Lineaire Regressie, maar nu maximaliseren we de waarschijnlijkheden (de correctheid) van de voorspellingen van de klasses in plaats van het minimaliseren van de kwadratensom.
- Gradient Descent minimaliseert een verliesfunctie, dus we hebben een functie nodig om te minimaliseren!

© 2025 Olivier Claerbout

Theorie en intuïtie

- Concept is zelfde als bij Lineaire Regressie, maar nu maximaliseren we de waarschijnlijkheden (de correctheid) van de voorspellingen van de klasses in plaats van het minimaliseren van de kwadratensom.
- Gradient Descent minimaliseert een verliesfunctie, dus we hebben een functie (‘log loss’) nodig om te minimaliseren!

$$J(\mathbf{x}) = -\frac{1}{m}\sum_{j=1}^{m} y^j \log\left(\hat{y}^j\right) + (1-y^j)\log\left(1-\hat{y}^j\right)$$

$$J(\mathbf{x}) = -\frac{1}{m}\sum_{j=1}^{m}\left(y^j \log\left(\frac{1}{1+e^{-\sum_{i=0}^{n}\beta_i x_i^j}}\right) + (1-y^j)\log\left(1-\frac{1}{1+e^{-\sum_{i=0}^{n}\beta_i x_i^j}}\right)\right)$$

© 2025 Olivier Claerbout

Theorie en intuïtie

- Deze gradient descent hoef je zelf nooit te implementeren en is dus weinig relevant
- Belangrijkste om mee te nemen is de relatie tussen log odds en waarschijnlijkheid

© 2025 Olivier Claerbout

Logistische Regressie

Logistische Regressie in Scikit-Learn

© 2025 Olivier Claerbout