Unsupervised Learning



© 2025 *Olivier Claerbout*

Lesmateriaal

- Via GitHub account
- © 2025 Olivier Claerbout

  Dit materiaal mag niet worden gekopieerd, verspreid, gepubliceerd of anderszins gereproduceerd zonder uitdrukkelijke schriftelijke toestemming van de auteur. Dit geldt eveneens voor de Jupyter Notebooks!

© 2025 *Olivier Claerbout*

Overzicht

- Intro to unsupervised learning
- The challenge of unsupervised learning
- The curse of dimensionality
- PCA – Principal Components Analysis

© 2025 *Olivier Claerbout*

Intro to unsupervised learning

© 2025 *Olivier Claerbout*

Unsupervised learning

- Supervised Learning
  - Op basis van gelabelde data een voorspelling doen (regressie of classificatie)
- Unsupervised Learning
  - Op basis van ongelabelde data patronen, clusters of belangrijke componenten ontdekken
  - We weten “het juiste antwoord” niet, we hebben enkel features!

© 2025 Olivier Claerbout

Unsupervised learning

- Unsupervised Learning – opsplitsing:
  - Clustering
    - Features gebruiken om data te groeperen in clusters
  - Dimensionality Reduction
    - Features gebruiken om te combineren en ontdekken hoe we het aantal componenten kunnen reduceren

© 2025 Olivier Claerbout

Unsupervised learning

- Supervised learning performantiestatistieken die we gezien hebben (RMSE, Accuracy,...) kunnen hier niet worden gebruikt!
- Hoe kunnen we vergelijken met een “correct” label als er geen label is?

© 2025 *Olivier Claerbout*

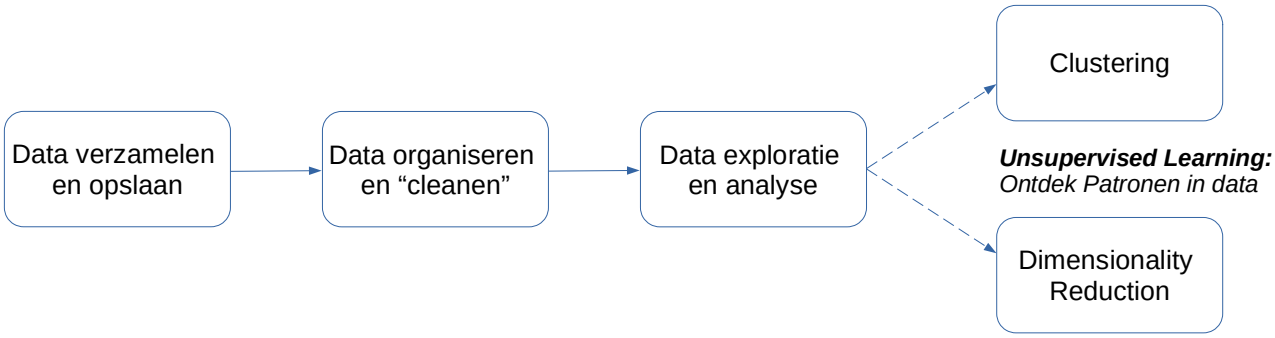
Unsupervised learning

- We moeten nieuwe manieren ontdekken om de performantie van een unsupervised model te evalueren
- Ons idee van “performantie” moet worden aangepast met unsupervised learning!

© 2025 *Olivier Claerbout*

Unsupervised learning

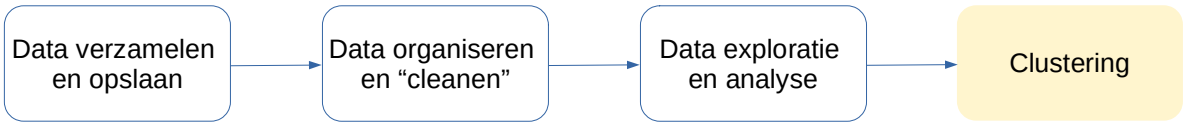
- Het Unsupervised Learning pad



© 2025 Olivier Claerbout

Unsupervised learning

- Clustering

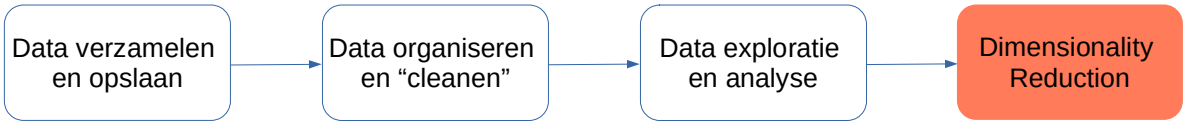


Clustering: *indien we ongelabelde data hebben, kunnen we dan gelijkaardige datapunten clusteren of groeperen om mogelijke cluster “labels” te ontdekken?*

© 2025 Olivier Claerbout

Unsupervised learning

- Dimensionality Reduction



Dimensionality Reduction: *indien we ongelabelde data hebben, kunnen we dan het aantal features reduceren door hen te combineren in nieuwe componenten? Geven deze nieuwe componenten ons verder inzicht in de data?*

© 2025 *Olivier Claerbout*

K-Means Clustering

© 2025 *Olivier Claerbout*

K-Means Clustering

- Overzicht:
  - Clustering?
  - Achtergrond en intuïtie van K-Means Clustering
  - Wiskundige achtergrond K-Means Clustering
  - Voorbeeld
  - Oefening

© 2025 *Olivier Claerbout*

K-Means Clustering

- Opgepast:
  - *Verwar K-Means (unsupervised) niet met KNN (K Nearest Neighbors - supervised)!*
  - *De 'K' is compleet verschillend voor beide algoritmes, de problemen die deze algoritmes oplossen zijn compleet verschillend en er is geen enkele vorm van gelijkenis tussen beide algoritmes!*

© 2025 *Olivier Claerbout*

Clustering

© 2025 Olivier Claerbout

Clustering - algemeen

- Clustering gebruikt ongelabelde data en zoekt naar gelijkenissen tussen groepen (clusters) om de data op te delen in verschillende clusters
- Opgepast: we kennen het “echte label” van de data niet!

© 2025 Olivier Claerbout

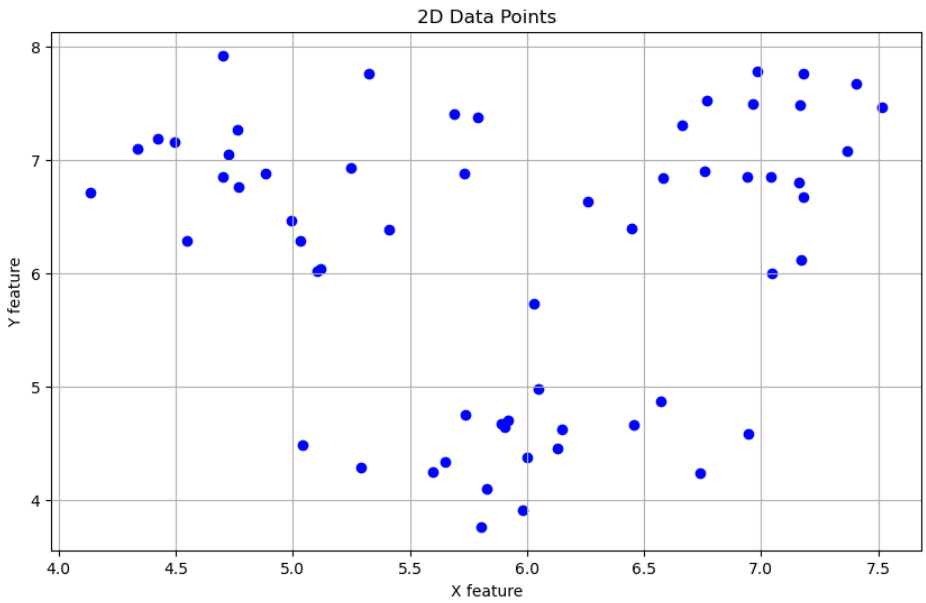
Clustering - algemeen

- Hoe zouden we data kunnen clusteren?
- Plotten data?

© 2025 Olivier Claerbout

Clustering - algemeen

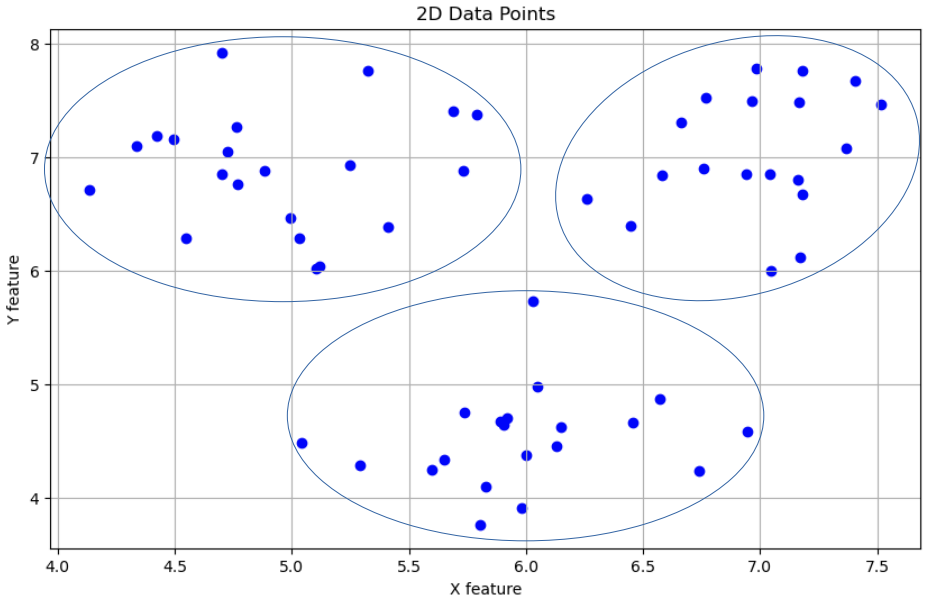
- Clusters? Hoeveel?



© 2025 Olivier Claerbout

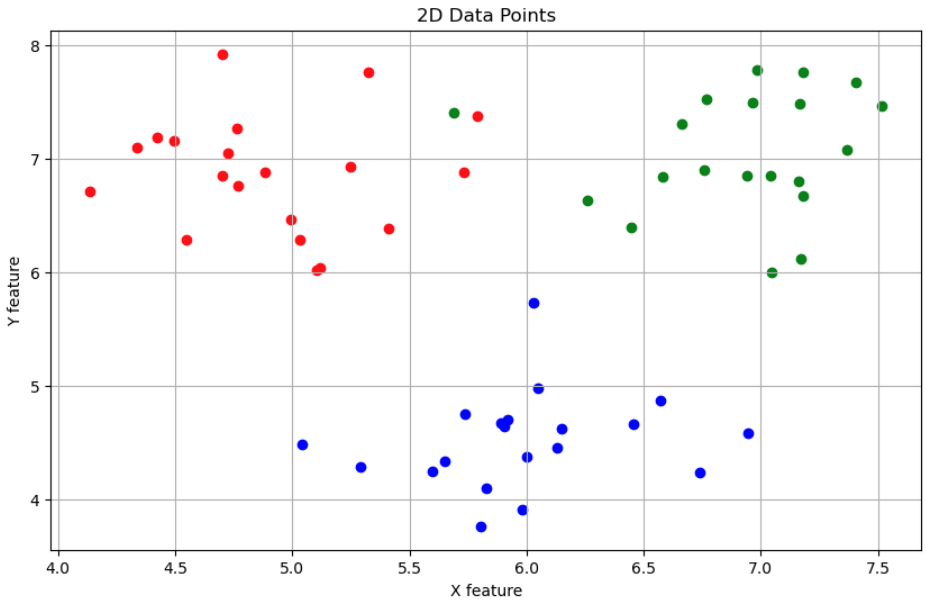
Clustering - algemeen

- Intuïtief zien we 3 groepen, maar we weten dit niet zeker!
- Afstand is onze intuïtieve parameter
- Zo kunnen we clusters “toewijzen” en een y-label toekennen



© 2025 Olivier Claerbout

Clustering - algemeen



© 2025 Olivier Claerbout

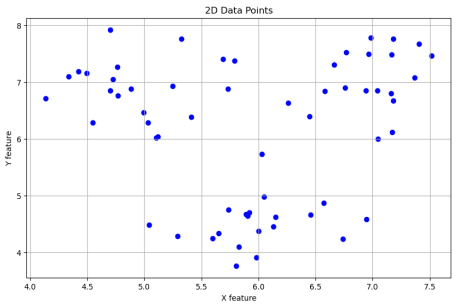
Clustering - algemeen

- We weten niet zeker of de manier waarop we gegroepeerd hebben de juiste is aangezien er geen y-label aanwezig is
- Wat indien het niet zo duidelijk is, of we met multi-dimensionale data te maken hebben?

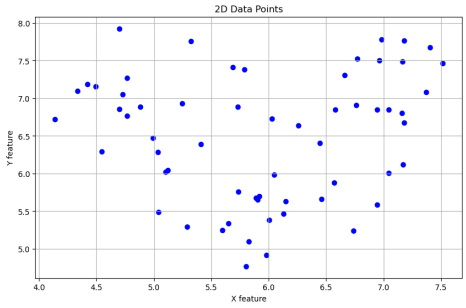
© 2025 Olivier Claerbout

Clustering - algemeen

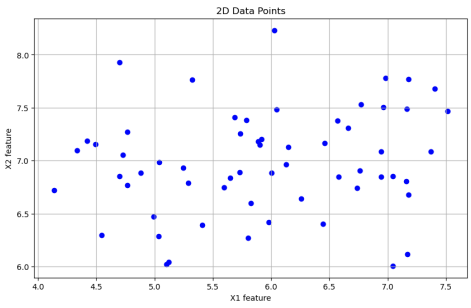
Stel in vorige voorbeeld dat de gemiddelde x2 waarde wijzigt (y as in grafiek):



4,5



5,5



7

© 2025 Olivier Claerbout

Clustering - algemeen

- Verschillende methodes worden gebruikt om het aantal clusters te bepalen. Sommige methoden doen dit voor jou, andere methoden verwachten een # van de gebruiker.
- Clustering ≠ labeling! Er komen geen labelnamen uit maar “Group:0, Group:1,…”
- Je moet zelf op basis van de data bepalen wat de logische clusters zijn

© 2025 *Olivier Claerbout*

Clustering - algemeen

- Idee achter clusteren:
  - Gebruik features om te beslissen welke punten meeste onderlinge gelijkenis hebben
  - Besef dat er geen finaal correct y-label is om de resultaten mee te vergelijken
  - Beschouw clustering als een unsupervised learning proces wat potentiële labels kan “ontdekken”

© 2025 *Olivier Claerbout*

Clustering - algemeen

- Fundamentele wijziging:
  - Wat met een nieuw ongelabeld datapunt?
  - Hoe wijzen we dit aan een cluster toe?
  - Was de toegewezen cluster de juiste?

© 2025 Olivier Claerbout

Clustering - algemeen

- Hoe wijzen we dit aan een cluster toe?
  - Verschillende manieren, afhankelijk van het algoritme
  - Gebruik features om punt aan de meest geschikte cluster toe te wijzen

Er is geen manier om te meten of de toewijzing correct is gebeurd!

© 2025 Olivier Claerbout

Clustering - algemeen

- Hoe wijzen we dit aan een cluster toe?
  - Als we cluster labels hebben toegewezen, kunnen we deze labels gebruiken om supervised learning toe te passen?

Ja! We kunnen unsupervised learning gebruiken om mogelijke labels te ontdekken, en vervolgens supervised learning toepassen op nieuwe datapunten.

Maar is dit geen oefening? Er is geen manier om na te gaan wat de cluster labels voorstellen. Er is geen manier om na te gaan of deze clusters echt significant zijn.

© 2025 Olivier Claerbout

Clustering - algemeen

- Concepten die we nog gaan bespreken:
  - Hoe beslissen we het optimaal aantal clusters?
  - Beslissen wij hierover? Of laten we het algoritme beslissen?
  - Hoe kunnen we bepalen hoe goed het model is zonder een **y** label om mee te vergelijken?

© 2025 Olivier Claerbout

Clustering - algemeen

- Om over na te denken:
  - Wat is de grondwaarheid (“ground truth”)?
  - Welke trade-offs maken we door unsupervised learning te gebruiken in plaats van het echte y label dat niet gegeven is?

    → *Houd dit in gedachten bij het ontdekken van de verschillende cluster-algoritmes!*

    → *Bedenk ook dat het veel moeilijker is om unsupervised learning algoritmes met elkaar te vergelijken omwille van het ontbreken van performantiestatistieken die zijn gebaseerd op de grondwaarheid (vb accuracy, RMSE)*

© 2025 Olivier Claerbout

K-Means Clustering

© 2025 Olivier Claerbout

K-Means Clustering

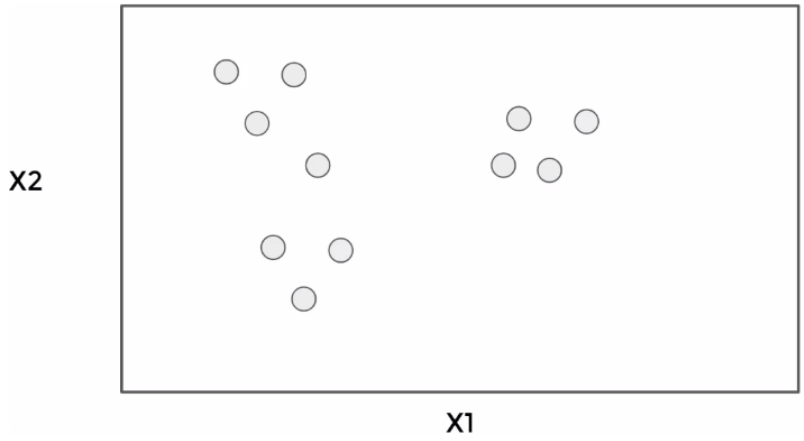
- Zeer populaire clustering techniek door zijn eenvoud
- ***Elk*** datapunt ***moet*** behoren tot ***één*** cluster
- Gelijkenis wordt uitgedrukt via een afstandsfunctie:
  - Hoe dicht liggen training samples van elkaar in de feature space?
  - Veel gebruikte afstandsmaat is de Euclidische afstand

Hoe werkt K-Means clustering?

© 2025 Olivier Claerbout

K-Means Clustering

- Voorstel werking met 2 features x1 en x2
- Stap 0: start met ongelabelde data (enkel features):

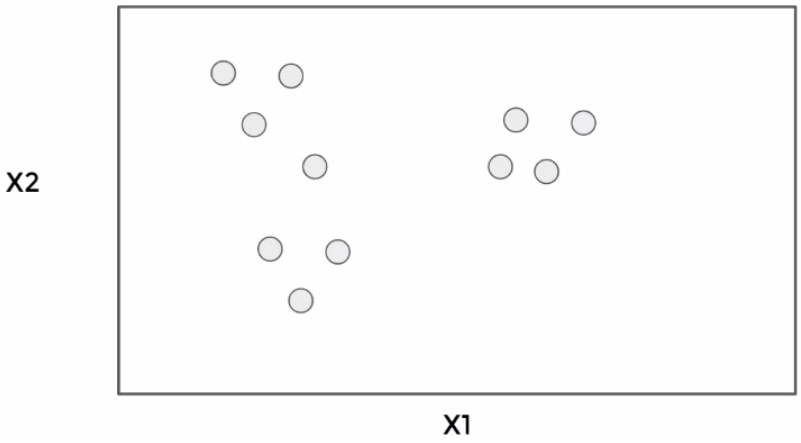


© 2025 Olivier Claerbout

K-Means Clustering

- Stap 1: Kies het aantal clusters (“K waarde”)

Stel K = 3. Opgepast: normaal kan je data niet visualiseren!

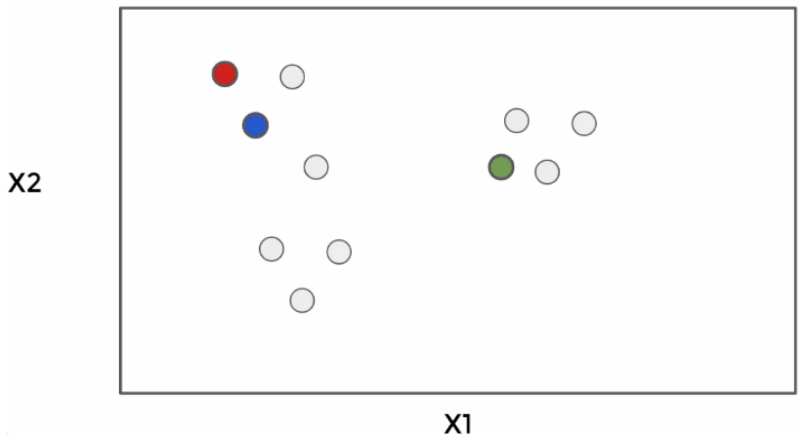


© 2025 Olivier Claerbout

K-Means Clustering

- Stap 2: Selecteer random K afzonderlijke datapunten

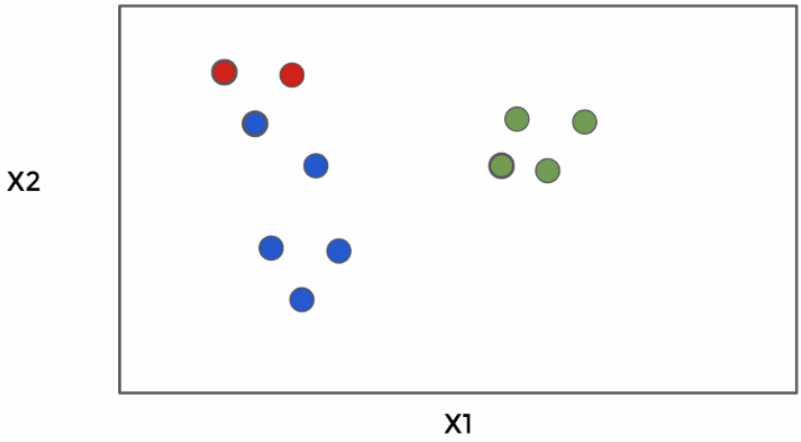
We behandelen deze K punten als de middelpunten van de clusters (‘centroïden’)



© 2025 Olivier Claerbout

K-Means Clustering

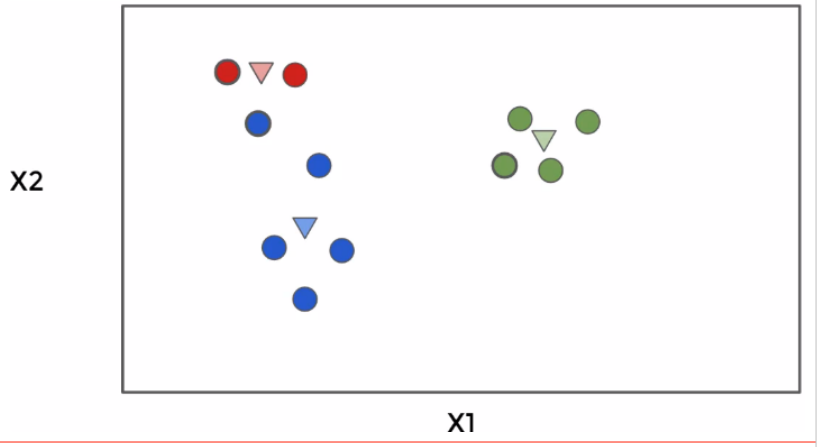
- Stap 3: Wijs elk resterend punt toe aan de dichtstbij liggende centroïde



© 2025 Olivier Claerbout

K-Means Clustering

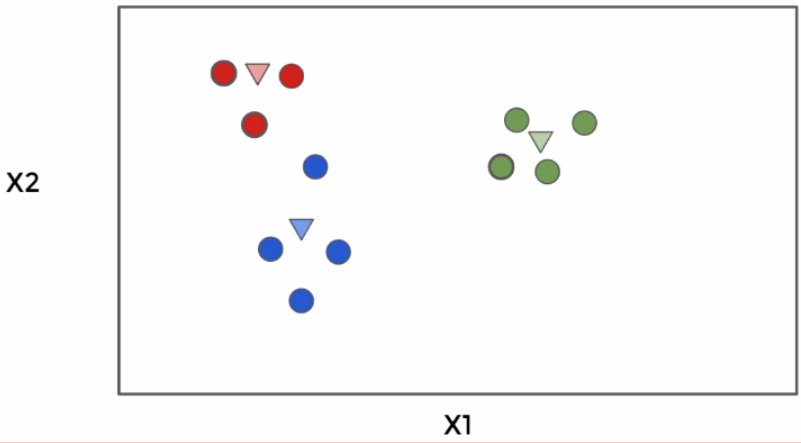
- Stap 4: Bereken het centrum van elke cluster (gemiddelde v/d puntvectoren)



© 2025 Olivier Claerbout

K-Means Clustering

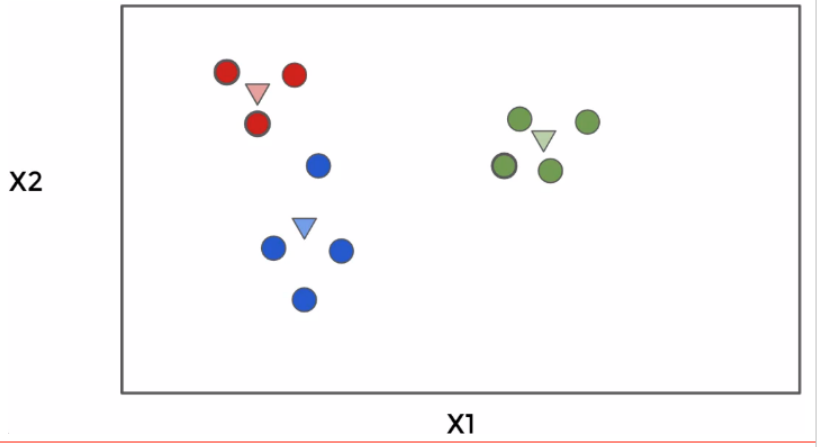
- Stap 5: Wijs elk punt toe aan de dichtstbijliggende centroïde



© 2025 Olivier Claerbout

K-Means Clustering

- Herhaal stappen 4 (berekenen centroïde) en 5 (toewijzen punten aan dichtste centroïde) tot er geen punten meer veranderen van cluster



© 2025 Olivier Claerbout

K-Means Clustering

- Hoe bepalen we een redelijke waarde voor het aantal clusters K?
- Is er een manier om te evalueren hoe goed onze huidige K waarde is?
- We gaan dit ontdekken via een praktisch voorbeeld!

© 2025 *Olivier Claerbout*

K-Means Clustering

Notebook: 00-Kmeans-Clustering.ipynb

© 2025 *Olivier Claerbout*

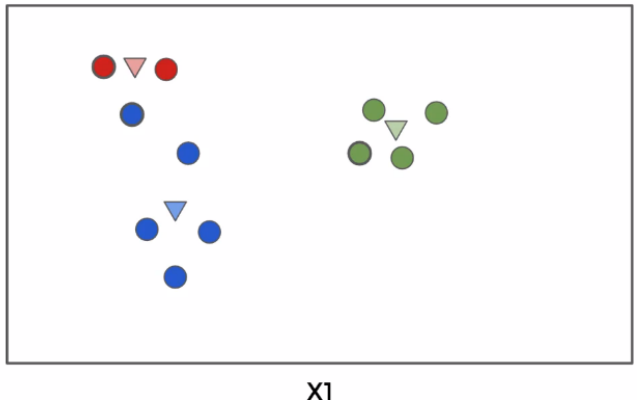
K-Means Clustering

- Hoe kunnen we nu een “redelijke” waarde voor het aantal clusters K kiezen?
- Is er een manier waarop we kunnen evalueren hoe goed de gekozen waarde voor K is?
- Hoe kunnen we de “goodness of fit” meten?

© 2025 Olivier Claerbout

K-Means Clustering

- Hier hebben we 3 clusters. Hoe weten we hoe goed het model met 3 clusters is?
- We kunnen de som van de afstanden van de punten tot hun centroïde meten!
- Sum of Squared Distances

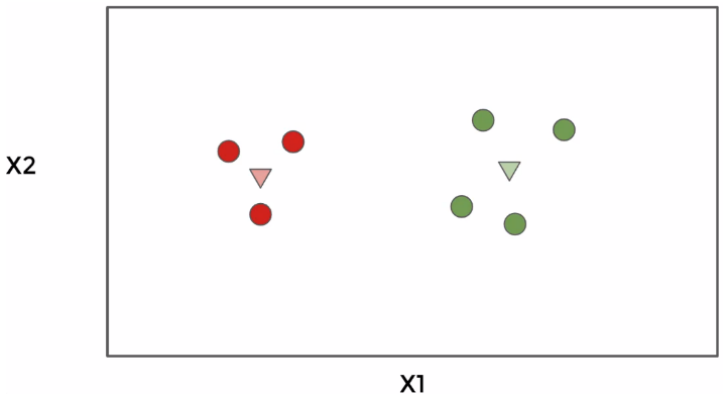


© 2025 Olivier Claerbout

K-Means Clustering

- Stel een model met K = 2
- We meten de som van de gekwadrateerde afstanden van punten tot hun centroïde

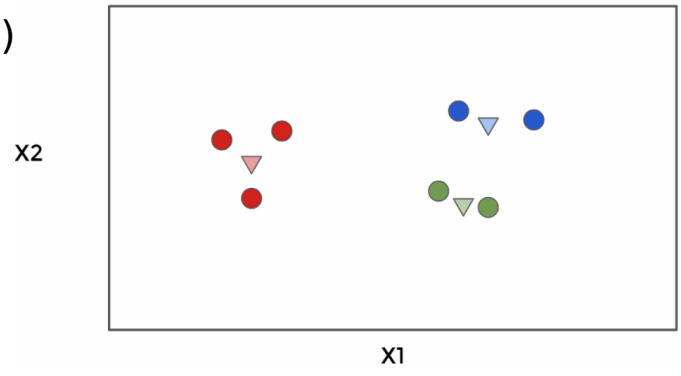
  ~ Hoe “dicht opeengepakt” zijn items in de cluster? Hoe beter de cluster, hoe lager deze waarde



© 2025 Olivier Claerbout

K-Means Clustering

- Volledig nieuw Kmeans model met K+1
- Bepaal opnieuw de SSD tot de centroïde
- Gaat altijd omlaag!
- SSD = 0 als K = n (1 cluster/punt)
- We minimaliseren SSD niet!



© 2025 Olivier Claerbout

K-Means Clustering

- We volgen de SSD waarde op voor een range van K waarden
- SSD daalt met toenemende K
- We zoeken naar een K waarde waar reductie van SSD begint af te nemen
- Dit betekent dat het toevoegen van een extra cluster onvoldoende meerwaarde in scheiding tussen clusters brengt

© 2025 *Olivier Claerbout*

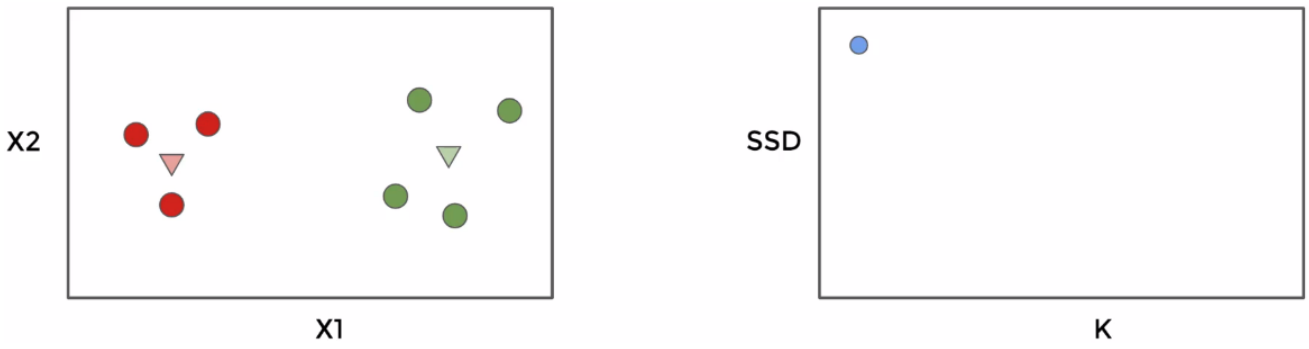
K-Means Clustering

- Dit is gekend als de elleboog methode aangezien je kan zien waar de afname van SSD uitvlakt met toenemende K
- Hoe zou dit er grafisch uitzien?

© 2025 *Olivier Claerbout*

K-Means Clustering

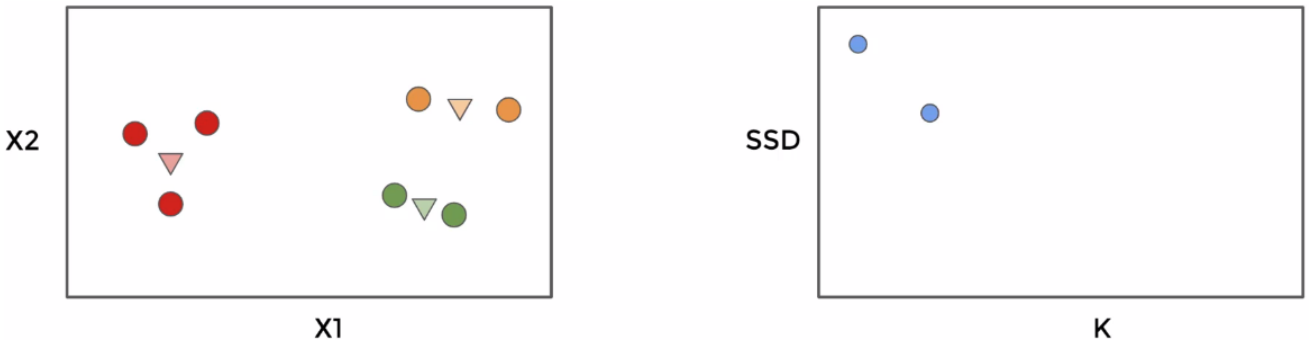
- Start met K = 2



© 2025 Olivier Claerbout

K-Means Clustering

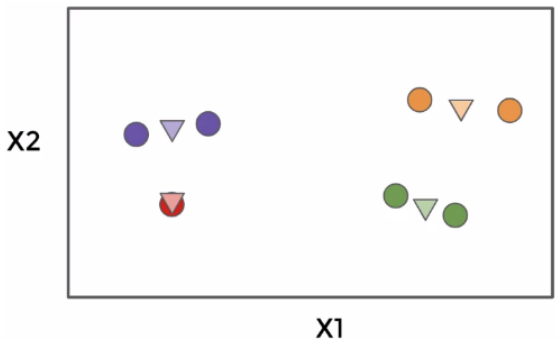
- Verhoog K en bepaal opnieuw SSD:

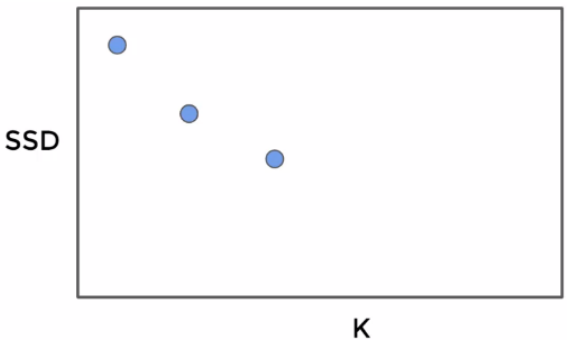


© 2025 Olivier Claerbout

K-Means Clustering

- Verhoog K en bepaal opnieuw SSD:

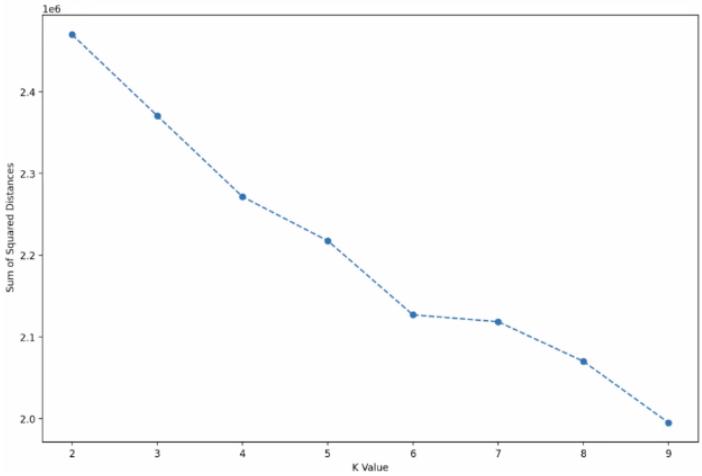




© 2025 Olivier Claerbout

K-Means Clustering

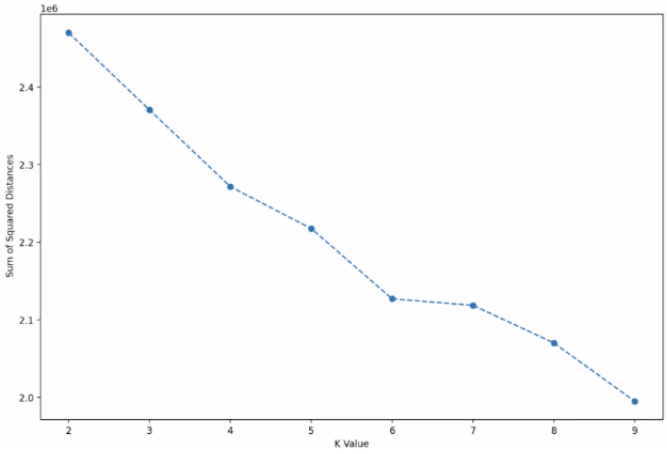
- Herhaal dit K keer. Je ziet een voortdurende afname van SSD:



© 2025 Olivier Claerbout

K-Means Clustering

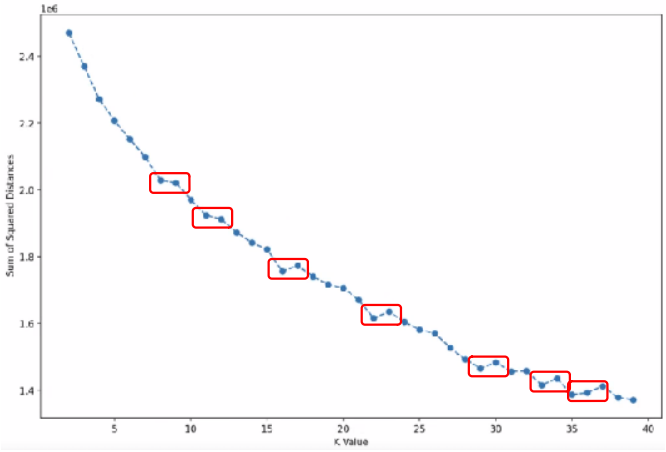
- Er zit een ‘knik’ bij overgang van K = 4 naar K = 5
- Idem van 6 naar 7
- Dit zijn “elleboog” punten



© 2025 Olivier Claerbout

K-Means Clustering

- Er is geen “juist antwoord”: het hangt af van hoeveel clusters je wenst
- Op zo’n punt reduceer je SSD slechts weinig door toevoegen van een extra cluster
- Je *kiest* een redelijke K vb 6 of 16 of 23 ...



© 2025 Olivier Claerbout

K-Means Clustering

- Deze punten zijn sterke indicatoren dat het verder verhogen van K niet langer gerechtvaardigd is
- Je kan SSD ook in een barplot weergeven
- Laat ons dit bekijken in de code!

© 2025 *Olivier Claerbout*

K-Means Clustering

Notebook: 00-Kmeans-Clustering.ipynb

© 2025 *Olivier Claerbout*

K-Means Clustering – Color Quantization

- Unsupervised Learning biedt mogelijkheden voor heel creatieve use cases
- Een interessante applicatie van clustering is “image quantization”
- We bekijken afbeeldingen, computers, kleuren en kwantisatie om een idee te krijgen hoe K Means clustering kan worden toegepast in verschillende domeinen

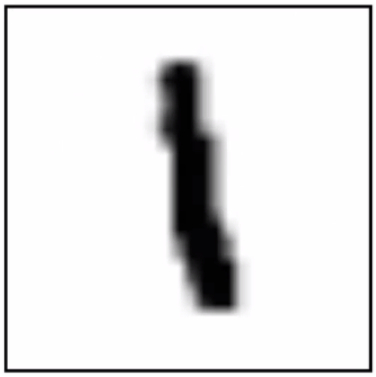
© 2025 Olivier Claerbout

K-Means Clustering – Color Quantization

- Dit stelt een afbeelding van een penstreek voor:

Deze afbeelding is in zwart wit, wat betekent dat
De kleurenrange van zwart naar wit gaat (grayscale)

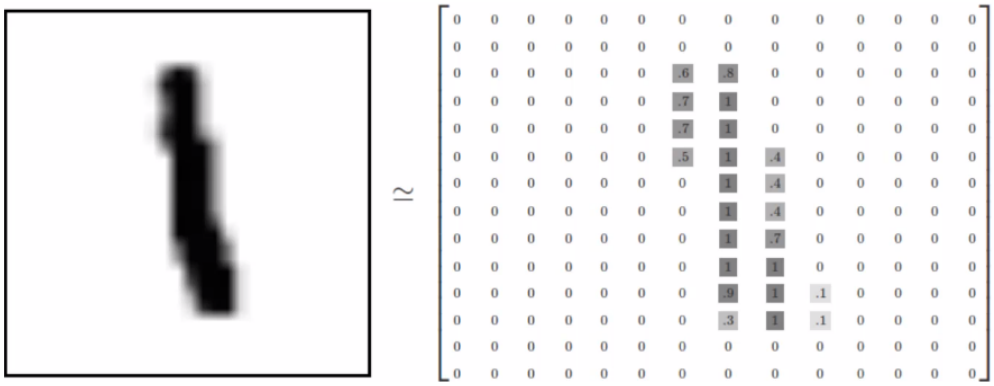
De computer slaat dit op als een array met waarden
die zich in een bepaalde range bevinden



© 2025 Olivier Claerbout

K-Means Clustering – Color Quantization

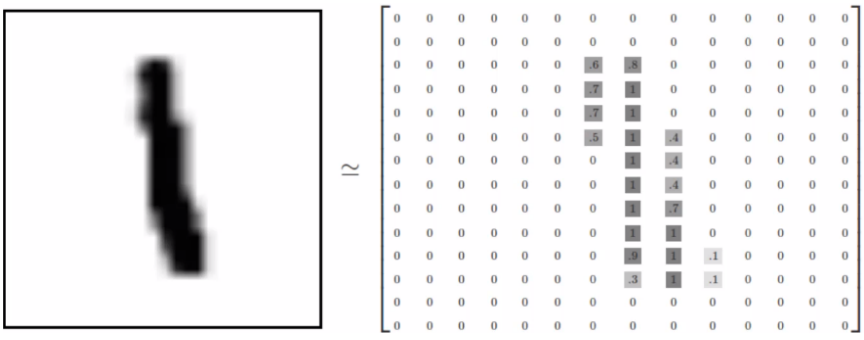
- 0 is wit en 1 is zwart, en waarden ertussen stellen grijs voor



© 2025 Olivier Claerbout

K-Means Clustering – Color Quantization

- Computers slaan ook vaak waarden van 0 tot 255 op (8-bit nummers)
- Normalisatie gebeurt door alle waarden te delen door 255

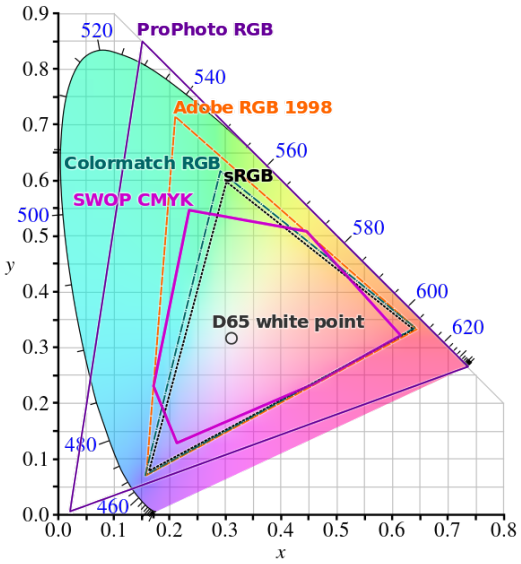


© 2025 Olivier Claerbout

K-Means Clustering – Color Quantization

- Hoe worden afbeeldingen in kleur opgeslagen?
  → Als combinatie van Rood, Groen en Blauw
- Combinaties ervan vormen een groot aantal kleuren
- Er bestaan verschillende RGB kleurruimtes





© 2025 Olivier Claerbout

K-Means Clustering – Color Quantization

- We hebben nu 3 afzonderlijke waarden, elk in 0-255 range
- Combinaties ervan vormen een specifiek kleur



© 2025 Olivier Claerbout

K-Means Clustering – Color Quantization

- Voor de computer zijn er nu 3 arrays, die elk een kleurkanaal vertegenwoordigen
- Bijvoorbeeld: een enkele pixel heeft 3 waarden: 1 voor Rood, 1 voor Groen, 1 voor Blauw – hieronder (58, 46, 34) voor (R, G, B)



© 2025 Olivier Claerbout