# Unsupervised Learning




© 2025 *Olivier Claerbout*




# Lesmateriaal

- Via GitHub account
- © 2025 Olivier Claerbout

  *Dit materiaal mag niet worden gekopieerd, verspreid, gepubliceerd of anderszins gereproduceerd zonder uitdrukkelijke schriftelijke toestemming van de auteur. Dit geldt eveneens voor de Jupyter Notebooks!*


© 2025 *Olivier Claerbout*

# Overzicht

- Kmeans Clustering
- **Hierarchisch Clusteren**
- PCA – Principal Components Analysis


© 2025 *Olivier Claerbout*




# Hierarchisch Clusteren


© 2025 *Olivier Claerbout*

# Hierarchisch Clusteren

- Vaak gebruikt in biologie
- Heel visueel
- Helpt beslissen inzake *aantal* clusters

- Topics:
  - *Theorie & intuïtie*
  - *Voorbeeld*


© 2025 *Olivier Claerbout*




# Hierarchisch Clusteren

- Hiërarchisch Clusteren berust op meten van similariteit tussen datapunten
- Similariteit wordt opnieuw uitgedrukt middels een afstandsmaat


© 2025 *Olivier Claerbout*

# Hierarchisch Clusteren

- Waarom Hiërarchisch Clusteren?
  - Eenvoudig te begrijpen en visualiseren
  - Visuele hulp om het aantal clusters te bepalen
  - Geen gewenst aantal clusters op te geven voor je begint *(itt Kmeans!)*


© 2025 Olivier Claerbout




# Hierarchisch Clusteren

Waarom Hiërarchisch Clusteren?

- Het creëert alle potentiële clusters en visualiseert deze
- Op basis hiervan kan je kiezen wat een redelijk aantal is
- Dit kan op 2 manieren gebeuren:
  - *"Agglomeratieve Methode" (meest gebruikt):*

    *Deze methode begint met elk datapunt als afzonderlijke cluster en voegt deze clusters geleidelijk samen tot één enkele cluster ("bottom-up")*
  - *"Divisieve Methode":*

    *Deze methode begint met alle datapunten in één enkele cluster en splitst deze geleidelijk op in kleinere clusters ("top-down")*


© 2025 Olivier Claerbout

# Hierarchisch Clusteren

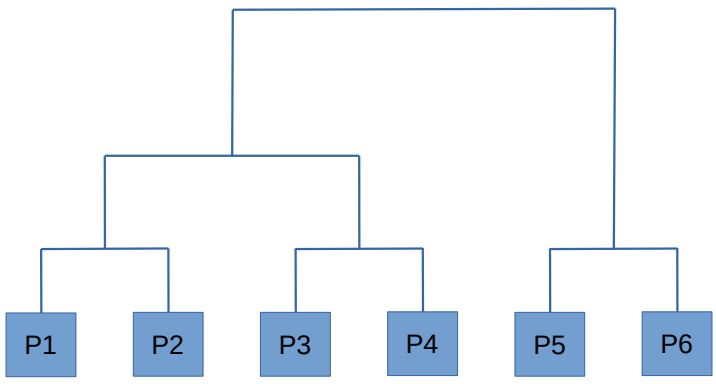
- Agglomeratief clusteren:
  - Start met datapunten
  - Bereken similariteit
  - Voeg de meeste gelijkaardige punten samen
  - Bepaal similariteit tussen clusters en voeg samen
  - ...


© 2025 Olivier Claerbout




# Hierarchisch Clusteren

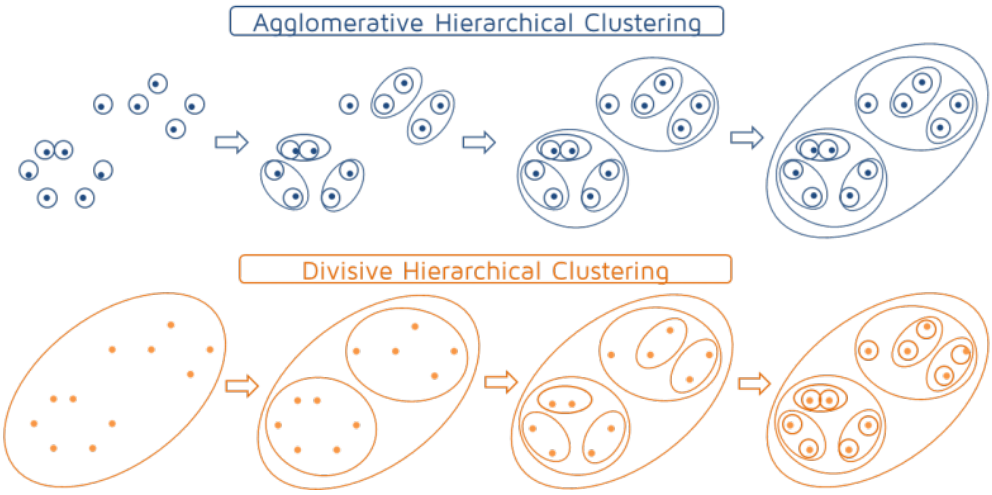
- Dendrogram: *(vb via agglomeratief clusteren)*





© 2025 Olivier Claerbout

# Hierarchisch Clusteren





© 2025 Olivier Claerbout



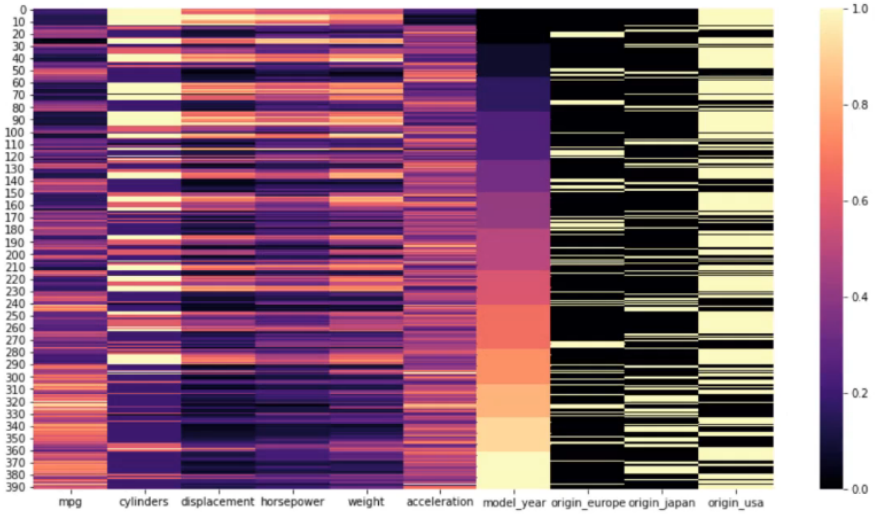

# Hierarchisch Clusteren

- Hiërarchisch Cluster Proces:
  - Vergelijk datapunten om de meest gelijkende punten te vinden
  - Voeg deze punten samen in een cluster
  - Vergelijk clusters om de meest gelijkende clusters te vinden
  - Voeg deze clusters samen tot een overkoepelende cluster
  - Herhaal dit tot alle punten zich in één cluster bevinden


© 2025 Olivier Claerbout

# Hierarchisch Clusteren

- Voorbeeld voor de mpg (miles per gallon) dataset:

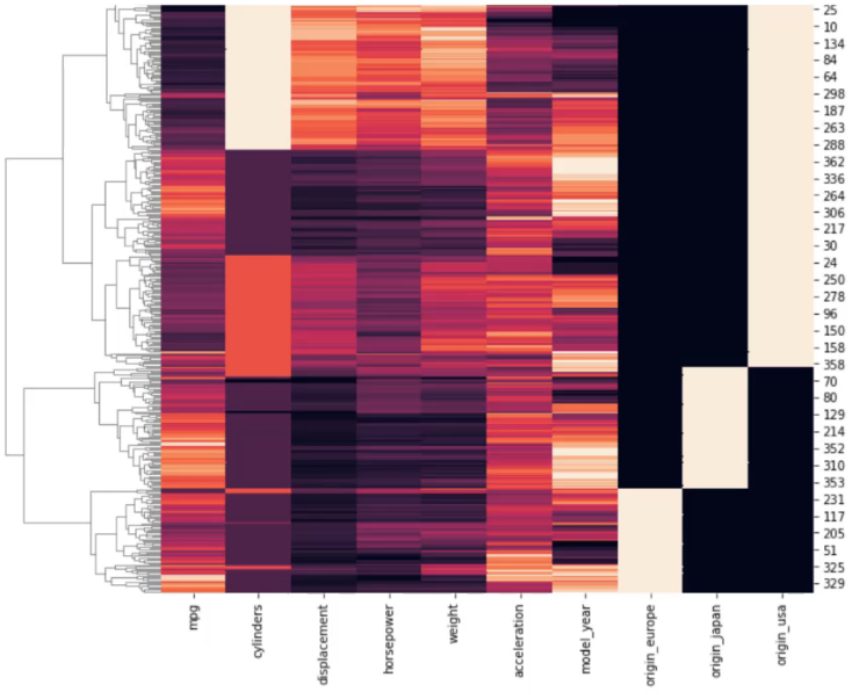




© 2025 Olivier Claerbout


## Hierarchisch Clusteren

- Dit is cluster mapping van seaborn.
- Hoe werkt een dendrogram?





© 2025 Olivier Claerbout

# Hierarchisch Clusteren

- Om dit te begrijpen hebben moeten we inzicht krijgen in:
  - *Maatstaf voor similariteit*
  - *Dendrogram*
  - *Koppelingsmatrix*

    *(Linkage Matrix – de wiskundige matrix die wordt gebruikt om het dendrogram op te bouwen)*

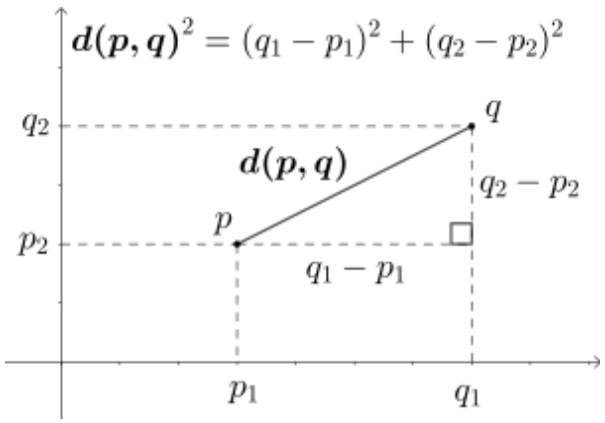

© 2025 Olivier Claerbout




# Hierarchisch Clusteren

- Maatstaf voor similariteit
  - Meet de afstand tussen 2 punten
  - Verschillende opties mogelijk:
    - Euclidische afstand
    - Cosine
    - ...

***Standaard wordt Euclidische afstand gekozen***





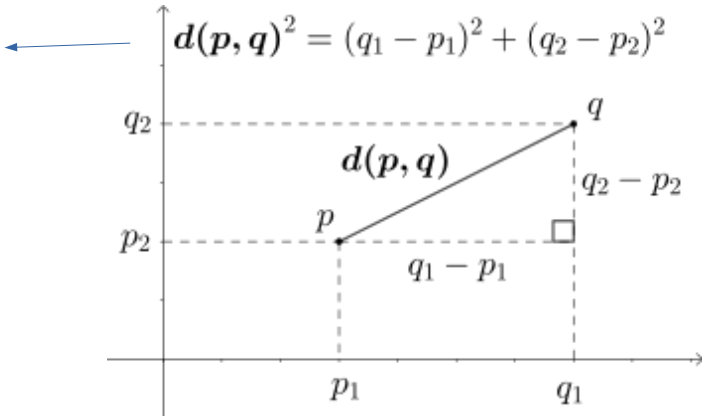
© 2025 Olivier Claerbout

# Hierarchisch Clusteren

- Maatstaf voor similariteit
  - Elke feature is een dimensie
  - *Formule voor het berekenen van het kwadraat van de Euclidische afstand D² tussen 2 datapunten in een p-dimensionale ruimte.*
  - Voor n datapunten en p features:

$$D^2=(X_{11}-X_{12})^2+...+(X_{n-1\,p-1}-X_{np})^2$$

***Standaard wordt Euclidische afstand gekozen***





© 2025 Olivier Claerbout



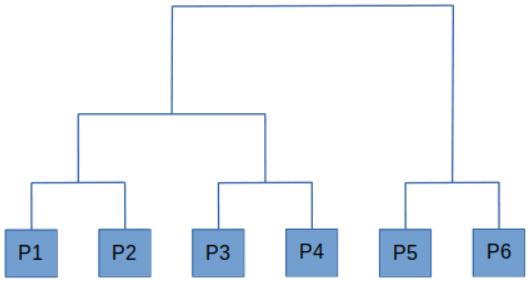
# Hierarchisch Clusteren

- Maatstaf voor similariteit
  - Elke feature is een dimensie
  - *Met de MinMaxScaler kunnen we alle features schalen tussen 0 en 1*
  - *Hierdoor zal de maximale afstand binnen één feature gelijk zijn aan 1!* *(1 - 0)²*


© 2025 Olivier Claerbout

# Hierarchisch Clusteren

- Het dendrogram
  - Een plot met daarop alle potentiële clusters
  - Vraagt zeer veel rekenkracht voor grotere datasets
  - Zeer nuttig om te bepalen hoeveel clusters je wenst



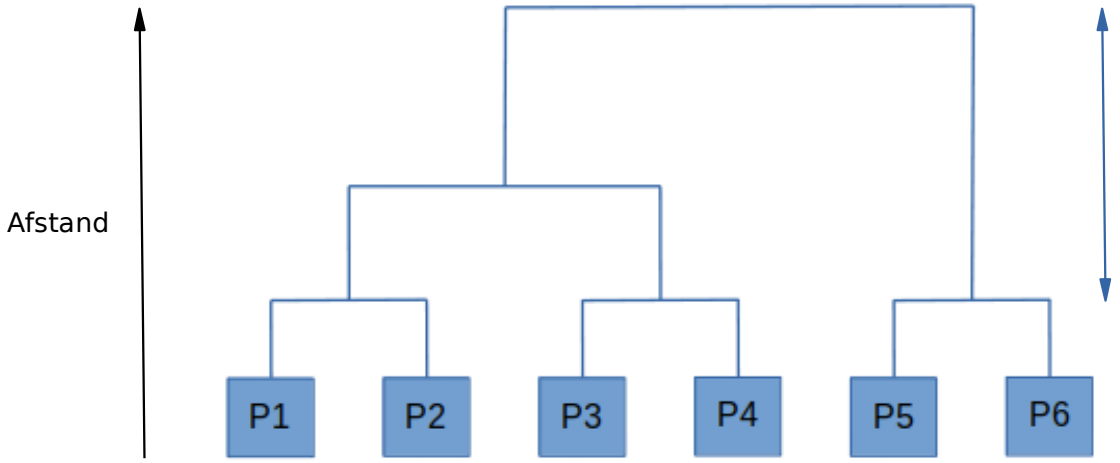


© 2025 Olivier Claerbout




# Hierarchisch Clusteren

- Het dendrogram

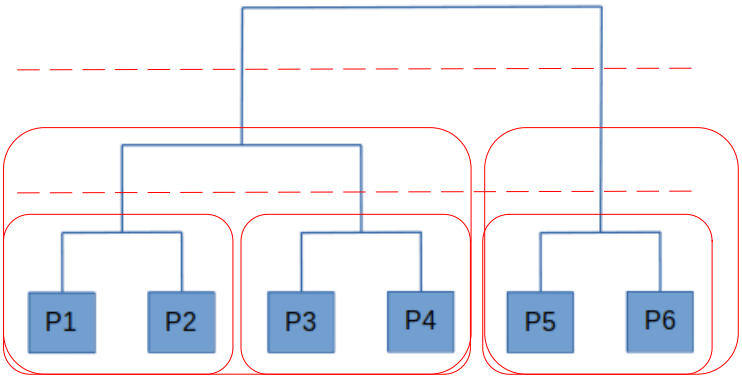




© 2025 Olivier Claerbout

# Hierarchisch Clusteren

- Het dendrogram:
- De y-as geeft de afstand tussen clusters en/of punten weer
- Korte afstand: zeer gelijkaardig; lange afstand niet zo gelijkaardig
- Je kan “slicen” om het aantal clusters te bepalen:




**3 clusters!**


© 2025 *Olivier Claerbout*




# Hierarchisch Clusteren

- De Koppelingsmatrix of Linkage Matrix:
  - Hoe meten we de afstand …
    - Van een punt tot een cluster?
    - Tussen clusters onderling?

Eénmaal 2 of meer punten samengevoegd zijn en we willen verdergaan met agglomeratief clusteren, moeten we een koppelingsparameter hebben.

→ **Linkage of koppeling!**


© 2025 *Olivier Claerbout*

# Hierarchisch Clusteren

- Linkage of koppeling is het criterium wat bepaalt welke afstand dient te worden gebruikt tussen sets observaties
- Het algoritme zal de clusterparen met de kleinste linkage samenvoegen


© 2025 *Olivier Claerbout*




# Hierarchisch Clusteren

- Ward's Linkage:
  - Combineert clusters die de **totale variantie binnen de cluster** het minst verhogen. Maw: bij elke stap combineert het de twee clusters die leiden tot een minimale toename in de totale som van kwadratische afstanden binnen alle clusters.
  - Efficiënt in het vinden van kleine, dicht bij elkaar liggende clusters. Dit maakt het een populaire keuze voor veel real-world clusteringproblemen.
  - gevoelig voor de schaal en de aanwezigheid van uitschieters
- Complete linkage:
  - de afstand tussen twee clusters wordt gedefinieerd als de ***maximale*** afstand tussen een lid van de ene cluster en een lid van de andere cluster (verste buren)
  - gevoelig voor uitschieters!


© 2025 *Olivier Claerbout*

# Hierarchisch Clusteren

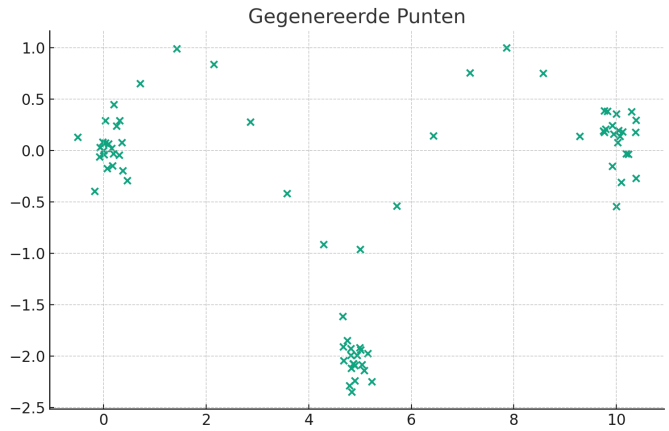
- Average linkage:
  - neemt de **gemiddelde** afstand tussen alle paren van individuele leden in twee clusters.
- Single linkage:
  - de afstand tussen twee clusters wordt bepaald door de **kortste** afstand van een lid in de ene cluster naar een lid in de andere cluster.
  - kan leiden tot zogenaamde "chain effects", waarbij clusters kunnen worden gevormd door een ketting van nabije punten, wat kan resulteren in langgerekte en "losse" clusters.

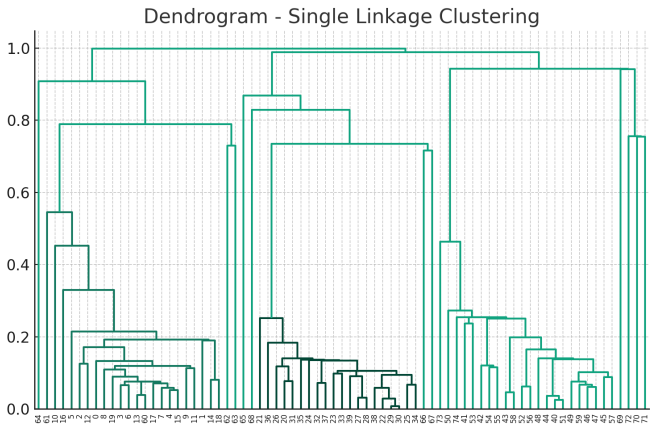

© 2025 Olivier Claerbout



# Hierarchisch Clusteren

"Chain effects" bij Single linkage:



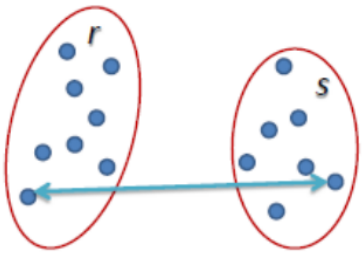





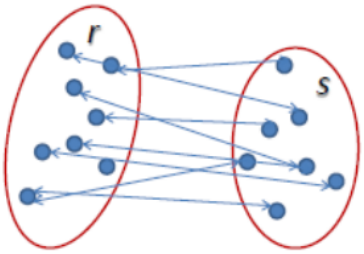
© 2025 Olivier Claerbout

# Hierarchisch Clusteren

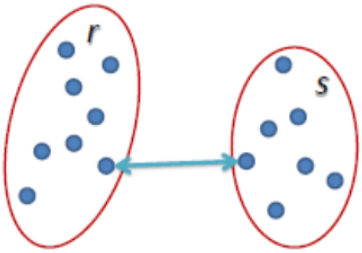
Complete linkage




Average linkage




Single linkage





© 2025 *Olivier Claerbout*




# Hierarchisch Clusteren – code!


© 2025 *Olivier Claerbout*