! Supervised Learning



© 2023 Olivier Claerbout

Lesmateriaal

- Via GitHub account:
  git clone https://github.com/oclaerbout/syntra_data_scientist.git
- © 2023 Olivier Claerbout

  Dit materiaal mag niet worden gekopieerd, verspreid, gepubliceerd of anderszins gereproduceerd zonder uitdrukkelijke schriftelijke toestemming van de auteur. Dit geldt eveneens voor de Jupyter Notebooks!

© 2023 Olivier Claerbout

Overzicht

- Introductie tot Tree Based Methods
- Terminologie
- Gini Impurity
- Code

© 2023 Olivier Claerbout

Tree Based Methods

© 2023 Olivier Claerbout

Tree Based Methods

- Opgepast: Tree Based Methods zijn supervised learning…
- 3 hoofdmethodes:
  - Decision Trees
  - Random Forests
  - Boosted Trees

© 2023 Olivier Claerbout

Tree Based Methods

- Al deze methodes stammen af van het basis decision tree algoritme
- Een “Decision Tree” refereert vaak naar een flowchart die mogelijke uitkomsten mapt
- Wij zijn echter bezig met Decision Tree Learning: statistisch modelleren waarbij node splits gebaseerd zijn op een bepaalde parameter die berekend wordt

© 2023 Olivier Claerbout

Tree Based Methods

- Decision Trees en andere Tree Based methoden splitsen data gebaseerd op informatie uit features
- Daarom hebben we een methode nodig om ‘informatie’ te meten

© 2023 Olivier Claerbout

Terminologie

- Splitting: aan een node, opsplitsen van data op basis van een bepaalde voorwaarde.
- Node: waar voorwaarden worden afgetoetst.
  - Root node: bovenaan de tree, 1e conditie om data te splitsen
  - Leaf (terminal) node: er gaat geen data meer uit de node, beslissing inzake output is gemaakt. Laatste node.
  - Parent/children nodes: parent node staat telkens boven children nodes
- Pruning: een decision tree “snoeien”; niet verder splitsen na node om overfitten tegen te gaan

© 2023 Olivier Claerbout

Gini Impurity

- Een algemene maatstaf om decision trees al dan niet te splitsen
- Het meet hoe ‘puur’ een dataset is
- Bij classificatie kunnen we denken in termen van uniformiteit binnen klasses

© 2023 Olivier Claerbout

Gini Impurity

- Gini Impurity voor Classificatie:
  - Voor een set klasses C voor een dataset Q:

$$G(Q)=\sum_{c\in C} p_c(1-p_c)$$

  - Waarbij p_c de kans is om te behoren bij klasse c
  - Wat is de maximale waarde voor G(Q)?

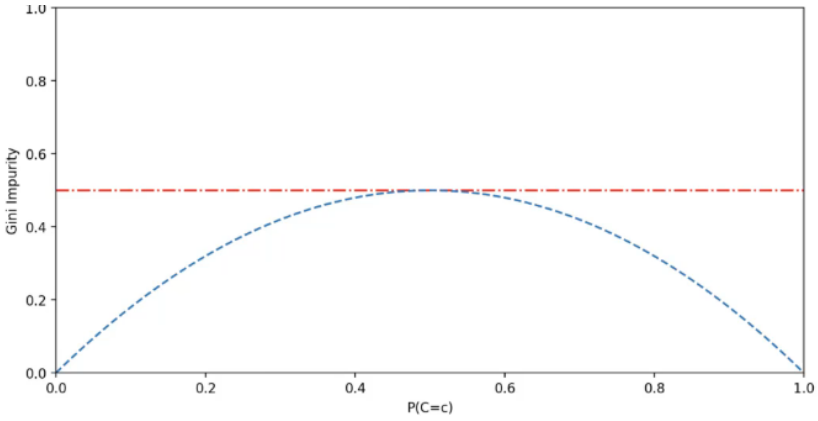
© 2023 Olivier Claerbout

Gini Impurity

- $G(Q)=\sum_{c\in C} p_c(1-p_c)$
  - p = 0 → G = 0
  - P = 1 → G = 0
  - P = 0,5 → G

    $= 0{,}5(1-0{,}5)+0{,}5(1-0{,}5)$

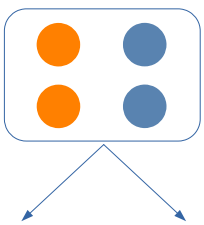
    $= 0{,}25+0{,}25=0{,}5$



© 2023 Olivier Claerbout

Gini Impurity $G(Q)=\sum_{c\in C} p_c(1-p_c)$

- Waar komt dit maximum vandaan?
  - Beeld je een eenvoudige dataset in met 4 datapunten
  - We berekenen Gini impurity
  - Deze dataset heeft maximale impurity!



Oranje klasse:
(2/4)(1 – 2/4) = 0,25

Blauwe klasse:
(2/4)(1 – 2/4) = 0,25

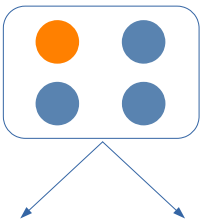
Gini Impurity:
0,25 + 0,25 = 0,5

Wat als we de data 'puurder' maken?

© 2023 Olivier Claerbout

Gini Impurity

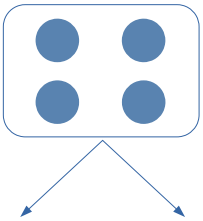
$$G(Q) = \sum_{c \in C} p_c(1 - p_c)$$



Oranje klasse:
(1/4)(1 – 1/4) = 0,1875

Blauwe klasse:
(3/4)(1 – 3/4) = 0,1875

Gini Impurity:
0,1875 + 0,1875 = 0,375



Oranje klasse:
(0/4)(1 – 0/4) = 0

Blauwe klasse:
(4/4)(1 – 4/4) = 0

Gini Impurity:
0 + 0 = 0

© 2023 Olivier Claerbout

Gini Impurity

- Als we klassen willen scheiden mbv een decision tree, kunnen we Gini Impurity gebruiken om te beslissen op welke waarden data wordt gescheiden
- We willen Gini Impurity minimaliseren aan de leaf nodes
- Minimale impurity aan de nodes betekent een effectieve split van de klasses!

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Hoe kunnen we Gini Impurity van features berekenen?
- Hoe weten we welke feature de root node moet zijn?
- Hoe kunnen we Gini Impurity gebruiken in Decision Trees?

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- We weten:

$$G(Q) = \sum_{c \in C} p_c (1 - p_c) \quad \text{met} \quad p_c = \frac{1}{N_Q} \sum_{x \in Q} 1(y_{class} = c)$$

© 2023 Olivier Claerbout

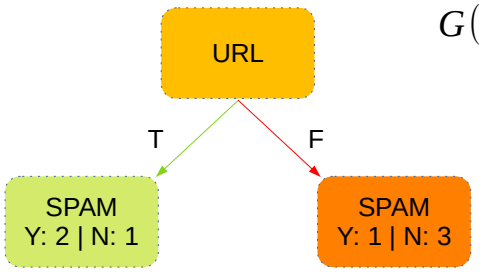
Decision Trees met Gini Impurity

- Bekijk deze dataset:
  - X: zit er een link in de mail?
  - Y: is de mail spam?
- We willen een decision tree maken
- Er is slechts één feature voor een node
- Deze feature heeft slechts 2 mogn

X – URL Link	Y-Spam
Ja	Ja
Ja	Ja
Nee	Nee
Nee	Nee
Nee	Ja
Nee	Nee
Ja	Nee

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity



$$G(Q) = \sum_{c \in C} p_c(1 - p_c)$$

voor elke klasse...

SPAM True
(2/3)(1 – 2/3) = 0,22

SPAM False
(1/3)(1 – 1/3) = 0,22

Gini Impurity 'Left Leaf':
0,22 + 0,22 = **0,44**

SPAM True
(1/4)(1 – 1/4) = 0,1875

SPAM False
(3/4)(1 – 3/4) = 0,1875

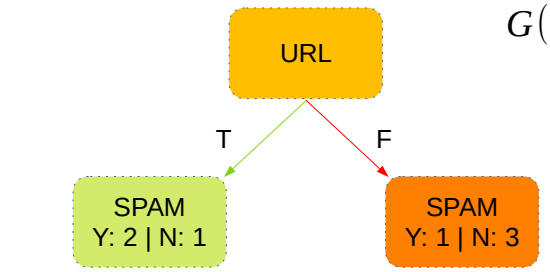
Gini Impurity 'Right Leaf':
0,1875 + 0,1875 = **0,375**

→ *"Impurity factors" na de split*

X – URL Link	Y-Spam
Ja	Ja
Ja	Ja
Nee	Nee
Nee	Nee
Nee	Ja
Nee	Nee
Ja	Nee

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity



$$G(Q)=\sum_{c\in C} p_c(1-p_c)$$

voor elke klasse...

Gini Impurity 'Left Leaf':
0,22 + 0,22 = **0,44**

3 mails

Gini Impurity 'Right Leaf':
0,1875 + 0,1875 = **0,375**

4 mails

Gini impurity van de URL feature:
→ Gewogen gemiddelde van beide:
(3/7) × 0,44 + (4/7) × 0,375 = **0,403**

X – URL Link	Y-Spam
Ja	Ja
Ja	Ja
Nee	Nee
Nee	Nee
Nee	Ja
Nee	Nee
Ja	Nee

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Wat indien er meerdere features waren?
- Wat met contunue features?
- Wat met multi-categorische features?

We kunnen Gini Impurity gebruiken om elk van deze issues op te lossen om de beste root nodes en best split parameters te vinden!

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Wat indien er meerdere features waren?
- Wat met contunue features?
- Wat met multi-categorische features?

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Continue features

X – Woorden in Email	Y – Spam
10	Ja
40	Nee
20	Ja
50	Nee
30	Nee

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Continue features
  - Stap 1: sorteer de data

X – Woorden in Email	Y – Spam
10	Ja
20	Ja
30	Nee
40	Nee
50	Nee

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Continue features
  - Stap 2: bereken de mogelijke split values voor de node met de feature als conditie om op te splitsen

X – Woorden in Email	Y – Spam
10	Ja
20	Ja
30	Nee
40	Nee
50	Nee

15
25
35
45

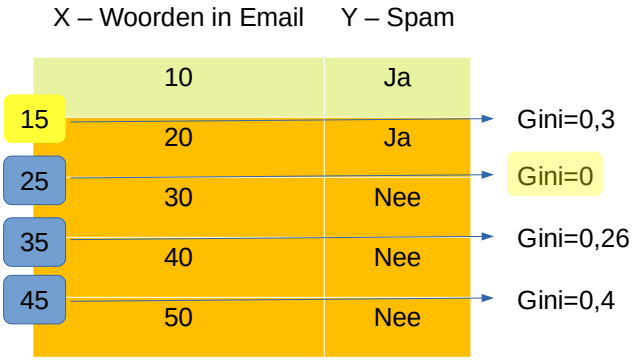
Woorden ≤ N

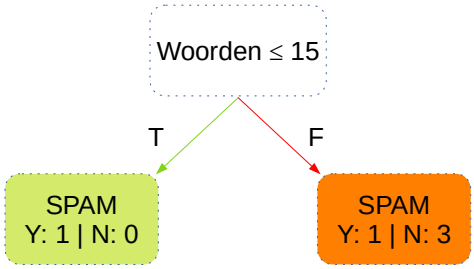
Je kan gemiddelde tussen rijen gebruiken als mogelijke waarden om op te splitsen!

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Continue features
  - Voer elke mogelijke split uit
  - Bereken gini impurity voor elke split





Gini Impurity:

(1/5) (0+0) + (4/5) ((1/4)(1-1/4)+(3/4)(1-3/4))

= **0,3**

Dit is de impurity voor deze feature bij deze split!

Welke kiezen we?

25 is een perfecte waarde om op te splitsen!

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- We hebben nu reeds gini impurity gebruikt voor:
  - Binaire categorieën
  - Continue waarden
- Nu berekenen we gini impurity voor een feature met meerdere categorieën

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

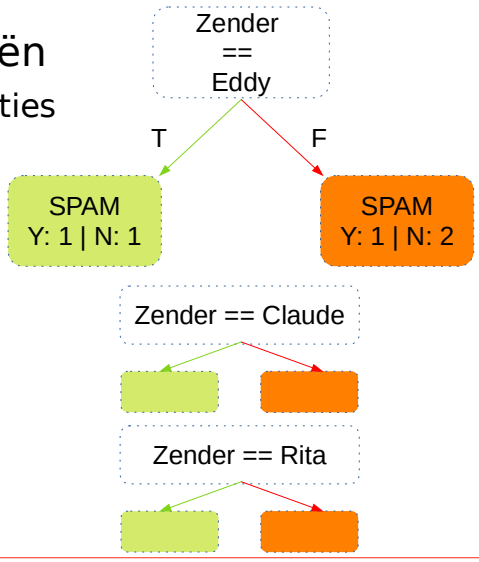
- We hebben nu reeds gini impurity gebruikt voor:
  - Binaire categorieën
  - Continue waarden
- Nu berekenen we gini impurity voor een feature met meerdere categorieën

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Feature met meerdere categorieën
  - Bereken gini impurity voor alle combinaties

X – Afzender	Y – Spam
Eddy	Ja
Claude	Ja
Rita	Nee
Eddy	Nee
Claude	Nee

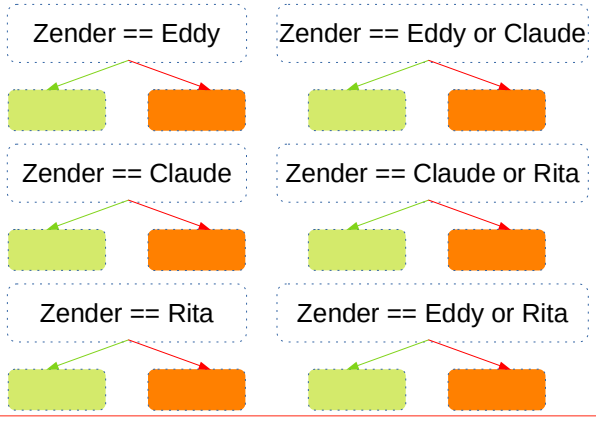


© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Feature met meerdere categorieën
  - Bereken gini impurity voor alle combinaties & *kies deze met laagste waarde en dus de puurste "leaf nodes"*

X – Afzender	Y – Spam
Eddy	Ja
Claude	Ja
Rita	Nee
Eddy	Nee
Claude	Nee



© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Nu kunnen we elk type feature splitsen!
- Hoe kiezen we de root node voor een multi-feature dataset?
- Bereken de gini impurity voor elke feature en kies de laagste impurity om eerst op te splitsen

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Door de feature met de laagste resulterende gini impurity in de leaf nodes te kiezen, kiezen we eigenlijk de feature die de data het best in “pure” klassen splitst.

© 2023 Olivier Claerbout

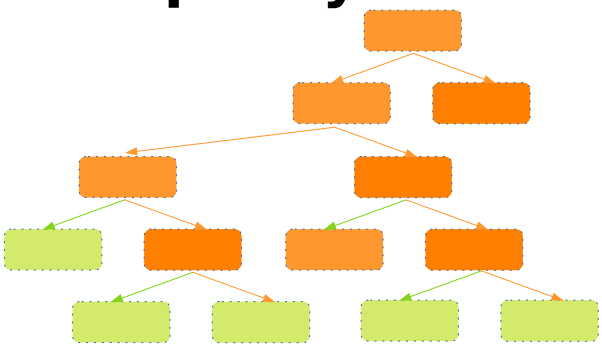
Decision Trees met Gini Impurity

- Bij een opsplitsing van data bij een node kunnen we gini impurity gebruiken als maatstaf voor de effectiviteit van de node split
- Hierdoor kunnen we automatische feature selectie doen: we kunnen een impurity treshold vooropstellen om de data al dan niet verder op te splitsen
- Hier komen we opnieuw in hyperparameter tuning

© 2023 Olivier Claerbout

Decision Trees met Gini Impurity

- Een grote tree die overfitted is:



Enkel splitsen bij een node indien de afname in gini impurity een verdere opsplitsing verantwoordt → feature selection!

Alternatief: max depth opleggen. Alles wat dieper zou gaan wordt niet meer opgesplitst

© 2023 *Olivier Claerbout*

Tree Based Methods: code!

© 2023 *Olivier Claerbout*