! Supervised Learning



© 2023 Olivier Claerbout

Lesmateriaal

- Via GitHub account:
  git clone https://github.com/oclaerbout/syntra_data_scientist.git
- © 2023 Olivier Claerbout

  Dit materiaal mag niet worden gekopieerd, verspreid, gepubliceerd of anderszins gereproduceerd zonder uitdrukkelijke schriftelijke toestemming van de auteur. Dit geldt eveneens voor de Jupyter Notebooks!

© 2023 Olivier Claerbout

Overzicht

- Hyperparameters
- Random Forest Classificatie
- Random Forest Regressie

© 2023 *Olivier Claerbout*

Random Forests

© 2023 *Olivier Claerbout*

Random Forests

- Gaan verder op concepten van Decision Trees
- Random Forests zijn ensemble learners, aangezien ze werken met meerdere decision trees (veel ML modellen)

© 2023 Olivier Claerbout

Random Forests: waarom?

- Waarom niet gewoon verder decision trees gebruiken?
  - Decision trees zijn eenvoudig te interpreteren
  - Decision trees werken heel goed op bepaalde datasets
- Hoe verbeteren Random Forests de ‘gewone’ decision tree?
- Denk even terug naar een ‘gewone’ decision tree...

© 2023 Olivier Claerbout

Random Forests: waarom?

- Stel een dataset met features en een label:

Als we een enkele decision tree bouwen op basis van deze dataset, gebaseerd op Gini Impurity als splitsingscriterium. Hierdoor gebruikt je slechts *bepaalde features* – er is geen garantie dat alle features worden gebruikt! Je bouwt ahw 'de beste' decision tree, gebaseerd op Gini Impurity.

Daarnaast is het ook zo dat de root node steeds dezelfde zal zijn bij dezelfde parameters. Dit heeft een grote impact aangezien de volledige dataset altijd eerst op basis van deze 'root feature' zal worden gesplitst!

© 2023 Olivier Claerbout

Random Forests: waarom?

- We kunnen parameters aanpassen, zoals:
  - Information gain ipv Gini Impurity
  - Minimum Gini Impurity Decrease
  - Instellen Depth Limits
  - Aantal terminal leaf nodes instellen

→ Voor elke 'rule set' blijft er slechts één 'beste decision tree'!

© 2023 Olivier Claerbout

Random Forests: waarom?

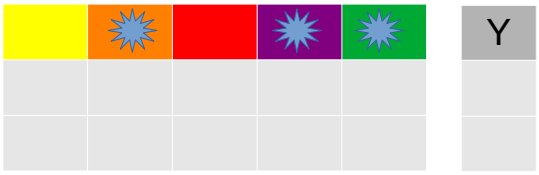
- Zelfs met deze hyperparameters blijft deze ‘beste tree’ gelimiteerd:
  - Eén feature voor de root node
  - Sommige features worden niet gebruikt
  - Gevoelig om te overfitten

→ Hoe kunnen we dit verbeteren?

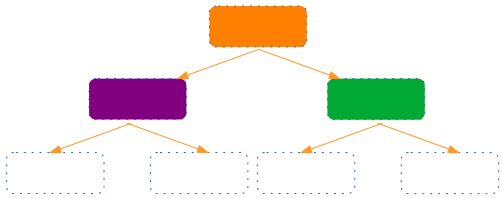
© 2023 Olivier Claerbout

Random Forests

- We hebben een dataset met features en een label:



We bouwen een decision tree. Sommige features worden gebruikt, andere niet...



© 2023 Olivier Claerbout

Random Forests

- Principe achter random forests:
  - *Maak subsets van willekeurig gekozen features* ***voor elke potentiële split***

Stel grootte subset = 3

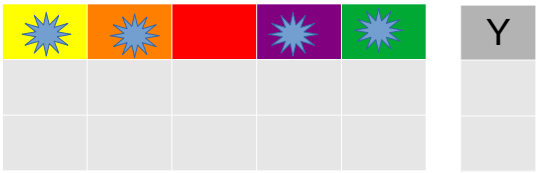
We selecteren dus random 3 van de 5 features

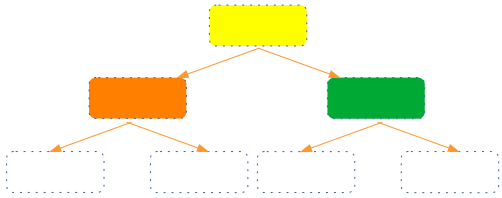
We kiezen de root node feature uit deze subset

We selecteren een nieuwe subset

We kiezen op basis van welke feature we splitten

...





© 2023 Olivier Claerbout

Random Forests

- Door bij elke split een willekeurige selectie van features te maken, krijg je veel meer mogelijkheden. De root node kan elke feature zijn, en elke split gebeurt op basis van een nieuwe selectie.
- Je kiest op basis van je criterium of je verder gaat splitsen of niet met de volgende selectie van features (voldoende afname of niet).
- Door de willekeurige selectie van features gaan we niet overfitten
- Elke feature die een signaal bevat zal wellicht worden gebruikt

© 2023 Olivier Claerbout

Random Forests

- Zo maak je veel verschillende trees, die verschillend uitgroeien omdat ze elk naar verschillende feature subsets kijken bij elke split
- We hebben dus verschillende root nodes
- En we gebruiken alle nuttige features
- Hoe wordt nu een antwoord bepaald uit een random forest?

© 2023 Olivier Claerbout

Random Forests

- Voor classificatie tellen we de ‘stemmen’ per klasse. De klasse met de meeste stemmen wint. Door de stemmen te tellen zie je ook hoe zeker het ‘forest’ is!
- Voor een regressie maken we het gemiddelde van de voorspelde waarden.

© 2023 Olivier Claerbout

Random Forests

- Dankzij de random feature subspace kunnen trees veel dieper groeien zonder overfitting te veroorzaken.
- De wiskundige uiteenzetting hiervan werd gedaan door Eugene Kleinberg in zijn ‘theory of stochastic discrimination’.

© 2023 *Olivier Claerbout*

Random Forests
Hyperparameters

© 2023 *Olivier Claerbout*

Hyperparameters

- Aangezien random forest een ensemble van veel decision trees is, zijn veel van de hyperparameters identiek.
  - Dit betekent dat je bij een random forest dezelfde set regels oplagt aan alle decision trees in het random forest. Vb alle trees in het random forest hebben dezelfde max_depth…
  - Het belangrijkste verschil tussen de trees in het random forest zijn de willekeurige feature subsets bij de nodes
- We gaan even na welke hyperparameters uniek zijn aan een Random Forest.

© 2023 Olivier Claerbout

Hyperparameters

- Er zijn 4 unieke hyperparameters die niet bij een decision tree aanwezig zijn:
  - n_estimators
    - Hoeveel decision trees (estimators) willen we in het random forest?
  - max_features
    - Hoeveel features willen we in elke subset?
  - bootstrap
    - Laten we bootstrap sampling toe bij elke training subset van de features?
  - oob_score
    - Berekenen we de OOB error tijdens training?

© 2023 Olivier Claerbout

Hyperparameters

- Aantal ‘estimators’:
  - Hoe meer decision trees, hoe meer mogelijkheden om te leren van een verschillende subset combinaties
  - Is er een limiet aan het aantal trees?
  - Is er gevaar voor overfitting?

“Random forests overfitten niet. Je kan zo veel trees toevoegen als je wil. Het is snel.”
Leo Breiman – https://www.stat.berkeley.edu/~breiman/RandomForests/cc_home.htm#remarks

© 2023 Olivier Claerbout

Hyperparameters

- Hoeveel trees kies je best?
  - 100 is een redelijk aantal
  - In publicaties wordt 64 tot 128 trees aanbevolen
    - Hoe meer features in je dataset, hoe meer trees
  - Gebruik cross validation om een grid search te doen en het beste aantal trees te zoeken
  - Een andere techniek is het plotten van de error in functie van het aantal trees (cfr KNN elbow method)
    - Bij een random forest met één tree krijgen we een slechter resultaat dan met een ‘gewone’ decision tree. Waarom? *We werken op een feature subset!*
    - De error *reductie* vermindert na een bepaald aantal trees
    - De error gaat *niet opnieuw omhoog* zoals we vroeger zagen

© 2023 Olivier Claerbout

Hyperparameters

- Wat zou gebeuren als je duizenden trees zou maken?
  - Nieuwe trees zijn *sterk gecorreleerd* met reeds bestaande, en bieden dus geen nieuwe informatie
  - Sommige trees beginnen identiek te zijn: je maakt gewoon dezelfde tree opnieuw; er zijn slechts een beperkt (maar groot) aantal mogelijke subselecties
  - We overfitten dus niet, maar er komt ook geen nieuwe informatie meer bij

© 2023 Olivier Claerbout

Hyperparameters

- Omdat er geen overfitting optreedt zijn we redelijk vrij in de keuze van het aantal estimators
- Hoe kiezen we nu het aantal bij elke split te gebruiken features?

© 2023 Olivier Claerbout

Hyperparameters

- Number of Features
  - Hoeveel features voegen we best aan de subset toe wanneer we splitsen op een node?
  - De originele publicatie suggereert een subset grootte van $\log_2(N+1)$ features bij een totaal aantal features N
  - Op heden is de suggestie om sqrt(N) te gebruiken
  - Breiman gaf later aan dat N/3 geschikter is voor regressietaken, wat normaal groter is dan sqrt(N).
  - ISLP geeft aan dat Number of features een tuning parameter is, met sqrt(N) als startpunt.
  - Alle voorgaande suggesties zijn gebaseerd op experimenten, dus wellicht moet je dit inderdaad tunen voor jouw dataset via grid search

© 2023 Olivier Claerbout

Hyperparameters

- Overzicht inzake Hyperparameters:
  - Aantal Estimators: start met 100 (default in sklearn), check of hogere aantallen zin hebben
  - Number of features: start met sqrt(N), onderzoek andere mogelijke waarden zoals N/3
  - Gebruik Grid Search om te tunen

© 2023 Olivier Claerbout

Random Forests
Bootstrapping en out-of-bag error

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Random Forest Hyperparameters:
  - Bootstrap Samples
    - *Staan we bootstrap sampling toe voor elke training subset van features?*
  - Out-of-Bag Error
    - *Berekenen we de OOB error tijdens de training?*

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Wat is bootstrapping?
  - Een algemene term, gebruikt om willekeurige steekproeftrekking met teruglegging aan te duiden
  - Voorbeeld:
    - Bootstrapping van 10 samples uit 5 letters A, B, C, D:

      B A C C D B A C A D

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Bootstrapping in Random Forests:
  - We kiezen al een random feature subset bij elke split
  - Deze random feature subset helpt ons om meer verschillende trees te krijgen die niet met elkaar gecorreleerd zijn
  - Om nu nog meer variatie in de trees te krijgen, kunnen we een bootstrap van de rijen bij elke split gebruiken
  - Daardoor heeft *elke tree* 2 random training componenten:
    - Een subset van gebruikte features
    - Een bootstrap van data rijen → random sampling met replacement!

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Waarom bootstrapping?
  - Je zou het op False kunnen zetten tijdens training (default is True)
  - Bootstrapping helpt om de correlatie tussen trees te reduceren, aangezien de trees getraind worden op verschillende subsets van feature kolommen en data rijen!
  - Reductie van de correlatie helpt het model om beter te generaliseren op de training data

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Out-of-Bag Error
  - Berekenen we de OOB error tijdens de training?

    → Wat is ‘bagging’?
    - Om ons random forest te maken, gebruiken we ‘bootstrapped’ data om een voorspelling te maken op basis van de combinatie van de geaggregeerde voorspellingen van de individuele trees:
      - Voor Classificatie: meest ‘gestemde’ Y klasse
      - Voor Regressie: gemiddelde van de voorspelde Y

We werken dus met **b**ootstrapped data en **ag**gregated predictions

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Out-of-Bag Error
  - Berekenen we de OOB error tijdens de training?
    → Wat is ‘bagging’?
    - Gebruik van bootstrapped data
    - Voorspelling gebaseerd op geaggregeerde voorspellingen van de individuele trees

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Out-of-Bag Error
  - Als we bootstrapping gebruiken om de trees te maken, dan zullen bepaalde rijen data niet gebruikt worden tijdens de training voor een tree
  - Typisch is dit ongeveer 1/3 van de data bij grotere datasets
  - Deze door een bepaalde tree nooit geziene rijen (‘out of bag samples’) zijn goede test data voor deze tree
  - We kunnen deze gebruiken om een voorspelling te doen

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Out-of-Bag Error
  - Aangezien elke tree getraind is op een andere data subset, doet elke tree voor verschillende ongeziene ‘Out-Of-Bag’ datapunten een voorspelling
  - Deze voorspellingen worden geaggregeerd: per datapunt wordt nagegaan voor welke trees dit een ‘Out-Of-Bag’ punt was en wat de voorspelde waarde was
  - De OOB error wordt vervolgens berekend door deze datapunten te vergelijken met de werkelijke waarden
  - Deze OOB error geeft een goed idee hoe het Random Forest zal presteren op ongeziene data

© 2023 Olivier Claerbout

Bootstrapping samples en out of bag error

- Out-of-Bag Error
  - De OOB score is een hyperparameter die het training proces niet beïnvloedt
  - Het is een optionele manier om de performantie te meten, een soort alternatief voor de standaard train/test split, aangezien bootstrapping door de aard van het proces tijdens de training resulteert in ongebruikte data
  - Aangezien de OOB score niet op het volledige random forest wordt berekend, wordt dit niet standaard gedaan (hyperparameter op False)
  - Wijzigen van de OOB Score hyperparameter zal de trees niet wijzigen; gebruik van Bootstrapping of niet daarentegen wel!

© 2023 Olivier Claerbout

Random Forests

- We begrijpen nu de theorie achter Random Forests
- We kennen de hyperparameters die we kunnen tunen
- Laat ons nu Random Forests voor Classificatie en Regressie verder ontdekken met code!

© 2023 *Olivier Claerbout*

Random Forests
Code!

© 2023 *Olivier Claerbout*