Supervised Learning



© 2024 Olivier Claerbout

Lesmateriaal

- Via GitHub account:
  git clone https://github.com/oclaerbout/syntra_data_scientist.git
- © 2023 Olivier Claerbout

  Dit materiaal mag niet worden gekopieerd, verspreid, gepubliceerd of anderszins gereproduceerd zonder uitdrukkelijke schriftelijke toestemming van de auteur. Dit geldt eveneens voor de Jupyter Notebooks!

Copyright Olivier Claerbout 2024

© 2024 Olivier Claerbout

Support Vector Machines

- Supervised Learning
- Classificatie en regressie
- Lineaire modellen
- Kunnen inputruimte naar hogerdimensionale ruimte transformeren (cfr PCA)
- Zoek optimaal hyperplane – lijn, vlak,… die de **marge** tussen klassen maximaliseert

© 2024 *Olivier Claerbout*

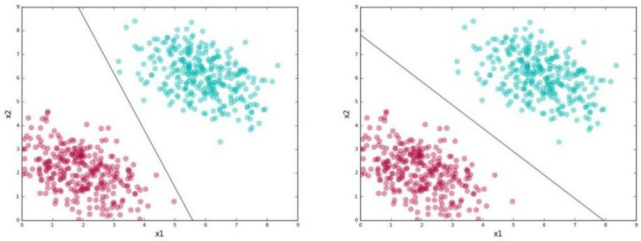
SVM

© 2024 *Olivier Claerbout*

Copyright Olivier Claerbout 2024

SVM – wat?

Welke classifier zou je verkiezen en waarom?



© 2024 Olivier Claerbout

Maximal Margin Classifiers

Stel dat we Golden Retrievers wegen om na te gaan of ze obees zijn of niet.

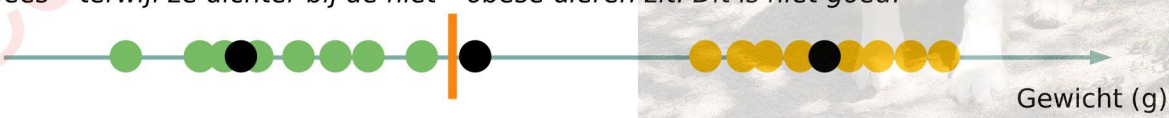
We kiezen een treshold om de obese honden van de niet-obese honden te scheiden.

Nieuwe observatie met gewicht < treshold: niet obees.

Nieuwe observatie met gewicht > treshold: obees!

Wat met deze observatie:

Aangezien de observatie zwaarder weegt dan de treshold, classificeren we deze als obees – terwijl ze dichter bij de niet – obese dieren zit. Dit is niet goed!



© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

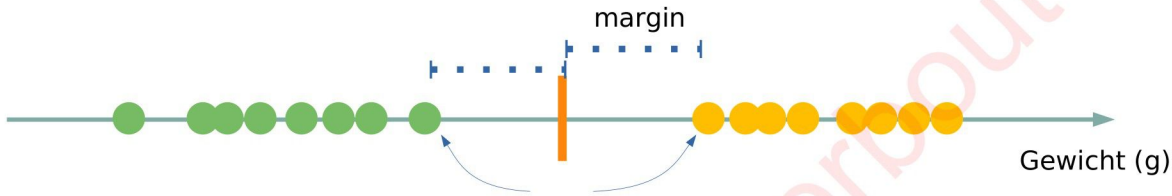
Maximal Margin Classifiers

We focussen op de observaties aan de randen van de clusters

We kiezen een treshold net tussen de randobservaties

Nieuwe observatie met gewicht < treshold: dichter bij de niet obese observaties!

De kortste afstand tussen de observaties en de treshold noemt de **margin**

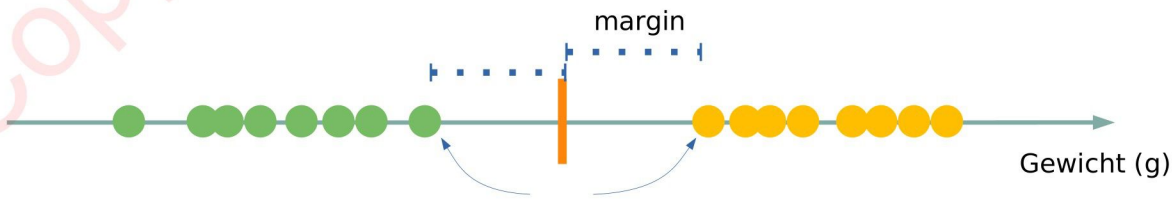


© 2024 Olivier Claerbout

Maximal Margin Classifiers

Indien de marge *net in het midden* van de uiterste waarden van elke klasse valt, dan is deze maximaal.

Indien een treshold wordt gebruikt die de maximale marge gebruikt om classificaties te doen, spreken we van een *Maximal Margin Classifier*.

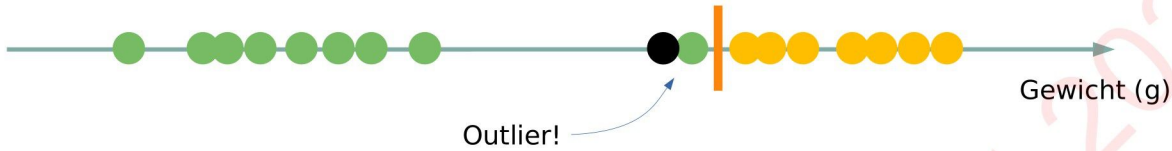


© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Maximal Margin Classifiers

Maximal Margin Classifiers lijken goed te werken, maar wat met deze dataset?



Nieuwe observatie...

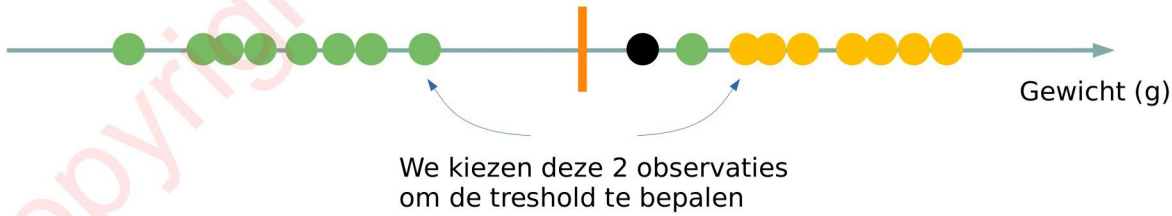
Deze zou worden geclassificeerd als niet obees, terwijl deze dichter bij de obese observaties ligt!

Maximal Margin Classifiers zijn zeer gevoelig aan uitschieters!

© 2024 Olivier Claerbout

Support Vector Classifiers

Om onze treshold minder gevoelig te maken voor uitschieters, moeten we misclassificaties toestaan!



Nieuwe observatie...

Deze zou worden geclassificeerd als obees, wat juist lijkt!

De keuze van een treshold die misclassificaties toestaat is een voorbeeld van de bias/variance tradeoff die we eerder hebben gezien!

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Classifiers

Zonder toestaan misclassificaties:

- Treshold is zeer gevoelig was aan training data *(lage bias)*
- Treshold presteert slecht voor nieuwe data *(hoge variantie)*

Met toestaan misclassificaties:

- Treshold minder gevoelig aan training data
- Treshold presteerde beter op nieuwe data

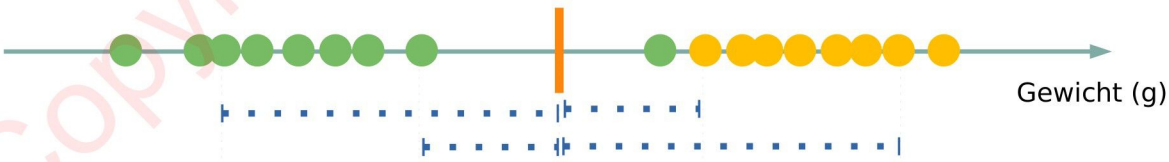
! Bij toestaan misclassificaties noemen we de afstand tussen de observaties en de treshold de **Soft Margin.**

© 2024 Olivier Claerbout

Support Vector Classifiers

Hoe weten we welke 'soft margin' (=tussen welke 2 punten) de beste keuze is?

Via Cross Validation bepalen we hoeveel misclassificaties en observaties binnen de Soft Margin mogen vallen om het beste resultaat te krijgen.



Kiezen we deze soft margin?
Of deze?

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Classifiers

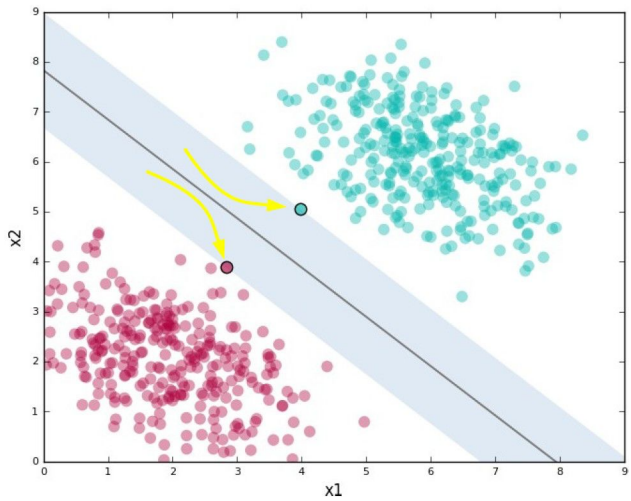
Soft Margin gebruiken om locatie treshold te bepalen:
→ Soft Margin Classifier aka **Support Vector Classifier**

De *observaties aan de rand* en *in* de **Soft Margin** worden ook wel **Support Vectors** genoemd
→ Vandaar de naam **Support Vector Classifier**

© 2024 Olivier Claerbout

Support Vector Classifiers

Als de data 2-dimensionaal is (vb gewicht en schofthoogte), dan is de Support Vector Classifier **een lijn**, en wordt de Soft Margin in dit geval gemeten vanaf de 2 aangeduide punten.

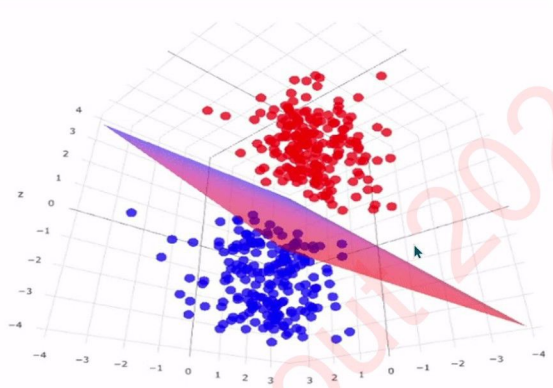


© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Classifiers

Als de data 3-dimensionaal is (vb gewicht, schofthoogte en leeftijd), dan is de Support Vector Classifier **een vlak**.



Als de data 4-dimensionaal is…

Dan kunnen we dit niet meer grafisch voorstellen! De Support Vector Classifier is een *hyperplane*.

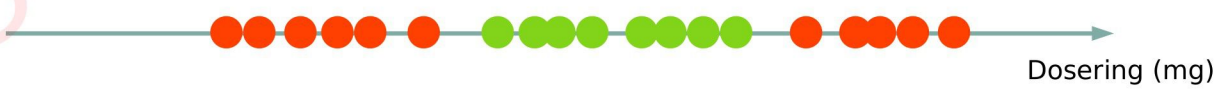
© 2024 Olivier Claerbout

Support Vector Classifiers

Support Vector Classifiers lijken goed te werken. Ze kunnen overweg met:

- Uitschieters
- Overlappende classificaties
- Misclassificaties

Maar stel nu deze dataset voor de dosis van een medicijn.
Groen = genezen, rood = niet genezen.

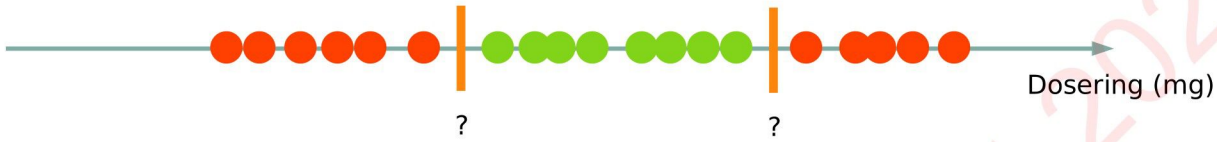


© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Machines

De dosis werkt enkel indien ze niet te laag en niet te hoog is.
Waar plaatsen we de classifier?



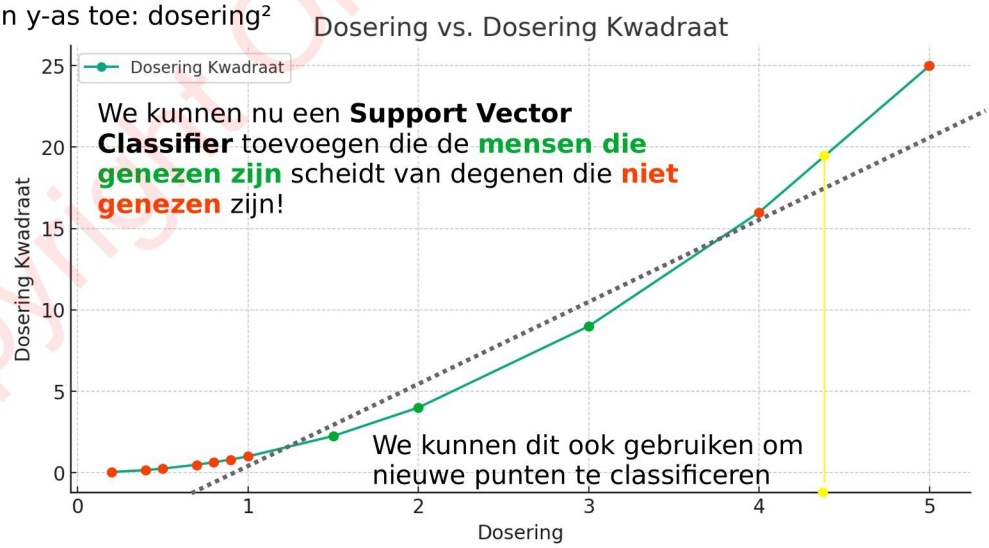
Waar we de classifier ook plaatsen, we zullen veel misclassificaties hebben!

Hebben we iets wat beter presteert dan Maximal Margin Classifiers en Support Vector Classifiers?

© 2024 Olivier Claerbout

Support Vector Machines - intuïtie

We voegen een y-as toe: dosering²



© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Machines

De belangrijkste ideeën achter Support Vector Machines zijn:

Start met data in een relatief lage dimensie

Bij niet-lineair scheidbare gegevens: breng de data naar een hogere dimensie, gevolgd door lineaire scheiding

Zoek een Support Vector Classifier die de hoger dimensionale data opdeelt in 2 groepen

© 2024 Olivier Claerbout

Support Vector Machines

Waarom kozen we in het voorbeeld voor een y-as met dosering² ?

Waarom niet dosering³ ?

Hoe beslissen we welke transformatie op de data wordt toegepast?

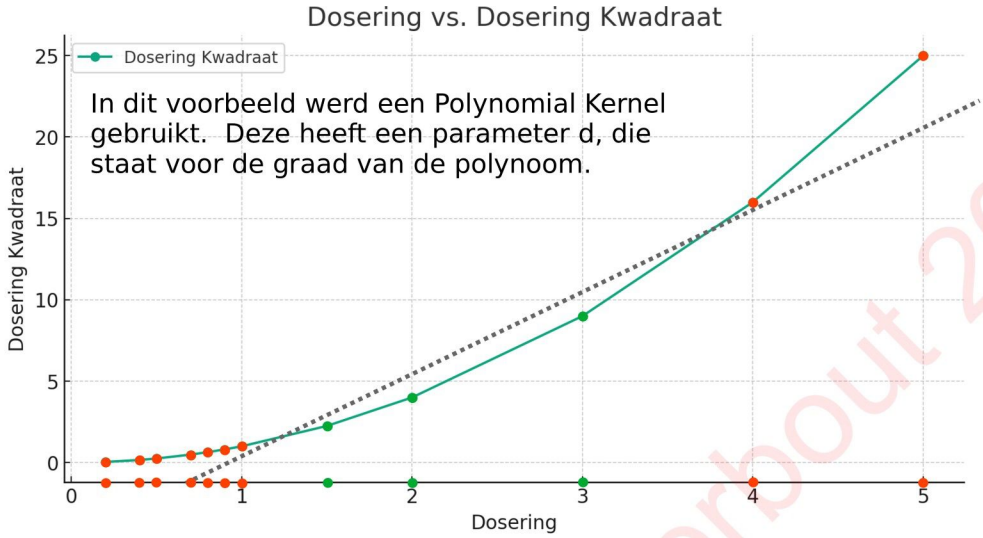
Support Vector Machines gebruiken iets wat Kernel Functions wordt genoemd om systematisch Support Vector Classifiers te zoeken in hogere dimensies.*

*In machine learning is een kernel een wiskundige functie die wordt gebruikt om data te mappen in een hoger dimensionale ruimte.

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Machines



© 2024 Olivier Claerbout

Support Vector Machines

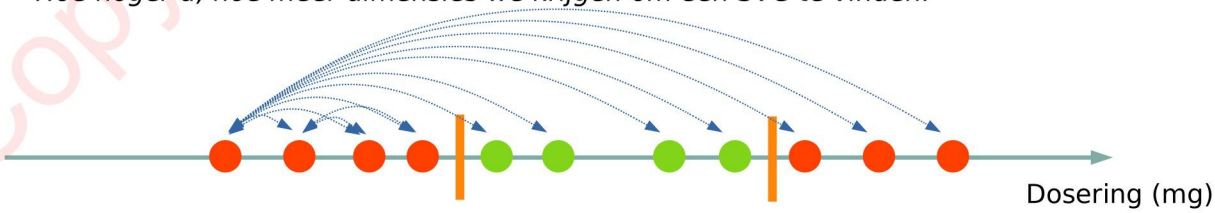
Als d = 1, dan zal de Polynomial Kernel de relatie tussen elk paar observaties in 1 dimensie berekenen.

Deze relaties worden gebruikt om een Support Vector Classifier te vinden.

Indien d = 2, dan krijgen we een 2de dimensie dosering². De Polynomial Kernel zal ook hier de relatie tussen elk paar observaties berekenen.

Deze relaties worden gebruikt om een Support Vector Classifier te vinden.

Hoe hoger d, hoe meer dimensies we krijgen om een SVC te vinden.



© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Machines

Samenvattend:

- De Polynomial Kernel verhoogt systematisch de dimensies door de graad van de polynomial d te verhogen
- De relaties tussen elk paar observaties worden gebruikt om een Support Vector Classifier te vinden
- De optimale waarde voor d wordt gevonden via Cross Validation

SVM maximaliseert de marges. Deze marge is de afstand tussen het hyperplane en de dichtste datapunten van elke klasse. Enkel de dichtst bij de decision boundary liggende datapunten bepalen deze marge. Deze punten bevatten dus de meeste info.

© 2024 Olivier Claerbout

Support Vector Machines

Opgepast:

- Kernel Functions berekenen de relaties tussen de puntenparen *alsof* deze zich in de hogere dimensie bevinden
- De transformatie van de datapunten naar de hogere dimensie gebeurt eigenlijk niet omwille van de nodige rekenkracht
- Dit is gekend als **de Kernel Trick**

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Support Vector Machines

- De **Kernel Trick** reduceert de nodige rekenkracht door de berekeningen die nodig zijn voor de transformatie van de datapunten van lage naar hoge dimensies te vermijden.
- Het maakt ook de berekening van de relaties in oneindige dimensies die worden gebruikt door de **Radial Kernel** mogelijk.
- Hoe deze relaties ook worden berekend, het concept blijft: zet de data in een relatief hoog dimensionale ruimte, en zoek een relatief hoog dimensionale **Support Vector Classifier** de de data kan scheiden.

© 2024 Olivier Claerbout

Support Vector Machines

Een andere veel voorkomende Kernel is de Radial Kernel, ook gekend als de Radial Basis Function (RBF) Kernel.

De Radial Kernel vindt Support Vector Classifiers in oneindige dimensies, dus kunnen we niet visualiseren wat het doet.

Bij de Radial Kernel hebben de datapunten die zich het dichtst bij een nieuw punt bevinden het meeste invloed op de classificatie ervan

Datapunten die zich verder van het nieuwe punt bevinden, hebben relatief weinig invloed op de classificatie.

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Kernels - Algemeen

Projecteer de data in een hogere dimenensie en probeer lineair te scheiden.

Meest gebruikte kernels:

- RBF - Radial Basis Function (Gaussiaanse kernel)
- Polynomial kernel
- Histogram kernel
- Lineaire kernel = SVM zonder kernel

© 2024 Olivier Claerbout

De Polynomial Kernel

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Polynomial Kernel

- Polynomial Kernel Parameters
- Hoe berekent de Polynomial Kernel hoog-dimensionale relaties?

© 2024 Olivier Claerbout

De Polynomial Kernel

- De gebruikte Polynomial Kernel: $(a \cdot b + r)^d$
  - **a** en **b** verwijzen naar 2 verschillende observaties in de dataset
  - **r** bepaalt de coëfficiënt van de polynoom
  - **d** bepaalt de graad van de polynoom



We nemen onze dataset voor de dosis van een medicijn er opnieuw bij.
Groen = genezen, rood = niet genezen.

Dosering (mg)

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Polynomial Kernel

- Voorbeeld:
  - We nemen de coëfficiënt **r = 1/2**
  - We nemen als graad van de polynoom **d = 2**

$(a \cdot b + r)^d$

$$\left(a \cdot b + \frac{1}{2}\right)^2 = \left(a \cdot b + \frac{1}{2}\right) \times \left(a \cdot b + \frac{1}{2}\right) = a^2 b^2 + \frac{1}{2} ab + \frac{1}{2} ab + \frac{1}{4} = a^2 b^2 + ab + \frac{1}{4} = ab + a^2 b^2 + \frac{1}{4}$$

Dit komt overeen met volgend Dot Product: $\left(a, a^2, \frac{1}{2}\right) \cdot \left(b, b^2, \frac{1}{2}\right)$

Dit dot product geeft ons dus de hoogdimensionale coördinaten voor de datapunten a en b!

© 2024 Olivier Claerbout

De Polynomial Kernel

- Voorbeeld:
  - $ab + a^2 b^2 + \frac{1}{4}$ == dot product $\left(a, a^2, \frac{1}{2}\right) \cdot \left(b, b^2, \frac{1}{2}\right)$

x-as coördinaten

y-as coördinaten

  - Dit dot product geeft ons de hoogdimensionale coördinaten voor de data
  - De derde termen vormen de z-as coördinaten. Aangezien deze identiek zijn kunnen we deze negeren

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Polynomial Kernel

- We hebben dus de x en y coördinaten voor de data in de hogere dimensie!
- We konden ook r = 1 en d = 2 hebben gekozen:

$$(a\cdot b+1)^2=(a\cdot b+1)\times(a\cdot b+1)=a^2b^2+2ab+1=2ab+a^2b^2+1$$

dit is nu onze polynoom

En dit het dot product: $(\sqrt{2}a, a^2, 1)\cdot(\sqrt{2}b, b^2, 1)$

r en d worden bepaald via **Cross Validation!**

© 2024 Olivier Claerbout

De Polynomial Kernel

- Dit is ons dot product: $(\sqrt{2}a, a^2, 1)\cdot(\sqrt{2}b, b^2, 1)$
- De nieuwe x-as coördinaten worden vermenigvuldigd met $\sqrt{2}$
- Alle punten op de x as verschuiven dus met deze factor
- De y-as coördinaten zijn dezelfde als voorheen: y^2
- De z-as coördinaat kunnen we opnieuw schrappen
- We gebruiken opnieuw hoogdimensionale relaties om een SVC te vinden.

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Polynomial Kernel

- Teruggaand naar de Polynomial Kernel met r = ½ en d=2:

$$\left(a \cdot b + \frac{1}{2}\right)^2 = \ldots = \left(a, a^2, \frac{1}{2}\right) \cdot \left(b, b^2, \frac{1}{2}\right)$$

- Alles wat we moeten doen om de hoogdimensionale relatie tussen punten te berekenen is het Dot Product van deze punten berekenen!

- Dus de hoogdimensionale relatie tussen doseringen x = 9 en x = 14:

$$\left(9 \cdot 14 + \frac{1}{2}\right)^2 = \left(126 + \frac{1}{2}\right)^2 = 126{,}5^2 = 16002{,}25$$

© 2024 Olivier Claerbout

De Polynomial Kernel

- 16002,25 is één van de 2 Dimensionale relaties die moeten worden opgelost om de Support Vector Classifier te bepalen
  - De datapunten werden niet echt naar 2 dimensies getransformeerd!

- Wanneer alle dot products zijn berekend, wordt de beste scheiding tussen de punten gezocht

- Er wordt daartoe een set coëfficiënten gezocht voor de features die het hyperplane bepalen

- Dit valt buiten de scoop van de opleiding

© 2024 Olivier Claerbout

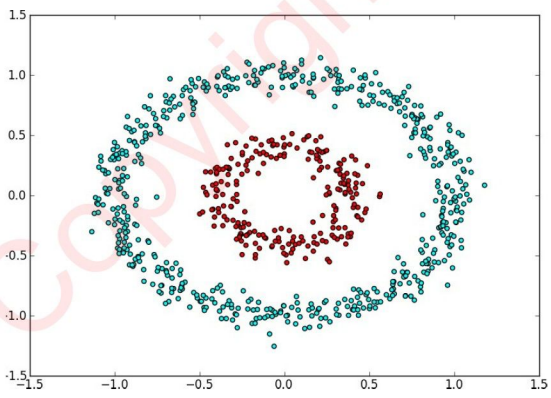
Copyright Olivier Claerbout 2024

De Radial Kernel

© 2024 Olivier Claerbout

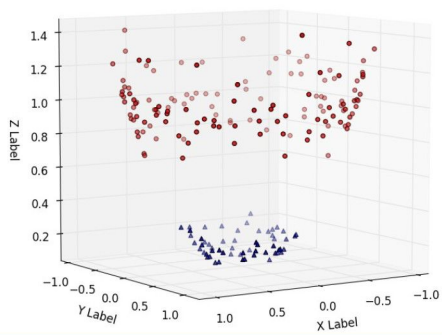
De Radial Kernel

Hoe kan je onderstaande klasses scheiden?



Gebruik v/e Gaussiaanse (RBF) kernel:

https://www.youtube.com/watch?v=3liCbRZPrZA



© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- Wat zijn de parameters van de Radial Kernel?
- Hoe berekent de Radial Kernel hoogdimensionale relaties?
- Hoe werkt de Radial Kernel in een oneindig aantal dimensies?

© 2024 Olivier Claerbout

De Radial Kernel

- Een Radial kernel kan worden gebruikt om overlappende data te scheiden (zie ook vorig voorbeeld inzage dosering)
- Ook gekend als de **Radial Basis Function (RBF)**
- De Radial Kernel vindt Support Vector Classifiers in oneindige dimensies → visualisatie van de werking is niet mogelijk
- Voor classificatie van een nieuw datapunt hebben de dichtstbij gelegen observaties het meeste invloed

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- Hoe bepaalt de Radial Kernel hoeveel invloed een bepaald punt heeft op de classificatie van een nieuwe observatie?
- Net als bij de Polynomial Kernel refereren a en b naar 2 verschillende doseringen:

$$e^{-\gamma(a-b)^2}$$

- Het verschil tussen de metingen wordt gekwadrateerd, wat ons een gekwadrateerde afstand tussen de observaties geeft.

© 2024 Olivier Claerbout

De Radial Kernel

- De invloed die een observatie op een andere heeft, is dus een functie van de gekwadrateerde afstand

$$e^{-\gamma(a-b)^2}$$

- γ (gamma), bepaald door Cross Validation, schaalt de gekwadrateerde afstand, en bijgevolg de invloed. Vb met gamma = 1 en 2 nabijgelegen observaties 2,5 en 4:

$$e^{-(2,5-4)^2} = e^{-(-1,5)^2} = e^{-2,25} = 0,11$$

- Met gamma = 2 en dezelfde datapunten: $e^{-2(2,5-4)^2} = e^{-2(-1,5)^2} = e^{-2\times 2,25} = 0,01$

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- Door de afstand te schalen, schaalt gamma de invloed die 2 punten op elkaar hebben:
  - 0,01 bij = 2
  - 0,11 bij = 1
- We kijken nu hoeveel invloed 2 punten die verder van elkaar weg liggen (vb 2,5 en 16) op elkaar hebben (bij = 1):
  - $e^{-(2,5-16)^2} = e^{-182,25} \simeq 0$
- Hoe verder ze van elkaar liggen, hoe minder ze elkaar beïnvloeden
- Net als bij de Polynomial Kernel krijgen we bij de Radial Kernel de hoog-dimensionale relatie door waarden in de formule te stoppen

$$e^{-\gamma(a-b)^2} = de\ hoogdimensionale\ relatie$$

© 2024 Olivier Claerbout

De Radial Kernel

- Alvorens verder te gaan: we vereenvoudigen de dataset tot slechts 2 observaties:



- We gebruiken de Polynomial Kernel om te begrijpen hoe de Radial Kernel in oneindig veel dimensies werkt.

Indien r = 0, dan:
- Vereenvoudigt de Polynomial Kernel tot een enkele term

$$(a \cdot b + r)^d = (a \cdot b)^d = a^d b^d = (a^d) \cdot (b^d)$$

- En dit geeft ons een Dot Product met één enkele coördinaat

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- Als d = 2 dan krijgen we: $a^2 b^2 = (a^2) \cdot (b^2)$

… dit komt overeen met het Dot Product van a² en b²

- Dit Dot Product heeft slechts één coördinaat. De nieuwe coördinaat is dus gewoon het kwadraat van de meting op de originele as.
- Stel 2 metingen voor dosis: 2,5 en 4: $2{,}5^2 4^2 = (2{,}5^2) \cdot (4^2)$
  - De nieuwe x-as coördinaat voor het eerste punt is 2.5² = 6,25
  - De nieuwe x-as coördinaat voor het tweede punt is 4² = 16

→ Als r = 0 en d = 2 is het enige wat de Polynomial Kernel veroorzaakt een data shift op de originele as

© 2024 Olivier Claerbout

De Radial Kernel

- Als r = 0 en d = 3 dan krijgen we: $a^3 b^3 = (a^3) \cdot (b^3)$

- Dezelfde 2 metingen voor dosis → 2,5 en 4:
  - De nieuwe x-as coördinaat voor het eerste punt is 2.5³ = 15,625
  - De nieuwe x-as coördinaat voor het tweede punt is 4³ = 64

→ Als r = 0 en d = 3 is het enige wat de Polynomial Kernel veroorzaakt een data shift op de originele as

→ Als r = 0 en d = 1? de data blijft op dezelfde locatie!

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- 0 als waarde voor r lijkt zinloos omdat de data in de originele dimensie blijft, ongeacht de waarde voor d.
- Terug naar de volledige dataset:
  - Wat gebeurt er indien we een Polynomial Kernel met r = 0 en d = 1 nemen en we voegen er een Polynomial Kernel met r = 0 en d = 2 bij

$$a^1 b^1 + a^2 b^2 \qquad a^1 b^1 + a^2 b^2 = (a, a^2) \cdot (b, b^2)$$

Dit geeft ons een Dot Product met coördinaten voor 2 dimensies!

© 2024 Olivier Claerbout

De Radial Kernel

- De eerste coördinaat is de originele dosis
- De tweede coördinaat is de dosis²
  - Nu kan je deze getransformeerde data op de x en y-as plotten en een Support Vector Classifier zoeken om de data te splitsen

Ondertussen weet je dat de data niet echt wordt getransformeerd naar een hogere ruimte, maar dat het Dot Product wordt gebruikt om de hoog dimensionale relaties te krijgen.

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- Voeg nu nog een Polynomial Kernel met r = 0 en d = 3 toe...
  - Dan heeft het Dot Product nu coördinaten voor 3 dimensies en kunnen we de getransformeerde data plotten op x/y/z assen...

$$a^1 b^1 + a^2 b^2 + a^3 b^3 = (a, a^2, a^3) \cdot (b, b^2, b^3)$$

© 2024 Olivier Claerbout

De Radial Kernel

- Wat als we steeds maar Polynomial Kernels met r = 0 blijven toevoegen met d = 1 tot ∞ ?

$$a^1 b^1 + a^2 b^2 + a^3 b^3 + \ldots + a^\infty b^\infty = (a, a^2, a^3, \ldots, a^\infty) \cdot (b, b^2, b^3, \ldots, b^\infty)$$

We hebben nu een Dot Product met coördinaten voor een oneindig aantal dimensies! En dat is exact wat de **Radial Kernel** doet!

Copyright Olivier Claerbout 2024

© 2024 Olivier Claerbout

De Radial Kernel

- We starten opnieuw met de Radial Kernel:

$$e^{-\gamma(a-b)^2} = e^{-\gamma(a^2+b^2-2ab)} = e^{-\gamma(a^2+b^2)} e^{\gamma 2ab}$$

We kunnen elke waarde kiezen voor γ, dus we kiezen ½:

$$e^{-\frac{1}{2}(a-b)^2} = e^{-\frac{1}{2}(a^2+b^2-2ab)} = e^{-\frac{1}{2}(a^2+b^2)} e^{ab}$$

Noot: *Een taylorreeks of taylorontwikkeling is de voorstelling of benadering van een functie als een oneindige machtreeks waarvan de coëfficiënten worden berekend uit de waarden van de afgeleiden van deze functie in een bepaald punt.*

© 2024 Olivier Claerbout

(Taylorreeks)

Een taylorreeks of taylorontwikkeling is de voorstelling of benadering van een functie als een oneindige machtreeks waarvan de coëfficiënten worden berekend uit de waarden van de afgeleiden van deze functie in een bepaald punt.

Dit wordt gebruikt om complexe functies te benaderen met een reeks die makkelijker te hanteren is.

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- Voorbeeld van een taylorreeks rond het punt a:

$$f(x)=f(a)+\frac{f'(a)}{1!}(x-a)+\frac{f''(a)}{2!}(x-a)^2+\frac{f'''(a)}{3!}(x-a)^3+...+\frac{f^{\infty}(a)}{\infty!}(x-a)^{\infty}$$

Voorbeeld: conversie e^x naar een oneindige som – de taylorreeks van e^x:

$$e^x=e^a+\frac{e^a}{1!}(x-a)+\frac{e^a}{2!}(x-a)^2+\frac{e^a}{3!}(x-a)^3+...+\frac{e^a}{\infty!}(x-a)^{\infty}$$

© 2024 Olivier Claerbout

De Radial Kernel

- Wat is a?

$$e^x=e^a+\frac{e^a}{1!}(x-a)+\frac{e^a}{2!}(x-a)^2+\frac{e^a}{3!}(x-a)^3+...+\frac{e^a}{\infty!}(x-a)^{\infty}$$

De definitie van een taylorreeks zegt dat a elke waarde kan zijn, zo lang f(a) bestaat… Wat zou dus een goede waarde voor a zijn?

$e^0 = 1 \rightarrow$ we stellen a = 0

$$e^x=e^0+\frac{e^0}{1!}(x-0)+\frac{e^0}{2!}(x-0)^2+\frac{e^0}{3!}(x-0)^3+...+\frac{e^0}{\infty!}(x-0)^{\infty}$$

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- We vereenvoudigen:

$$e^x = e^0 + \frac{e^0}{1!}(x-0) + \frac{e^0}{2!}(x-0)^2 + \frac{e^0}{3!}(x-0)^3 + \ldots + \frac{e^0}{\infty!}(x-0)^\infty$$

$$e^x = 1 + \frac{1}{1!}x + \frac{1}{2!}x^2 + \frac{1}{3!}x^3 + \ldots + \frac{1}{\infty!}x^\infty$$

e^x is dus gelijk aan deze oneindige som!

Praktisch: benadering van e^x met x = 1 rond het punt a = 0:

$$e^1 = 1 + 1 + \frac{1}{2} + \frac{1}{6} + \frac{1}{24} = 2{,}708$$

de afgeleide van $e^x = e^x$, e ~ 2,718; de Taylorreeks van e^x rond a=0 is de Maclaurinreeks

© 2024 Olivier Claerbout

De Radial Kernel

- Teruggaand naar de Radial Kernel:

$$e^{-\frac{1}{2}(a-b)^2} = e^{-\frac{1}{2}(a^2+b^2-2ab)} = e^{-\frac{1}{2}(a^2+b^2)} e^{ab}$$

We maken de taylorreeks voor deze laatste term

$$e^{ab} = 1 + \frac{1}{1!}ab + \frac{1}{2!}(ab)^2 + \frac{1}{3!}(ab)^3 + \ldots + \frac{1}{\infty!}(ab)^\infty$$

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- *Voorheen voegden we voortdurend Polynomial Kernels met r = 0 en d gaande van 0 tot ∞ toe, en we kregen een Dot Product met coördinaten voor een ∞ aantal dimensies:*

$$a^0b^0+a^1b^1+a^2b^2+a^3b^3+\ldots+a^\infty b^\infty=(1,a,a^2,a^3,\ldots,a^\infty)\cdot(1,b,b^2,b^3,\ldots,b^\infty)$$

Taylorreeks van de laatste term

$$e^{ab}=1+\frac{1}{1!}ab+\frac{1}{2!}(ab)^2+\frac{1}{3!}(ab)^3+\ldots+\frac{1}{\infty!}(ab)^\infty$$

Elke term in de taylorreeks bevat een Polynomial Kernel met r = 0 en d gaande van 0 tot ∞

© 2024 Olivier Claerbout

De Radial Kernel

- *Het Dot Product van de rechterzijde komt overeen met de som van de vermenigvuldiging van alle overeenkomstige termen*

$$a^0b^0+a^1b^1+a^2b^2+a^3b^3+\ldots+a^\infty b^\infty=(1,a,a^2,a^3,\ldots,a^\infty)\cdot(1,b,b^2,b^3,\ldots,b^\infty)$$

- *Op dezelfde wijze maken we het Dot Product van de taylorreeks:*

$$e^{ab}=1+\frac{1}{1!}ab+\frac{1}{2!}(ab)^2+\frac{1}{3!}(ab)^3+\ldots+\frac{1}{\infty!}(ab)^\infty$$

$$e^{ab}=\left(1,\sqrt{\frac{1}{1!}}a,\sqrt{\frac{1}{2!}}a^2,\sqrt{\frac{1}{3!}}a^3,\ldots,\sqrt{\frac{1}{\infty!}}a^\infty\right)\cdot\left(1,\sqrt{\frac{1}{1!}}b,\sqrt{\frac{1}{2!}}b^2,\sqrt{\frac{1}{3!}}b^3,\ldots,\sqrt{\frac{1}{\infty!}}b^\infty\right)$$

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- *Teruggaand naar de originele Radial Kernel:*

$$e^{-\frac{1}{2}(a-b)^2} = e^{-\frac{1}{2}(a^2+b^2-2ab)} = e^{-\frac{1}{2}(a^2+b^2)} e^{ab}$$

$$e^{ab} = \left(1, \sqrt{\frac{1}{1!}}a, \sqrt{\frac{1}{2!}}a^2, \sqrt{\frac{1}{3!}}a^3, \ldots, \sqrt{\frac{1}{\infty!}}a^{\infty}\right) \cdot \left(1, \sqrt{\frac{1}{1!}}b, \sqrt{\frac{1}{2!}}b^2, \sqrt{\frac{1}{3!}}b^3, \ldots, \sqrt{\frac{1}{\infty!}}b^{\infty}\right)$$

$$e^{-\frac{1}{2}(a-b)^2} = e^{-\frac{1}{2}(a^2+b^2)} \left[\left(1, \sqrt{\frac{1}{1!}}a, \sqrt{\frac{1}{2!}}a^2, \sqrt{\frac{1}{3!}}a^3, \ldots, \sqrt{\frac{1}{\infty!}}a^{\infty}\right) \cdot \left(1, \sqrt{\frac{1}{1!}}b, \sqrt{\frac{1}{2!}}b^2, \sqrt{\frac{1}{3!}}b^3, \ldots, \sqrt{\frac{1}{\infty!}}b^{\infty}\right)\right]$$

© 2024 Olivier Claerbout

De Radial Kernel

- *On de Radial Kernel volledig als Dot Product te schrijven, vermenigvuldigen we beide delen van het product met de vierkantswortel van de term waarmee we initieel vermenigvuldigen:*

$$e^{-\frac{1}{2}(a-b)^2} = e^{-\frac{1}{2}(a^2+b^2)} \left[\left(1, \sqrt{\frac{1}{1!}}a, \sqrt{\frac{1}{2!}}a^2, \sqrt{\frac{1}{3!}}a^3, \ldots, \sqrt{\frac{1}{\infty!}}a^{\infty}\right) \cdot \left(1, \sqrt{\frac{1}{1!}}b, \sqrt{\frac{1}{2!}}b^2, \sqrt{\frac{1}{3!}}b^3, \ldots, \sqrt{\frac{1}{\infty!}}b^{\infty}\right)\right]$$

$$stel\sqrt{e^{-\frac{1}{2}(a^2+b^2)}} = s$$

$$e^{-\frac{1}{2}(a-b)^2} = \left(s, s\sqrt{\frac{1}{1!}}a, s\sqrt{\frac{1}{2!}}a^2, s\sqrt{\frac{1}{3!}}a^3, \ldots, s\sqrt{\frac{1}{\infty!}}a^{\infty}\right) \cdot \left(s, s\sqrt{\frac{1}{1!}}b, s\sqrt{\frac{1}{2!}}b^2, s\sqrt{\frac{1}{3!}}b^3, \ldots, s\sqrt{\frac{1}{\infty!}}b^{\infty}\right)$$

De Radial Kernel is een Dot Product met coördinaten in een ∞ aantal dimensies!

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

De Radial Kernel

- *Wanneer we dus nummers 'in de Radial Kernel stoppen' en de berekening doen (veronderstel gamma = 1)...*

$$e^{-(a-b)^2} = e^{-(2,5-4)^2} = e^{-2,25} = 0,11$$

de uitkomst hiervan is de relatie tussen de 2 punten in een oneindig aantal dimensies!

© 2024 Olivier Claerbout

SVM - praktisch

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

Wanneer SVM gebruiken?

- Kan zowel gebruikt worden voor regressie als classificatie (en zelfs clustering)
- Werkt goed op kleine datasets (itt neurale netwerken)
- Is nog altijd effectief wanneer het aantal features groter is dan het aantal training samples
- Het werkt goed bij een groot aantal features (high dimensional space)
- Gebruikt niet alle training examples tijdens training ⇒ geheugenefficiënt
- Geen lokale minima/optima, maar globaal optimum

© 2024 Olivier Claerbout

SVM vs Logistic Regression

- Bij veel features ten opzichte van het aantal training samples:
  - Gebruik logistic regression of SVM zonder kernel (= lineaire kernel)
- Bij klein aantal features en redelijk aantal training samples:
  - Gebruik SVM met RBF kernel
- Bij weinig features met veel training samples:
  - creëer meer features en gebruik logistic regression of SVM zonder kernel (= lineaire kernel)

Copyright Olivier Claerbout 2024

© 2024 Olivier Claerbout

Implementatie v/e SVM

- Test eerst een lineaire kernel (geen kernel) en RBF kernel
- Tune C
- Bij RBF: tune zowel C als gamma

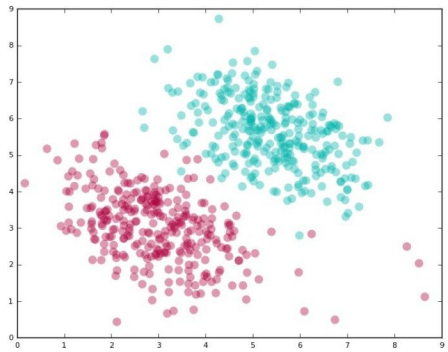
© 2024 Olivier Claerbout

SVM - regulatie

Hoe bepalen we de grootte van de Soft Margin?

→ Werken met een **regularisatie parameter C**

Afweging tussen:
· correcte classificatie op training set en
· een grote marge tussen de klasses (large margin).



© 2024 Olivier Claerbout

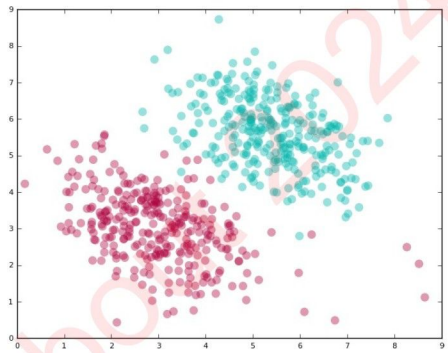
Copyright Olivier Claerbout 2024

SVM - regulatie

Hoe bepalen we de grootte van de Soft Margin?

Hoge C-waarde:

- De SVM zal streven naar een kleinere marge als dat betekent dat meer datapunten correct worden geclassificeerd.
- Het model wordt minder bereid om misclassificaties op de trainingsset toe te staan, wat kan leiden tot een model dat te goed past op de trainingsdata (overfitting).
- Een hoge C-waarde legt meer nadruk op het minimaliseren van de trainingsfout, wat soms ten koste gaat van de marge.



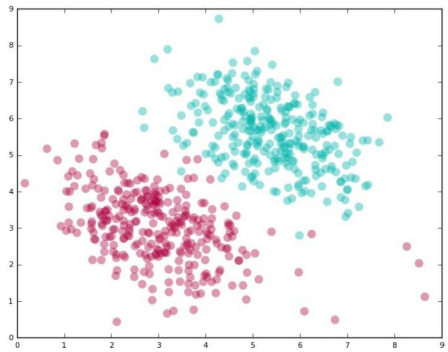
© 2024 Olivier Claerbout

SVM - regulatie

Hoe bepalen we de grootte van de Soft Margin?

Lage C-waarde:

- De SVM maakt het minder uit als sommige datapunten verkeerd worden geclassificeerd, zolang de marge maar groot is.
- Het model staat meer misclassificaties toe, wat kan resulteren in een model dat meer generaliseert (minder overfitting).
- Een lage C-waarde geeft de voorkeur aan een grotere marge en kan dus beter presteren op nieuwe, ongeziene gegevens.

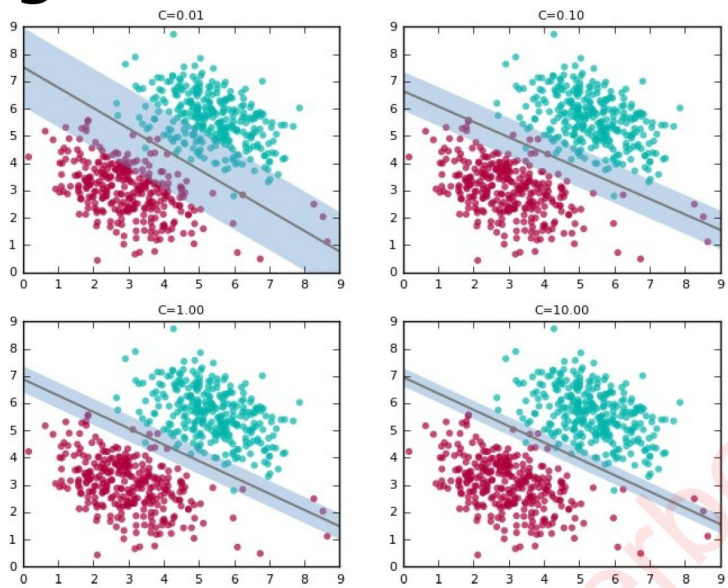


Keuze van C gebeurt via … cross validation!

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

SVM - regulatie



© 2024 Olivier Claerbout

SVM – gamma

Gamma
- Bepaalt hoe ver de invloed van een enkel trainingsvoorbeeld reikt
- Of: de invloed van een individueel voorbeeldpunt op de beslissingsgrens.
- Heeft een directe invloed op de ‘gladheid’ van de beslissingsgrens in de SVM-classificator.

Grote gamma-waarde:
- Elke support vector heeft een klein regionaal effect heeft.
- Dit leidt tot meer complexe beslissingsgrenzen die dichter bij individuele punten passen.
- Met andere woorden, het model kan zeer gevoelig worden voor de locatie van de support vectoren, wat kan leiden tot een hoge variantie en dus tot overfitting op de trainingsdata.

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

SVM – gamma

Gamma
- Bepaalt hoe ver de invloed van een enkel trainingsvoorbeeld reikt

Kleine gamma-waarde:
- Een lage waarde voor gamma betekent dat elke support vector een breed effect heeft.
- Dit resulteert in een gladdere beslissingsgrens die minder geneigd is om zich aan te passen aan individuele voorbeeldpunten.
- We krijgen hierdoor een hogere bias maar lagere variantie.

© 2024 Olivier Claerbout

SVM – gamma

Een juiste gamma-waarde is essentieel voor de balans tussen bias en variantie

Een goede gamma-waarde helpt het model
- te generaliseren naar ongeziene data door overfitting te voorkomen
- nauwkeurig genoeg te zijn om onderscheid te maken tussen de klassen.

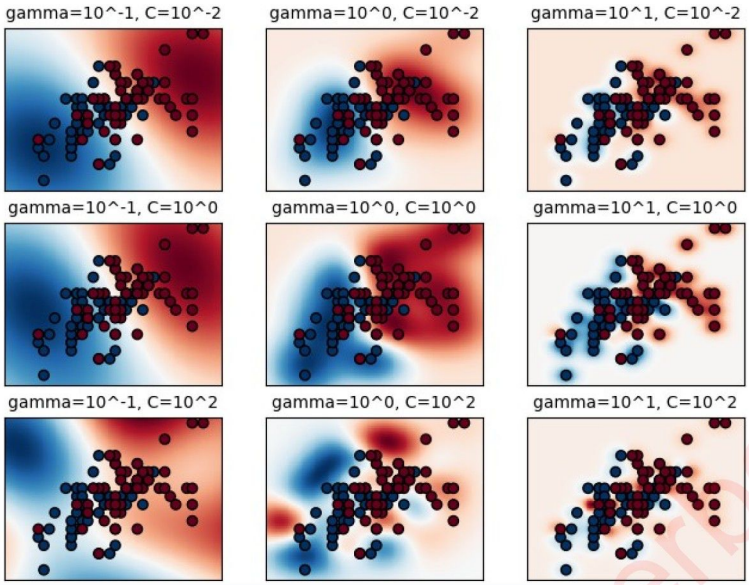
Het juist instellen van de gamma-parameter is een vorm van modelcomplexiteitscontrole.

Bij gebruik van een RBF kernel: **feature scaling** (= normalisatie) toepassen

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024

SVM – gamma



© 2024 Olivier Claerbout

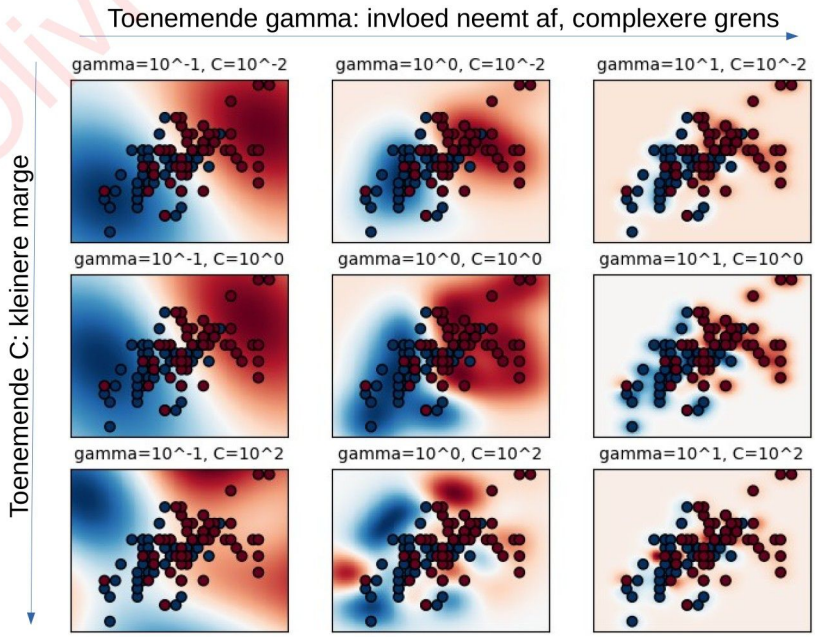
SYNTRA ANTWERPEN & VLAAMS-BRABANT

SVM – gamma

Lage C (C=10^-2): de SVM heeft een grote marge heeft en hoeft niet elk punt correct te classificeren. De invloed van gamma is minder uitgesproken.

Gemiddelde C (C=10^0): de invloed van gamma begint zichtbaar te worden: met een lage gamma is de marge breed en glad, terwijl met een hoge gamma de beslissingsgrens meer details van de data volgt.

Hoge C (C=10^2): zelfs een lage gamma-waarde geeft een vrij gedetailleerde beslissingsgrens, en bij een hoge gamma-waarde past de beslissingsgrens zich heel nauwkeurig aan bij de trainingdata, wat wijst op overfitting.



© 2024 Olivier Claerbout

SYNTRA ANTWERPEN & VLAAMS-BRABANT

Copyright Olivier Claerbout 2024

SVM - notebook

© 2024 Olivier Claerbout

Copyright Olivier Claerbout 2024